

ESTADÍSTICA

Grado en Enfermería

Tema I

Estadística descriptiva

Pedro Femia Marzo & Miguel Angel Luque Fernandez


pfemia@ugr.es; mluquefe@ugr.es

**Unidad de Bioestadística – Facultad de Medicina
Universidad de Granada**

Actualización: 2023



La investigación empírica



¿En cuáles de estas etapas se puede cometer error? ¿de qué tipo?

Tabla de datos en bruto (casos × variables) → cómo son los datos que analiza un paquete informático

Id	Sujeto	Sexo	FNacimiento	Edad	Peso	TALLA	Grupo	Rehabilitación	Nivel_AF	Fe	Na	K	urea	AcUrico	Colesterol	centro
1	Elias R. O.	Masculino	27-Nov-1987	17	63,2	180,0	Grupo control	.	Moderado	.	.	.	.	.	.	Granada
2	Manuel J G. O.	Masculino	14-Jan-1988	17	101,3	175,7	Grupo control	51	Alto	149	140	4,8	40	6,3	145	Málaga
3	Elena D. H.	Femenino	15-Jul-1987	18	52,0	166,7	Tratamiento intenso	71	Moderado	76	141	4,9	19	3,1	177	Málaga
4	J Ignacio F. E.	Masculino	09-Apr-1989	16	68,4	161,1	Tratamiento intenso	47	Alto	114	143	4,4	43	6,3	214	Granada
5	Laura A. R.	Femenino	22-Dec-1986	18	56,1	165,4	Tratamiento suave	53	Alto	53	141	4,3	46	4,8	177	Sevilla
6	Leticia R. U.	Femenino	16-Sep-1989	15	59,8	149,3	Grupo control	75	Moderado	124	137	4,5	29	5,2	211	Sevilla
7	Antonio Raul T. O.	Masculino	12-Jul-1989	16	62,3	164,0	Tratamiento suave	.	Alto	.	.	.	.	.	.	Granada
8	Julio M. A.	Masculino	05-May-1986	19	58,1	169,3	Tratamiento intenso	53	Alto	116	145	5,0	28	5,1	126	Málaga
9	Jose Manuel M. U.	Masculino	22-Aug-1987	18	71,1	174,5	Tratamiento suave	46	Bajo	73	142	4,4	21	4,8	152	Málaga
10	Luis B. E.	Masculino	08-Nov-1984	20	84,9	175,1	Grupo control	45	Bajo	125	143	4,2	29	6,9	161	Sevilla
11	Eva A. R.	Femenino	17-Aug-1987	18	58,7	154,2	Tratamiento suave	50	Moderado	74	142	4,2	37	4,9	159	Málaga
12	Enrique R. E.	Masculino	10-Nov-1985	19	84,6	177,4	Tratamiento intenso	36	Alto	147	136	4,8	24	3,6	150	Málaga
13	Andres J P. R.	Masculino	22-Jan-1989	16	54,4	173,2	Tratamiento intenso	47	Alto	68	139	4,1	30	5,7	172	Granada
14	Manuel J G. O.	Masculino	14-Jan-1988	17	104,3	176,4	Grupo control	48	Moderado	243	142	4,5	36	6,7	143	Málaga
15	Sebastián G. U.	Masculino	14-Sep-1989	15	91,3	170,4	Tratamiento intenso	49	Alto	80	140	4,4	43	5,1	160	Granada
16	Antonio Raul T. O.	Masculino	12-Jul-1989	16	62,8	163,4	Tratamiento suave	24	Alto	69	146	4,2	35	6,1	135	Granada
17	Angel M. A.	Masculino	04-Aug-1988	17	67,2	176,1	Tratamiento suave	.	Bajo	.	.	.	.	.	.	Granada
18	Patricia B. A.	Femenino	16-Jun-1988	17	61,0	169,5	Tratamiento intenso	54	Moderado	103	137	4,7	23	4,1	212	Sevilla
19	Raúl G. A.	Masculino	06-May-1987	18	58,1	175,5	Tratamiento intenso	.	.	.	.	.	.	.	.	Málaga
20	Carmen T. E.	Femenino	17-Jul-1988	17	73,4	167,1	Grupo control	39	Moderado	72	140	4,4	23	2,5	139	Málaga
21	Carmen T. E.	Femenino	17-Jul-1988	17	71,8	166,6	Grupo control	.	Bajo	.	.	.	.	.	.	Málaga
22	Javier P. E.	Masculino	16-Jul-1987	18	76,9	187,2	Grupo control	65	Moderado	81	140	4,4	30	4,4	148	Granada
23	Antonio D. I.	Masculino	13-May-1989	16	54,7	168,4	Tratamiento suave	.	Moderado	.	.	.	.	.	.	Granada
24	Carlos Fª C. I.	Masculino	08-Aug-1988	16	54,9	164,3	Grupo control	49	Bajo	92	139	4,7	19	5,4	183	Granada
25	Antonio Raul T. O.	Masculino	12-Jul-1989	16	62,5	164,7	Tratamiento suave	41	Alto	76	139	4,5	32	7,0	168	Sevilla
26	Miriam M. E.	Femenino	22-Sep-1989	15	52,3	154,9	Tratamiento intenso	53	Moderado	84	141	4,6	33	4,8	150	Sevilla
27	Enrique J A. N.	Masculino	15-Apr-1988	17	59,7	172,2	Tratamiento intenso	39	Moderado	118	143	4,4	21	6,5	122	Granada
28	Angel M. A.	Masculino	04-Aug-1988	17	68,8	176,3	Tratamiento suave	62	Alto	148	141	4,5	30	4,8	139	Granada
29	Pedro G. O.	Masculino	30-Jul-1988	17	66,3	167,3	Tratamiento suave	41	Alto	77	.	.	42	4,8	116	Granada
30	Oscar Manuel L. A.	Masculino	04-Feb-1986	19	60,1	168,0	Tratamiento suave	43	Alto	63	143	4,6	26	5,5	137	Málaga
31	Alba T. O.	Femenino	20-Oct-1989	15	85,2	154,9	Tratamiento intenso	48	Moderado	112	138	4,2	18	5,0	146	Sevilla

Los tipos de datos

Modalidad

Cada una de las maneras en las que se presenta un carácter.

Tipos de Datos (o tipos de variables)

Cualitativos: aquellos que se refieren a una cualidad, no son expresables de manera rigurosa por un número.

1. **Nominales:** las modalidades no son susceptibles de estar ordenadas. Si solo hay dos modalidades se habla de datos *Binarios* o *Dicotómicos*.
→ **Categorías** (sexo, grupo sanguíneo, ser o no seropositivo para VIH,...)
2. **Ordinales:** cuando las modalidades son susceptibles de estar ordenadas
→ **Escalas** (escala de dolor (nada/poco/mucho), escala de satisfacción (baja/media/alta),...)

Cuantitativos: aquellos que necesariamente requieren de un número para ser expresados de manera rigurosa.

3. **Discretos:** aquellos datos que sólo pueden tomar "valores numéricos aislados" (*números enteros*)
→ **Recuentos** (nº de recaídas tras un tratamiento, nº de hijos, nº de afectados,...)
4. **Continuos:** pueden tomar cualquier valor dentro de un intervalo, de modo que entre dos valores cualquiera siempre existe otro valor posible (*números reales*)
→ **Medidas** (peso, nivel de colesterol, presión arterial,...)

Los tipos de datos

Cualitativos:

1. **Nominales** → Categorías

2. **Ordinales** → Escalas

↑ categorización


Cuantitativos:

3. **Discretos** → Recuentos

↑ redondeo

4. **Continuos:** → Medidas

Contenido informativo



? — ¿Qué tipo de carácter es la edad de un paciente?

Edad > 35

si
no



Grupos de
Edad

20-30
30-40
40-50



Edad
(forma habitual)

22
38
48
....



Edad
(exacta)

22.2
38.5
48.8
....

Las escalas en Medicina y Ciencias de la Salud

Constructo (RAE: Construcción teórica para comprender un problema determinado)

Idealización de un concepto en el marco de una teoría (habitualmente psicológica). Desde el punto de vista físico, el constructo es una magnitud **mal medible**, no hay un instrumento físico de medida que permita evaluar su magnitud o intensidad. En su lugar se utilizan **cuestionarios** (= **instrumentos** en el ámbito psicométrico). Habitualmente se define a través de múltiples aspectos (=variables = **ítems** del cuestionario).

Ejemplos de constructos: Inteligencia, personalidad, innovación, ansiedad,...

Por parte del profesional { Nivel de Sobrecarga
Nivel de Compromiso
Nivel de Competencia
... etc

Por parte del paciente

Nivel de calidad de vida (Cuestionario SF36)
Nivel de dependencia (Escala de Barthel)
Capacidad funcional física de las actividades cotidianas (Test de Barthel, Escala de Lawton y Brody)
Riesgo de deterioro de la integridad cutánea (Escala Norton)
Nivel de impacto de la fibromialgia (FIQ, *Fibromyalgia Impact Questionnaire*)
... etc

¿Puede **definir** lo que es la **estatura** de un paciente?

¿Puede explicar cómo **cuantificar** la **estatura** de un paciente?

¿Puede definir lo que es el **nivel de ansiedad** de un paciente?

¿Puede explicar cómo **cuantificar** el **nivel de ansiedad** de un paciente?

Cuestionario = Instrumento para *medir constructos*

Suele constar de varias preguntas = **ítems** cada uno de los cuales evalúa un aspecto determinado

Con frecuencia, los ítems se construyen en forma de un enunciado y una escala de intensidad (habitualmente con un número impar de opciones) = **escalas de Likert**

Las escalas de Likert son **sumativas**, de manera que se obtiene una **puntuación total** del cuestionario obtenida por la suma de los ítems

El paciente con esquizofrenia debe permanecer aislado

Niveles de la escala	Codificaciones alternativas		
	A	B	C
Total desacuerdo	1	0	-2
Desacuerdo	2	1	-1
Neutral	3	2	0
De acuerdo	4	3	1
Totalmente de acuerdo	5	4	2

¿Da igual la codificación elegida?

Ejemplo de variables de tipo ordinal (escalas)

Test de Zarit para evaluar el nivel de sobrecarga del cuidador

Ítem	Pregunta a realizar	Puntuación				
		0	1	2	3	4
1	¿Siente que su familiar solicita más ayuda de la que realmente necesita?					
2	¿Siente que debido al tiempo que dedica a su familiar ya no dispone de tiempo suficiente para usted?					
3	¿Se siente tenso cuando tiene que cuidar a su familiar y atender además otras responsabilidades?					
4	¿Se siente avergonzado por la conducta de su familiar?					
5	¿Se siente enfadado cuando está cerca de su familiar?					
6	¿Cree que la situación actual afecta de manera negativa a su relación con amigos y otros miembros de su familia?					
7	¿Siente temor por el futuro que le espera a su familiar?					
8	¿Siente que su familiar depende de usted?					
9	¿Se siente agobiado cuando tiene que estar junto a su familiar?					
10	¿Siente que su salud se ha resentido por cuidar a su familiar?					
11	¿Siente que no tiene la vida privada que desearía debido a su familiar?					
12	¿Cree que su vida social se ha visto afectada por tener que cuidar de su familiar?					
13	¿Se siente incómodo para invitar amigos a casa, a causa de su familiar?					
14	¿Cree que su familiar espera que usted le cuide, como si fuera la única persona con la que puede contar?					
15	¿Cree que no dispone de dinero suficiente para cuidar a su familiar además de sus otros gastos?					
16	¿Siente que será incapaz de cuidar a su familiar por mucho más tiempo?					
17	¿Siente que ha perdido el control sobre su vida desde que la enfermedad de su familiar se manifestó?					
18	¿Desearía poder encargar el cuidado de su familiar a otras personas?					
19	¿Se siente inseguro acerca de lo que debe hacer con su familiar?					
20	¿Siente que debería hacer más de lo que hace por su familiar?					
21	¿Cree que podría cuidar de su familiar mejor de lo que lo hace?					
22	En general: ¿Se siente muy sobrecargado por tener que cuidar de su familiar?					

La escala es **sumativa**. Para el diagnóstico suelen asumirse **puntos de corte** (=categorización de la variable numérica)

Un total de 22 ítems puntuados en una escala de 0 a 4 → Puntuación total 0-88 puntos →

< 46	No hay sobrecarga
46-56	Sobrecarga moderada
>56	Sobrecarga intensa

En España es más habitual puntuar los ítems de 1 a 5, entonces la escala iría de 22 a 110 puntos →

< 68	No hay sobrecarga
68-78	Sobrecarga moderada
>78	Sobrecarga intensa

Fiabilidad *test-retest* = 0.86

Ejemplo de variables de tipo ordinal (escalas)

Más ejemplos

Escala de Norton – Valoración del riesgo del deterioro de la integridad cutánea.

Consta de 14 ítems. Cada uno se puntúa de 1 (=mayor deterioro) a 4 (=menor deterioro)

Riesgo de formación de úlceras según la puntuación total:

Puntuación	Riesgo
1-11	Muy alto
12-14	Moderado
15-20	Mínimo

Escala de Barthel – Valoración de la capacidad para realizar las actividades básicas de la vida diaria

Consta de 10 ítems. No todos se puntúan igual. Valoración de cada ítem: 0 (=independencia), 5, 10 incluso 15 en algunos ítems (mayor puntuación = mayor independencia) →

Puntuación	Nivel de dependencia
0 – 19	Dependencia Total
20 – 39	Dependencia Grave
40 – 59	Dependencia Moderada
60 – 85	Dependencia Leve
86 – 100	Independiente



Actividad	Puntuación
Comer	0 – 5 – 10
Empleo ducha/baño	0 – 5
Vestirse	0 – 5 – 10
Aseo personal	0 – 5
Control anal	0 – 5 – 10
Control vesical	0 – 5 – 10
Uso retrete	0 – 5 – 10
Trasladarse (sillón/cama)	0 – 5 – 10 – 15
Desplazamiento	0 – 5 – 10 – 15
Subir escaleras	0 – 5 – 10

Construir un instrumento no es inmediato. Debe demostrarse su

- **Validez:** que el instrumento realmente mide el constructo que se pretende medir
- **Fiabilidad:** si se mide repetidamente a los mismos pacientes ¿se obtiene siempre el mismo resultado?

El **análisis de cuestionarios** no se va a abordar en este curso. Requiere conocimientos un tanto más avanzados (para los que este curso constituye la base). Técnicas habituales son las propias del **Análisis Factorial** (tanto exploratorio como confirmatorio)

Métodos descriptivos

Datos

Id	Sujeto	Sexo	Fecha de nacimiento	Edad	Peso	TALLA	Grupo	Rehabilitación	AF	Fe	Na	K	urea	Acido Urico	Colesterol	centro
1	Elias R. O.	Masculino	27-Nov-1907	17	63,2	180,0	Grupo control	Moderado								Granada
2	Manuel J. G. O.	Masculino	14-Jan-1908	17	101,3	175,7	Grupo control	Alto	51	149	140	4,8	40	6,3	145	Málaga
3	Elena D. H.	Femenino	15-Jul-1907	18	52,0	168,7	Tratamiento intenso	Moderado	76	141	4,9	19	3,1	177		Málaga
4	Ignacio F. E.	Masculino	30-Apr-1909	16	68,4	181,1	Tratamiento intenso	Alto	114	143	4,4	43	6,3	214		Granada
5	Laura A. R.	Femenino	22-Dec-1906	18	56,1	165,4	Tratamiento suave	Alto	53	141	4,3	46	4,8	177		Sevilla
6	Leticia R. U.	Femenino	16-Sep-1909	15	59,8	149,3	Grupo control	Moderado	124	137	4,5	29	5,2	211		Sevilla
7	Antonio Raúl T. O.	Masculino	12-Jul-1909	16	62,3	164,0	Tratamiento suave	Alto								Granada
8	Julio M. A.	Masculino	05-May-1906	19	68,1	169,3	Tratamiento intenso	Alto	116	145	5,0	38	5,1	126		Málaga
9	José Manuel M. O.	Masculino	22-Aug-1907	18	71,1	174,5	Tratamiento suave	Bajo	73	142	4,4	21	4,8	152		Málaga
10	Luis B. E.	Masculino	08-Nov-1904	20	84,9	175,1	Grupo control	Bajo	125	143	4,2	29	6,9	161		Sevilla
11	Eva A. R.	Femenino	17-Aug-1907	18	50,7	154,2	Tratamiento suave	Moderado	74	142	4,2	37	4,9	159		Málaga
12	Enrique P. E.	Masculino	10-Nov-1905	19	64,6	177,4	Tratamiento intenso	Alto	147	136	4,9	24	3,6	150		Málaga
13	Andrés J. P. R.	Masculino	22-Jan-1909	16	54,4	173,2	Tratamiento intenso	Alto	69	139	4,1	30	5,7	172		Granada
14	Manuel J. G. O.	Masculino	14-Jan-1908	17	104,3	176,4	Grupo control	Moderado	243	142	4,5	36	6,7	143		Málaga
15	Sebastián G. U.	Masculino	14-Sep-1909	15	91,3	170,4	Tratamiento intenso	Alto	80	140	4,4	43	5,1	160		Granada
16	Antonio Raúl T. O.	Masculino	12-Jul-1909	16	62,0	163,4	Tratamiento suave	Alto	69	146	4,2	35	6,1	135		Granada
17	Angel M. A.	Masculino	04-Aug-1908	17	67,2	176,1	Tratamiento suave	Bajo								Granada
18	Patricia B. A.	Femenino	16-Jun-1908	17	61,0	168,5	Grupo control	Moderado	103	137	4,7	23	4,1	212		Sevilla
19	Raúl G. A.	Masculino	06-May-1907	18	58,1	175,5	Tratamiento intenso									Málaga
20	Camren T. E.	Femenino	17-Jul-1908	17	73,4	167,1	Grupo control	Moderado	72	140	4,4	23	2,5	139		Málaga
21	Camren T. E.	Femenino	17-Jul-1908	17	71,8	166,6	Grupo control	Bajo								Málaga
22	Javier P. E.	Masculino	15-Jul-1907	18	76,9	187,2	Grupo control	Moderado	81	140	4,4	30	4,4	148		Granada
23	Antonio D. I.	Masculino	13-May-1909	16	54,7	169,4	Tratamiento suave	Moderado								Granada
24	Carlos P. C. I.	Masculino	06-Aug-1908	16	54,9	164,3	Grupo control	Bajo	92	139	4,7	19	5,4	163		Granada
25	Antonio Raúl T. O.	Masculino	12-Jul-1909	16	62,5	164,7	Tratamiento suave	Alto	76	139	4,5	32	7,0	168		Sevilla
26	Miriam M. E.	Femenino	22-Sep-1909	15	52,3	154,9	Tratamiento intenso	Moderado	84	141	4,6	33	4,8	150		Sevilla
27	Enrique J. A. N.	Masculino	15-Apr-1908	17	59,7	172,2	Tratamiento intenso	Moderado	118	143	4,4	21	6,5	122		Granada
28	Angel M. A.	Masculino	04-Aug-1908	17	69,8	176,3	Tratamiento suave	Alto	140	141	4,5	30	4,8	139		Granada
29	Pedro G. O.	Masculino	30-Jul-1908	17	66,3	167,3	Tratamiento suave	Alto	77							Granada
30	Osca Manuel L. A.	Masculino	04-Feb-1906	19	60,1	168,0	Tratamiento suave	Alto	63	143	4,6	26	5,5	137		Málaga
31	Alba T. O.	Femenino	20-Oct-1909	15	65,2	154,9	Tratamiento intenso	Moderado	112	138	4,2	16	5,0	146		Sevilla
32	Andrés J. P. R.	Masculino	22-Jan-1909	16	54,9	173,9	Tratamiento intenso	Moderado	25	146	4,0	25	4,8	112		Granada
33	Laura A. R.	Femenino	22-Dec-1906	18	55,0	165,1	Tratamiento suave	Alto	126	137	4,5	32	3,6	151		Málaga
34	Natalia P. R.	Femenino	13-Jun-1908	17	61,8	170,2	Grupo control	Bajo	45	139	4,0	30	4,1	126		Granada


Resumen de la información

3 niveles descriptivos:

- Tablas de frecuencias
- Representaciones gráficas
- Medidas descriptivas

EDAD

		Frecuencia	Porcentaje	Porcentaje acumulado
Validos	2.00	6	10.7	10.7
	3.00	11	19.6	30.4
	4.00	9	16.1	46.4
	5.00	13	23.2	69.6
	6.00	7	12.5	82.1
	7.00	6	10.7	92.9
	8.00	4	7.1	100.0
	Total	56	100.0	



Se trata de sintetizar cómo es la **distribución de la variable**

Estadísticos descriptivos

	N	Mínimo	Máximo	Media	Desv. típ.
Peso (kg)	190	41,5	106,8	64,777	12,9230

Tablas de frecuencias // variables nominales

Grupo sanguíneo observado en los participantes del estudio (n=500)

	Frecuencia absoluta (n_i)	Frecuencia relativa (f_i)	Porcentaje
A	150	0.30	30.0
B	75	0.15	15.0
AB	25	0.05	5.0
O	250	0.50	50.0
Total	500		100.0

La **frecuencia relativa** (o el %) no es mas que la *estandarización* de la frecuencia absoluta. Este tipo de estandarización es muy conveniente, ya que permitirá hacer comparaciones coherentes, como veremos más adelante

Frecuencia absoluta (*recuento*): $f_1 + f_2 + \dots + f_k = \sum_{i=1}^k f_i = n$

Frecuencia relativa (*porcentaje*): $h_i = f_i / n$; $h_1 + h_2 + \dots + h_k = \sum_{i=1}^k h_i = 1$

Sobre la notación y el símbolo sumatoria

Aquí $k = 4$: $n = \sum_{i=1}^4 f_i = \underset{f_1}{150} + \underset{f_2}{75} + \underset{f_3}{25} + \underset{f_4}{250} = 500$

Propiedades: 1) $\sum_{i=1}^k ax_i = a \sum_{i=1}^k x_i$; 2) $\sum_{i=1}^k (a + x_i) = ka + \sum_{i=1}^k x_i$

Tablas de frecuencias // variables ordinales

Efecto observado tras la aplicación de una terapia acuática en n=500 mujeres con fibromialgia

Estado	Frecuencia	Frecuencia acumulada	Porcentaje	Porcentaje acumulado
Mucho peor	25	25	5.0	5.0
Peor	98	$25+98= 123$	19.6	$5+19.6= 24.6$
Igual	159	$123+159= 282$	31.8	$24.6+31.8= 56.4$
Mejor	147	$282+147= 429$	29.4	85.8
Mucho mejor	71	$429+71= 500$	14.2	100
Total	500		100	

La posibilidad de ordenar de forma unívoca a las categorías de la variable permite poder definir un nuevo tipo de frecuencia: la **frecuencia acumulada** (que podrá ser relativa o absoluta)

La frecuencia acumulada es relativa al orden natural de las categorías

Tablas de frecuencias // variables discretas

Distribución de la edad (años)

n=124

	n	f(%)	F(%) acum.
15	5	4.0	4.0
16	28	22.6	26.6
17	64	51.6	78.2
18	18	14.5	92.7
19	6	4.8	97.6
20	3	2.4	100.0

Total n=124 100.0

Con pocos valores distintos ($k=6$)

Distribución de la edad (años)

n=124

	n	f(%)	F(%) acum.
menos de 21	5	4.0	4.0
21-25	28	22.6	26.6
26-30	64	51.6	78.2
31-35	18	14.5	92.7
36-40	6	4.8	97.6
más de 40	3	2.4	100.0

Total n=124 100

Con muchos valores distintos (k grande)

Agrupación en intervalos desde el punto de vista estadístico

Si la variable discreta puede tomar muchos valores distintos, su resumen como tabla de frecuencias suele hacerse agrupándola en intervalos.

Los intervalos deben ser:

- **Homogéneos** (todos con la misma amplitud)
- **Exhaustivos** (recorren todos los valores de la variable)
- **Excluyentes** (no pueden solaparse)

TABLA DISTRIBUCION DE FRECUENCIAS VARIABLE CUANTITATIVA

I_i	x_i	n_i	f_i	N_i	F_i	$a_i = e_i - e_{i-1}$	$h_i = n_i / a_i$
$(e_0, e_1]$	x_1	n_1	f_1	N_1	F_1	$a_1 = e_1 - e_0$	h_1
$(e_1, e_2]$	x_2	n_2	f_2	N_2	F_2	$a_2 = e_2 - e_1$	h_2
$(e_2, e_3]$	x_3	n_3	f_3	N_3	F_3	$a_3 = e_3 - e_2$	h_3
.	.	.	.	.	.	.	.
.	.	.	.	.	.	.	.
.	.	.	.	.	.	.	.
$(e_{k-1}, e_k]$	x_k	n_k	f_k	$N_k = n$	$F_k = 1$	$a_k = e_k - e_{k-1}$	h_k
		n	1				

Marca de clase (x_i): Punto medio del intervalo $x_i = \frac{e_{i-1} + e_i}{2}$

Amplitud del intervalo: Diferencia entre los extremos del intervalo

Densidad de frecuencia: $h_i = \frac{n_i}{a_i}$

Tablas de frecuencias // variables continuas

Con variables continuas, no queda más remedio que agrupar en intervalos

**Nivel de colesterol (mg/dL) observado
n=157**

	n	f(%)	F % acum.
102 - 128	20	12.7	12.7
129 - 155	69	43.9	56.7
156 - 182	85	28.7	85.4
183 - 209	13	8.3	93.6
210 - 236	10	6.4	100.0

Total 157 100.0

No se han observado (se han redondeado) los valores decimales, por tanto, no hace falta solapar los intervalos

**Nivel de colesterol (mg/dL) observado
n=157**

	n	f(%)	F% acum.
(101, 128]	20	12.7	12.7
(128, 155]	69	43.9	56.7
(155, 182]	45	28.7	85.4
(182, 209]	13	8.3	93.6
(209, 236]	10	6.4	100.0

Total 157 100.0

Si que se han observado los valores decimales, es preciso establecer un criterio para los límites de los intervalos

(209, 236] indica: $209 < x \leq 236$

Tipos de datos

Diagramas de frecuencias ← Qué diagrama es correcto depende del *tipo* de variable

Datos cualitativos:

1. **Nominales**




Diagrama de sectores

2. **Ordinales**





Diagrama de barras

Cuantitativos

3. **Discretos**


$k \downarrow$



Polígono de frecuencias

4. **Continuos**


$k \uparrow$



Histograma

Diagramas de frecuencias // variables cualitativas

**Distribución de los grupos sanguíneos
(n=500)**



$$angulo_i^0 = 360^0 \times \frac{f_i}{n}$$

Diagrama de sectores






Diagrama de barras



Desgajado de un sector



¡menos adecuado!
(falsa tridimensionalidad)

Principio básico: para cada categoría de la variable, el área del objeto gráfico debe ser proporcional (o igual) a la frecuencia de dicha categoría.

Diagramas de frecuencias // variables ordinales y discretas

Distribución de la edad (n=124)





Diagrama de barras


Distribución de la edad (n=124)




Polígono de frecuencias

D. frecuencias // variables agrupadas en intervalos (discretas o continuas)

Distribución del nivel de colesterol (n=500)



Distribución del nivel de colesterol (n=500)





Histogramas

Las dos representaciones corresponden a los mismos datos. Pocos intervalos y muy anchos (dcha) pueden enmascarar la distribución real de la variable

Diagramas de frecuencias // muestras pequeñas

Distribución del nivel de colesterol (mg/dL)



Muestras pequeñas de variables continuas


Cuando hay pocos datos, los histogramas (izda) carecen de sentido. En su lugar es mejor hacer un **diagrama de puntos** (dcha). Tales diagramas tienen mayor interés si se usan con fines comparativos.

Diagramas de frecuencias

Otros diagramas

Pictogramas de repetición

Consumo de medicamentos en los cuatro distritos de una ciudad



Pictogramas de amplificación

Enfermedades más comunes en España
(los datos son ficticios)




La **nube de palabras** es un tipo de pictograma de amplificación muy utilizado en el ámbito de internet

Principios básicos de los diagramas de frecuencias:

- El área del motivo gráfico asignado a cada categoría/valor/intervalo debe ser proporcional a su frecuencia
- Siempre deben tener un encabezado en donde aparezcan *datos básicos* como son el tamaño muestral, las unidades de medida si las hay, el año de referencia,...


Diagramas de frecuencias // Gráficas comparativas

Barras solapadas





! Cuidado: En el eje de ordenadas debe aparecer la frecuencia relativa (%)

Polígonos de frecuencias




Uso de paneles




Diagramas de frecuencias // Gráficas comparativas

Pirámide de población

Muy utilizada en **demografía**. Se trata de un doble histograma en donde se representa la frecuencia de individuos en función de grupos de edad y sexo. No obstante, pueden representarse otras variables con fines comparativos (dcha)







Evolución de la pirámide de población española con pronóstico para el año 2025 (fuente: INE)



Diagramas de frecuencias // aspectos de las gráficas


En qué hay que fijarse (histogramas):

- **Simetría** de la distribución
- Presencia de **valores extremos** o **atípicos**
- Posible **mezcla** de grupos (**bimodalidad**)
- **Equilibrio** en las gráficas comparativas



Analice esta imagen

Pyramide des âges, Émirats arabes unis, 2005




Pirámide de población de los Emiratos Árabes en 2005.
(en ese año hubo mucha inmigración procedente, sobre todo, de Pakistán)

Source: Organisation des Nations Unies (World Population Prospects: The 2004 Revision)

Síntesis de datos: medidas descriptivas

¿En qué se diferencian estas dos distribuciones?




Síntesis de datos: medidas descriptivas

Medidas descriptivas

- De **posición**, con tendencia
 - **Central**: media, mediana, moda
 - **No central**: extremos, percentiles
- De **dispersión**: Rango, varianza, desviación típica, coeficiente de variación, rango intercuartílico

Dispersión = Variabilidad

Normalmente se **resumen** los datos proporcionando una medida de **posición central** junto a una de **dispersión**. Adicionalmente puede darse información relativa a otras medidas, como extremos y percentiles



Síntesis de datos: medidas descriptivas

Medidas descriptivas ← Qué medida se puede calcular depende del tipo de la variable

Datos cualitativos:

1. **Nominales** → Proporción (porcentajes), moda
2. **Ordinales** → Las anteriores y además medidas basadas en el orden de los datos:
Mediana y Percentiles, Rango intercuartílico

Cuantitativos

3. **Discretos**
 4. **Continuos**
- } → Todas las anteriores y además
Medidas basadas en el valor numérico de los datos:
Media y varianza (desviación típica)

Síntesis de datos: medidas descriptivas de posición

Nominales

Proporción (de cada categoría): es la frecuencia relativa de dicha categoría: $p_i = \frac{f_i}{n}$
 Cuando se informa de ella se suele dar como porcentaje: $(p_i \times 100)\%$

Moda: es el valor de la variable que tiene mayor frecuencia (puede no ser única).

Ordinales A las medidas descritas hay que añadir

Mediana: es el valor de la variable que divide a la muestra ordenada en dos partes iguales (es decir, deja tanto por debajo como por encima el 50% de las observaciones).

$$Me = x_{\left(\frac{n+1}{2}\right)}$$

Ejemplos:

$$a) \{3, 6, 7, 10, 15\} \rightarrow Me = x_{\left(\frac{5+1}{2}\right)} = x_{(3)} = 7$$

$$b) \{3, 6, 10, 15\} \rightarrow Me = x_{\left(\frac{4+1}{2}\right)} = x_{(2.5)} = \frac{6+10}{2} = 8$$

$$c) \{1, 5, 1, 2, 2, 4, 7, 2, 10\} \rightarrow Me = x_{(5)} = 2$$

$$d) \{peor, peor, peor, mejor, igual, mejor, peor\} \rightarrow Me = x_{\left(\frac{7+1}{2}\right)} = peor$$

No confundir la *posición mediana* $(n+1)/2$, con la *mediana* en sí, que es el valor que *ocupa* la posición mediana cuando los datos están ordenados de menor a mayor

Síntesis de datos: medidas descriptivas de posición

Más ejemplos:

Edad (años)
n=124

	n_i	N_i	F(%) acum.
15	5	5	4.0
16	28	33	26.6
17	64	97	78.2
18	18	115	92.7
19	6	121	97.6
20	3	124	100.0

Total **n=124**

$$Me = x_{\left(\frac{124+1}{2}\right)} = x_{(62.5)} = 17$$

La mediana es el primer valor de la variable cuya frecuencia acumulada es mayor o igual a 62.5 o, equivalentemente, cuyo porcentaje acumulado es mayor o igual al 50%

Edad (años)
n=124

	n_i	N_i	F(%) acum.
menos de 21	5	5	4.0
21-25	28	33	26.6
26-30	64	97	78.2
31-35	18	115	92.7
36-40	6	121	97.6
más de 40	3	124	100.0

Total **n=124**

$$Me = x_{\left(\frac{124+1}{2}\right)} = 26 \leq x_{(62.5)} \leq 30$$

Cuando la variable está agrupada en intervalos, la mediana se puede aproximar por **interpolación lineal** (se ve en prácticas)

• MEDIANA ($n/2$): CUANTILES: Percentiles, Deciles, Cuartiles ...

- **Cálculo para variables continuas:** De igual forma que la mediana pero usamos αn en vez de $n/2$ (equivalentemente α por $1/2$)
- El intervalo que contiene a $C(\alpha)$ será aquel $(I_{i-1}-I_i]$ cuyo $N_i > \alpha n$, o equivalentemente, aquel x_i cuyo $F_i > \alpha$.
- La expresión para el cálculo sería:

$$C(\alpha) = I_{i-1} + \frac{\alpha \cdot n - N_{i-1}}{n_i} a_i$$

C = cuantil (alfa)

I_{i-1} = extremo inferior del intervalo agrupado para la categoría identificada

ALFA = 0.3 (cuantil 30% o Decil 3 o Percentil 30)

n = tamaño de la muestra

N = frecuencia absoluta acumulada

a = amplitud

• MEDIANA ($n/2$): CUANTILES: Percentiles, Deciles, Cuartiles ...

- **Cálculo para variables continuas:** De igual forma que la mediana pero usamos αn en vez de $n/2$ (equivalentemente α por $\frac{1}{2}$)
- El intervalo que contiene a $C(\alpha)$ será aquel $(l_{i-1}, l_i]$ cuyo $N_i > \alpha n$, o equivalentemente, aquel x_i cuyo $F_i > \alpha$.
- La expresión para el cálculo sería:

$$C(\alpha) = l_{i-1} + \frac{\alpha \cdot n - N_{i-1}}{n_i} a_i$$

l_i	x_i	n_i	f_i	N_i	F_i	$a_i = e_i - e_{i-1}$	$h_i = n_i / a_i$
$(e_0, e_1]$	x_1	n_1	f_1	N_1	F_1	$a_1 = e_1 - e_0$	h_1
$(e_1, e_2]$	x_2	n_2	f_2	N_2	F_2	$a_2 = e_2 - e_1$	h_2
$(e_2, e_3]$	x_3	n_3	f_3	N_3	F_3	$a_3 = e_3 - e_2$	h_3
.	.	.	.	.	.	.	.
.	.	.	.	.	.	.	.
.	.	.	.	.	.	.	.
$(e_{k-1}, e_k]$	x_k	n_k	f_k	$N_k = n$	$F_k = 1$	$a_k = e_k - e_{k-1}$	h_k
		n	1				

Marca de clase (x_i): Punto medio del intervalo $x_i = \frac{e_{i-1} + e_i}{2}$


Amplitud del intervalo: Diferencia entre los extremos del intervalo

Densidad de frecuencia: $h_i = \frac{n_i}{a_i}$

Medidas de posición variable cuantitativa continua

- **Ejemplo:** Queremos obtener el peso máximo del 15% de los alumnos que menos pesan, esto es, el $C(0.15)$.
- El intervalo que lo contiene en este ejemplo es $(60-75]$ pues su $N_i > 0.15n = 10.95$

$I_{i-1} - I_i$	n_i	N_i	x_i	a_i
50-60	5	5	55	10
60-75	25	30	67,5	15
75-90	29	59	82,5	15
90-100	14	73	95	10
Sumas	$n=73$			



$$C(0.15) = I_{i-1} + \frac{\alpha n(0.15 \times 73 = 10.95) - N_{i-1}}{n_i} \cdot a_i =$$

$$60 + \frac{10.95 - 5}{25} \cdot 15 =$$

$$60 + 3.57 = 63.57 \text{ kg}$$


• MEDIANA ($n/2$): CUANTILES: Percentiles, Deciles, Cuartiles ...

- **Cálculo para variables continuas:** De igual forma que la mediana pero usamos αn en vez de $n/2$ (equivalentemente α por $1/2$)
- El intervalo que contiene a $C(\alpha)$ será aquel $(I_{i-1}-I_i]$ cuyo $N_i > \alpha n$, o equivalentemente, aquel x_i cuyo $F_i > \alpha$.
- La expresión para el cálculo sería:

$$C(\alpha) = I_{i-1} + \frac{\alpha \cdot n - N_{i-1}}{n_i} a_i$$

- **Ejemplo:** Queremos obtener el peso máximo del 15% de los alumnos que menos pesan, esto es, el $C(0.15)$.
- El intervalo que lo contiene en este ejemplo es $(60-75]$ pues su $N_i > 0.15n = 10.95$

$I_{i-1} - I_i$	n_i	N_i	x_i	a_i
50-60	5	5	55	10
60-75	25	30	67,5	15
75-90	29	59	82,5	15
90-100	14	73	95	10
Sumas	$n=73$			



$$C(0.15) = I_{i-1} + \frac{\alpha n (0.15 \times 73 = 10.95) - N_{i-1}}{n_i} \cdot a_i =$$

$$60 + \frac{10.95 - 5}{25} \cdot 15 =$$

$$60 + 3.57 = 63.57 \text{ kg}$$

Síntesis de datos: medidas descriptivas de posición

Cuantitativas (Además de las medidas anteriores, al manejar números, ahora podemos hacer cálculos)

Media aritmética: dada una muestra de n observaciones numéricas $x_1, \dots, x_n$

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{x_1 + L + x_n}{n};$$

si los datos están agrupados en una tabla de frecuencias:

$$\bar{x} = \frac{\sum_{i=1}^k f_i x_i}{n} = \frac{f_1 x_1 + L + f_k x_k}{n}$$

Ejemplos: a) $\{3, 6, 7, 10, 15\} \rightarrow \bar{x} = (3+6+7+10+15)/5 = 8.2$

b) Edad (años)
n=124

x_i	f_i	$(x_i f_i)$
15	5	15×5=75
16	28	448
17	64	1088
18	18	324
19	6	114
20	3	60

Total $n=124$ $\sum (x_i f_i) = 2109$

$$\bar{x} = 2109 / 124 = 17.0 \text{ años}$$

c) Edad (años)
n=124

	f_i	Marca de clase X_i	$(x_i f_i)$
menos de 21	5	18*	5×18=90
21-25	28	(21+25)/2=23	644
26-30	64	(26+30)/2=28	1792
31-35	18	33	594
36-40	6	38	228
más de 40	3	43*	129

Total 124 3477

$$\bar{x} = 3477 / 124 = 28.0 \text{ años}$$

* En estos intervalos "mal definidos" se usa la misma regla que con los restantes de la tabla

Síntesis de datos: medidas descriptivas de posición

Media ponderada: Debe utilizarse cuando no todas las observaciones tienen la misma *importancia* (= peso o ponderación: w_i)

Dados

x	x_1	$\dots$	x_n
w	w_1	$\dots$	w_n

$$\rightarrow \bar{x}_p = \frac{x_1 w_1 + \dots + x_n w_n}{w_1 + \dots + w_n} = \frac{\sum_{i=1}^n x_i w_i}{\sum_{i=1}^n w_i}$$

Ejemplo:

Nota obtenida (x)	5	7	9
Créditos de la asignatura (w)	3	3	6


$$\rightarrow \bar{x}_p = \frac{5 \times 3 + 7 \times 3 + 9 \times 6}{3 + 3 + 6} = \frac{90}{12} = 7.5 \quad \left(\neq \bar{x} = \frac{5 + 7 + 9}{3} = 7 \right)$$

Observe la similitud entre la **media aritmética** para datos agrupados y la **media ponderada**. Cuando la ponderación (w_i) de cada valor es su frecuencia de aparición (f_i), entonces tenemos la misma expresión

$$\bar{x} = \frac{\sum_{i=1}^k f_i x_i}{n} = \frac{\sum_{i=1}^k f_i x_i}{\sum_{i=1}^k f_i} \xrightarrow[\bar{x} \rightarrow \bar{x}_p]{f_i \rightarrow w_i} \bar{x}_p = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$$

Síntesis de datos: comparativa media y mediana y simetría de la distribución

Mediana vs. Media aritmética



Mediana

Se puede calcular con variables ordinales en adelante

El *número de casos* con valores por debajo de la Me es el mismo que el número de casos con valores por encima de ella

Es **robusta** frente a valores extremos

Es menos frecuente como medida de posición en *inferencia*

Media aritmética




Requiere que los datos sean cuantitativos

La suma de las *distancias a la media* de los valores inferiores a $\bar{x}$ se compensa con la suma de distancias a la media de los valores por encima de ella:

$$-\sum_{x_i < \bar{x}} (x_i - \bar{x}) = \sum_{x_i > \bar{x}} (x_i - \bar{x})$$

Más **sensible** a los valores extremos, especialmente cuando el tamaño de muestra es pequeño (gana robustez al aumentar n)

Es la medida de posición más habitual en *inferencia*



Si la distribución es **simétrica**, $Me \approx \bar{x}$ lo cual permite decir que en esta situación y de forma aproximada, la media viene a dividir a la muestra en dos partes iguales


¿Quiénes son cada caso la media y la mediana?

Si **media=moda=mediana**, la **distribución** es **simétrica**

Ejemplo: al estudiar la fuerza muscular de un paciente usando la **Escala de Robert Lovett & Kendall** de una muestra de $n=300$ pacientes, se obtuvo un valor medio de 4 unidades en la escala. *¿quiere esto decir que, aproximadamente, la mitad de los pacientes tienen un nivel de colesterol por debajo de este valor?* **NO**. Solo si la distribución de la escala es **SIMETRICA** donde media, mediana y moda coinciden

Si **media > mediana**, la **distribución** es **asimétrica** con cola a la derecha (sesgada a la derecha).

Si **media < mediana**, la **distribución** es **asimétrica** con cola a la izquierda (sesgada a la izquierda).



Síntesis de datos: medidas descriptivas de posición no central


Medidas de posición no central para variables ordinales o cuantitativas

Extremos (mínimo y máximo): Pueden estar muy alejados del resto de los datos en cuyo caso deben estudiarse. Para caracterizar la distribución se usa *otro criterio de extremo*: los **percentiles**

Percentiles: el percentil α , P_α , es el valor de la variable que divide a la muestra ordenada en dos partes, dejando por debajo el $\alpha\%$ de las observaciones y por encima el $(1-\alpha)\%$. (generalización del concepto de mediana). Se habla de percentil 1 (P_1), ..., percentil 99 (P_{99}).

$$P_\alpha = x_{\left((n+1) \times \frac{\alpha}{100}\right)}$$

Ejemplo: Cálculo del P_{40} a partir de una tabla de frecuencias



x	fi	Fi	acum
0	72	72	14.4%
1	155	227	45.4%
2	97	324	64.8%
3	81	405	81.0%
4	30	435	87.0%
5	27	462	92.4%
6	20	482	96.4%
más de 6	18	500	100.0%

500

$$\text{Posición del } P_{40} (n = 500) : (500 + 1) \times 0.4 = 200.4 \longrightarrow P_{40} = x_{(200.4)} = 1$$

El 40% de los casos observados tienen una recaída o ninguna. El 60% restante tienen una recaída o más

Síntesis de datos: medidas descriptivas de posición no central

Observaciones respecto a los percentiles:

- Casos particulares: hay percentiles que reciben también otro nombre:
 - *Cuartiles*: $Q_1 = P_{25}$, $Q_2 = P_{50} = Me$, $Q_3 = P_{75}$
 - *Deciles*: $D_1 = P_{10}$, ..., $D_9 = P_{90}$
- Obsérvese que si $\alpha_1 < \alpha_2$ entonces

$$P_{\alpha_1} \leq P_{\alpha_2}$$



Es decir, el P_{20} por ejemplo, no puede ser mayor que el P_{25} (aunque si que podría ser igual)

- Si la muestra es muy pequeña, no tiene sentido hablar de percentiles respecto a ella.
- Además de los cuartiles, se utilizan mucho los percentiles 5 y 95 ¿cómo se interpreta cada uno de ellos?


? ¿Encuentra alguna relación entre los percentiles y la frecuencia relativa acumulada?

Diagramas de caja

Un diagrama de caja es una interesante representación de la distribución de la variable que está basada en los cuartiles




Relación con el histograma




Diagramas con fines comparativos


Síntesis de datos: medidas descriptivas de dispersión



¿Son iguales en estatura los dos grupos?



¿Son “iguales” estas dos distribuciones con la misma media?



¿Qué se puede decir de estas dos distribuciones?


Síntesis de datos: medidas descriptivas de dispersión

Para caracterizar un conjunto de datos, no basta con dar solamente medidas de posición, también es necesario conocer su ***dispersión = heterogeneidad = variabilidad***

Medidas de dispersión (solo variables cuantitativas)

Rango (R) o amplitud (A): $A = x_{\max} - x_{\min}$

Es una medida fácil de calcular, pero muy pobre, ya que solo tiene en cuenta a dos observaciones de toda la muestra (los extremos)




A y B tienen el mismo rango o amplitud

Síntesis de datos: medidas descriptivas de dispersión

¿Cómo se puede definir una buena medida de dispersión que tenga en cuenta a todas las observaciones?

- Es necesario utilizar el concepto de **distancia** de cada observación respecto a un valor de referencia
- La mejor referencia es una medida de posición central: optamos por la media aritmética como referencia
- La idea es calcular todas las distancias de cada observación a la media y hacer la media de dichas distancias:



Ahora la media de las distancias (o distancia media respecto a la media aritmética) será


$$\bar{d} = \frac{\sum d_i}{n} = \frac{\sum (x_i - \bar{x})}{n} = \frac{\sum x_i}{n} - \frac{\sum \bar{x}}{n} = \bar{x} - \frac{n\bar{x}}{n} = 0 \quad \text{¡¡Siempre cero!!}$$

El problema es que debido al carácter central de la media aritmética, las distancias negativas se compensan siempre con las positivas. En la imagen $d_1 < 0$ y $d_2 > 0$.

De hecho, el problema es permitir que haya ¡¡distancias negativas!! (eso no tiene sentido)

Síntesis de datos: medidas descriptivas de dispersión

La estrategia que se usa para impedir que las distancias sean negativas es una muy utilizada en las ciencias en general. Se trata de elevar cada distancia al cuadrado. Esto mantiene la información sobre su magnitud pero evita el problema del signo negativo.



El promedio (de las distancias al cuadrado respecto a la media) entonces es:

$$\frac{\sum d_i^2}{n} = \frac{\sum (x_i - \bar{x})^2}{n} = S^2$$

Por cuestiones que veremos mas adelante, se considera un promedio no respecto al tamaño de muestra n , sino respecto a una cantidad que se denomina grados de libertad y que es $n-1$.

Se define así la

Varianza muestral

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$$

Síntesis de datos: medidas descriptivas de dispersión

Cálculo práctico de la varianza

Si los datos no están agrupados en una tabla de frecuencias

$$s^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - \frac{\left(\sum_{i=1}^n x_i \right)^2}{n} \right)$$

Si los datos están agrupados en una tabla de frecuencias

$$s^2 = \frac{\sum_{i=1}^n f_i (x_i - \bar{x})^2}{n-1} = \frac{1}{n-1} \left(\sum_{i=1}^n f_i x_i^2 - \frac{\left(\sum_{i=1}^n f_i x_i \right)^2}{n} \right)$$

Ejemplos

a) $x_i : \{4, 6, 8, 10\} \rightarrow \bar{x} = 7; s^2 = \frac{1}{3} \left((4^2 + 6^2 + 8^2 + 10^2) - \frac{(4+6+8+10)^2}{4} \right) = 6.667$

b)

x_i	f_i	$x_i f_i$	$x_i^2 f_i$
15	5	75	1125
16	28	448	7168
17	64	1088	18496
18	18	324	5832
19	6	114	2166
20	3	60	1200
Suma	124	2109	35987

$$\bar{x} = \frac{2109}{124} = 17.0$$

$$s^2 = \frac{1}{124-1} \left(35987 - \frac{2109^2}{124} \right) = 0.941$$

Obsérvese que la varianza depende de la media y su valor no puede ser negativo, pero en el caso de que todos sus valores sean iguales podría ser igual a cero.

Síntesis de datos: medidas descriptivas de dispersión

La varianza tiene unidades de medida que son aquellas que tenga la variable pero al cuadrado. Esto supone que si la variable es por ejemplo la estatura en cm (unidad de longitud) su varianza viene dada en cm^2 (¡¡unidad de superficie!!)
Para evitar este problema de dimensionalidad se define la

Desviación típica (o estándar)

$$s = \sqrt{s^2}$$

Esto debe entenderse en el sentido de que la d.t. se obtiene una vez calculada la varianza al considerar su raíz cuadrada

- Es una medida de dispersión que tiene en cuenta a todas las observaciones
- Se expresa en las mismas unidades que la variable
- La desviación típica de forma aislada no dice nada, debe de ir acompañada de la media. Normalmente se expresa

$$\bar{x} \pm s$$

por ejemplo: “...el nivel de colesterol observado en la muestra fue 175.3 ± 12.5 ...”

- Cuando la distribución de la variable es simétrica (mas concretamente *normal**) el intervalo

$$\bar{x} \pm 2s$$


contiene aproximadamente al 95% de las observaciones.

En el ejemplo anterior, aproximadamente el 95% de los casos tienen un nivel de colesterol comprendido en el intervalo (150.5, 200.5) si la distribución del colesterol es simétrica (*normal**)

* Más adelante se verá qué quiere decir exactamente que una distribución sea *normal*

Posición y dispersión sobre el diagrama de frecuencias

Indicar $\bar{x} \pm s$ define muy bien la distribución, especialmente si es **simétrica** (*normal**)



* Más adelante se verá qué quiere decir exactamente que una distribución sea *normal*

Síntesis de datos: medidas descriptivas de dispersión

Otras medidas de dispersión

Coeficiente de variación

$$CV = \frac{s}{\bar{x}} (\times 100\%)$$

- Es una medida de dispersión adimensional (se multiplica por 100 y es un %)
- Expresa la dispersión dada por la desviación típica en términos de la media (estandarización)
- No debe calcularse si la media es inferior a 1
- Permite comparar la variabilidad de muestras con diferente media e incluso con diferentes unidades
- Muy utilizada para expresar la precisión de los aparatos de medida

Rango intercuartílico (RIQ)

$$RIQ = Q_3 - Q_1$$

Es una medida de dispersión basada en percentiles, por tanto

- Se usa cuando la medida de posición considerada es la mediana
- No tiene sentido con muestras de pequeño tamaño
- Debe interpretarse como que en un margen de RIQ unidades (entre Q_1 y Q_3) está el 50% (central) de las observaciones
- Una variación de esta medida es el **rango semi intercuartílico (RSI)** o **desviación cuartil**

$$RSI = \frac{Q_3 - Q_1}{2}$$

4. Medida de dispersión relativa: coeficiente de variación

$$CV = 100 \frac{S}{\bar{X}} \%$$

- Se utiliza para comparar métodos de medida.
- Es una medida que tiene en cuenta a todas las observaciones.
- Es adimensional y no depende de las unidades de medida.
- Se utilizan solamente cuando los datos son positivos.
- Se expresa en %.
- Cuanto menor es el CV, mayor es la precisión del método.
- **Ejemplo:** CV=10% indica que por cada 100 unidades de medida, el método comete un error, medido en desviaciones típicas, de 10.

Síntesis de datos: ejercicio

Ejercicio

Calcule la media, la desviación típica y la mediana de las 7 muestras que aparecen a continuación
¿Puede decirse que las muestras 3 y 6 tienen la misma dispersión?

La media suele presentarse con un decimal más que los valores de la variable y la desviación típica con un decimal más que la media

Muestra

1)	10.2	11.4	11.0	10.2	11.9	11.1	10.8	10.1	10.8	11.1
2)	102	109	107	106	103	103	105	102	104	106
3)	2.9	3.0	3.1	3.5	2.7	2.9	3.1	3.4	2.6	
4)	1.0	1.1	2.6	4.0	0.0	1.3	3.5	-1.0	1.0	1.5
5)	-0.6	-1.6	-1.6	-2.7	0.9	-0.3	-0.6	-2.9	-0.9	-2.2
6)	5.9	6.0	6.1	6.5	5.7	5.9	6.1	6.4	5.6	
7)	0.5030	0.4961	0.5001	0.4961	0.5003	0.5023	0.4972			

Solución

n	Media	s	Me
10	10.86	0.574	10.9
10	104.7	2.31	104.5
9	3.02	0.295	3.0
10	1.50	1.515	1.2
10	-1.25	1.177	-1.25
9	6.02	0.295	6.0
7	0.49930	0.00286	0.5001

La respuesta a la pregunta es que no. La media (dt) en la muestra 3 es 3.02 (0.295) mientras que en la 6 resulta ser 6.02 (0.295). Las desviaciones típicas, aunque numéricamente presentan el mismo valor, no son comparables, ya que ambas muestras tienen diferente media (la de 6 es el doble que la de 3). Si obtenemos los coeficientes de variación resulta que $CV_{(3)} = 9.8\%$ y $CV_{(6)} = 4.9\%$ lo que pone de manifiesto que la dispersión relativa a la media de la muestra 3 es el doble que la de la muestra 6.