

ESTADÍSTICA

Grado en Enfermería


Tema II

Nociones sobre probabilidad, variable aleatoria y muestreo

Pedro Femia Marzo, autor
Miguel Angel Luque Fernandez, actualización
Unidad de Bioestadística – Facultad de Medicina

Universidad de Granada

Esq. 1.4 El proceso estadístico y metodología estadística.



Determinismo y aleatoriedad

Tipos de fenómenos (sucesos)

Fenómeno determinista: es aquel que se puede reproducir siempre que se desee estableciendo unas mismas condiciones de partida: **iguales condiciones → iguales resultados** (determinismo $\longleftrightarrow$ certidumbre); Ej.: Leyes de la FÍSICA (Newton)

Fenómeno aleatorio: es aquel cuya aparición viene condicionada por el azar. No se puede reproducir siempre que se desee estableciendo unas mismas condiciones de partida: **iguales condiciones → resultado incierto** (aleatoriedad $\longleftrightarrow$ incertidumbre). Ej: Probabilidad

Fenómenos en la naturaleza

Fenómenos totalmente deterministas: el determinismo está relacionado con las Teorías (por ejemplo, el *Determinismo Biológico*), pero en la naturaleza el determinismo absoluto es más que cuestionable

Fenómenos totalmente aleatorios: los resultados de los juegos de azar (lanzar una moneda, un dado, ...)

Fenómenos naturales: al observar el mundo físico siempre hay un mayor o menor grado de **aleatoriedad** implícito en las observaciones (el *error de medida* es un primer responsable de esto)

Fenómeno observado = componente determinista + componente aleatorio

Peso = f (talla, sexo,...) (componente determinista) + variabilidad (componente aleatorio)

El Peso de un individuo depende de su talla, sexo, etc...

No todos los hombres que miden 1.80m pesan lo mismo

Modelo estadístico

Un papel fundamental de la **Inferencia Estadística** consiste en “separar” la partes determinista y aleatoria

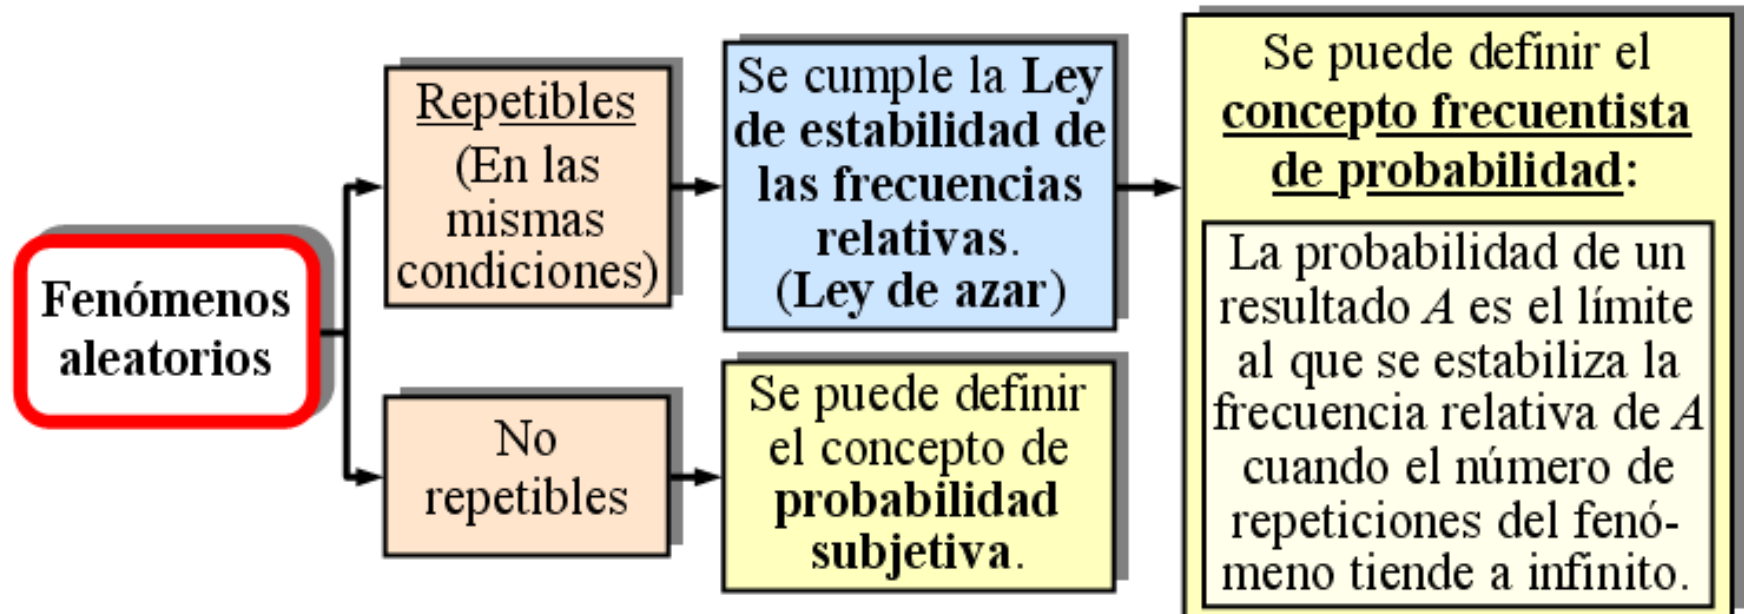
Experimentos determinísticos y aleatorios

Experimento determinístico: es aquel en el que conocidas las condiciones de realización del experimento su resultado está determinado y por tanto es predecible. Al repetir el experimento en las mismas condiciones se conoce el resultado que se va a obtener. Ejemplos: la velocidad con la que un objeto llega al suelo tras lanzarlo de una altura de 1m, presión a la que está sometido un gas que tiene un determinado volumen, etc.

Experimento aleatorio: es el experimento en el que al repetirlo en las mismas condiciones no se sabe el resultado que se va a obtener, y por tanto su resultado es impredecible. Ejemplos: estado de un paciente tras un tratamiento, nivel de glucosa en sangre después de un ejercicio, el peso de una persona al levantarse, lanzamiento de un dado, etc.

Definición de Probabilidad

Esq. 3.1 Fenómenos aleatorios y concepto frecuentista de probabilidad.



La probabilidad es una medida

El estudio de los fenómenos aleatorios requiere cubrir la necesidad de poder **medir con qué frecuencia se presentan** → Concepto de **Probabilidad**

Probabilidad de un suceso A, $P(A)$ = medida de lo frecuente o lo extraño que resulta observar ese suceso A

No hay una definición única del concepto de Probabilidad

La **noción de probabilidad** se presta a *diferentes aproximaciones* y es objeto de particular atención en al ámbito de la *Epistemología*. Esto genera diferentes enfoques:

Basada en la **regla de Laplace**:

Definición **frecuentista**: sucesos **EQUIPROBABLES**

Definición axiomática (de Kolmogorov, es la más formal)

Definición subjetiva de probabilidad): **Teorema de Bayes**

Regla de Laplace

$$P(A) = \frac{\text{nº de casos favorables a A}}{\text{nº de casos posibles}}$$

Independientemente del enfoque, la **probabilidad de un suceso es un número positivo comprendido entre 0 y 1** (que se puede multiplicar por cien y darlo como porcentaje)

Que ocurra A es:

$$\left\{ \begin{array}{l} \text{Posible, si } P(A) > 0 \\ \text{Imposible, si } P(A) = 0 \end{array} \right\} \left\{ \begin{array}{l} \text{Seguro, si } P(A) = 1 \\ \text{Probable, si } 0 < P(A) < 1 \end{array} \right\} \left\{ \begin{array}{l} \text{si } P(A) \geq 1 \quad A \text{ es frecuente} \\ \text{si } P(A) \leq 0 \quad A \text{ es raro} \end{array} \right.$$

Es importante tener presente que la **probabilidad es una medida** (como si habláramos de la longitud o del peso) de lo **frecuente** o **infrecuente** (=raro) que resultar observar un determinado **suceso aleatorio**

Definición Frecuentista de la Probabilidad

Si en un experimento aleatorio se define un suceso A como cualquier resultado del experimento, entonces la probabilidad de que ocurra el suceso A es el límite de la frecuencia relativa con la que aparece dicho suceso cuando el número de repeticiones del experimento aleatorio tiende a infinito. Es decir,

$$P(A) = \lim_{n \rightarrow \infty} h_n(A)$$

Definición axiomática de la Probabilidad

La probabilidad de que ocurra un suceso A en un experimento aleatorio es un valor que verifica una serie de axiomas (propiedades), entre ellos:

a). $0 \leq P(A) \leq 1$.


b). Si $P(A) = 0$, entonces el suceso A no ocurre nunca y se denomina suceso imposible.

c). Si $P(A) = 1$, entonces el suceso A ocurre siempre y se denomina suceso seguro.


Perspectiva frecuencista: la Ley de Azar

Cada prueba es la observación de un suceso binario (resultado = Acierto/fallo)


$n=10$ pruebas



Proporción (frecuencia relativa) de aciertos: h_A




Al repetir un experimento un número n suficientemente grande de veces (se dice que $n \rightarrow \infty$) la frecuencia relativa con la que aparece cada posible modalidad del resultado tiende a **estabilizarse** en un valor (*Ley de los grandes números*)



Perspectiva frecuencista: la Ley de Azar

Definición frecuencista de probabilidad: La **probabilidad** con la que se presenta un fenómeno es el valor al que se aproxima la **frecuencia relativa** con la que aparece dicho fenómeno cuando el **número de realizaciones** de la experiencia que permite observarlo es “**suficientemente**” grande



$$h_A = \frac{\text{nº de veces que aparece la modalidad A (casos favorables a A)}}{\text{nº total de pruebas realizadas (casos posibles)}} \xrightarrow{n \rightarrow \infty} P(A)$$

- Formalmente se indica $P(A) = \lim_{n \rightarrow \infty} h_A$
- Obsérvese que bajo esta definición $0 \leq P(A) \leq 1$

$$\left\{ \begin{array}{ll} P(A) \leftarrow h_A = 0 & \text{Si nunca se observa A} \\ P(A) \leftarrow h_A = 1 & \text{Si siempre se observa A} \end{array} \right.$$
- Por otra parte, si un fenómeno puede aparecer en forma de solo una de k modalidades posibles: $A_1, A_2, \dots, A_k$ entonces

$$P(A_1) + P(A_2) + \dots + P(A_k) = \sum P(A_i) = 1 \quad (\text{Probabilidad total})$$

Cálculo de Probabilidades: Probabilidad

Definición axiomática de Probabilidad (Kolmogorov)

Ejemplo 1. En las carreras de caballos que se celebran en el hipódromo de Sevilla, se sabe que el caballo favorito, A, tiene el doble de probabilidad de ganar que B y B tiene el doble que C. Calcular las probabilidades de que gane cada uno.

Sucesos:

A: Gana el caballo A

B: Gana el caballo B

C: Gana el caballo C

Espacio muestral:

$$E = \{A, B, C\}$$

$$P(C) = k$$

$$P(B) = 2k$$

$$P(A) = 4k$$

El espacio muestral **NO** es
equiprobable

$$P[A \cup B \cup C] = P[E] = 1$$

$$P[A] + P[B] + P[C] = 1$$

$$k + 2k + 4k = 1$$

$$7k = 1$$

$$k = \frac{1}{7}$$

$$P(C) = 1/7$$

$$P(B) = 2/7$$

$$P(A) = 4/7$$

Cálculo de Probabilidades: Probabilidad

Propiedades de la Probabilidad


$$1. \quad P(\overline{A}) = 1 - P(A), \quad \forall A \in \beta$$

$$2. \quad P(\emptyset) = 0$$


$$3. \quad \forall A, B \in \beta, A \subset B \Rightarrow P(A) \leq P(B)$$

$$4. \quad \forall A \in \beta, 0 \leq P(A) \leq 1$$

$$5. \quad \forall A, B \in \beta, P(A - B) = P(A) - P(A \cap B)$$



$$6. \quad \forall A, B \in \beta, P(A \cup B) = P(A) + P(B) - P(A \cap B)$$



$$7. \quad \forall A, B, C \in \beta,$$

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$$

Cálculo de Probabilidades: Probabilidad

Propiedades de la Probabilidad

Ejemplo 2. En una población el 4% de las personas son daltónicas, el 18% hipertensas y el 0.5% **daltónicas e hipertensas**. ¿Cuál es la probabilidad de que una persona sea **daltónica ó hipertensa**?

Sucesos:

A: “Ser daltónico”

B: “Ser hipertenso”

$$P(A) = 0.04$$

$$P(B) = 0.18$$

$$P[A \cap B] = 0.005$$

$$P[A \cup B] = P[A] + P[B] - P[A \cap B] = 0.04 + 0.18 - 0.005 = 0.215$$

Ejemplo 3. En el lanzamiento un dado, sea A el suceso obtener un número impar y B obtener un número mayor que 3. Determinar la Probabilidad de obtener un número impar que no sea mayor que 3

Sucesos:


A: “Sacar impar (1, 3 ó 5)”

B: “Sacar mayor que 3 (4, 5 ó 6)”

C= “Sacar número impar no mayor que 3 (1 ó 3)”

$$C = A \cap \bar{B} = A - B$$

$$P[A \cap \bar{B}] = P[A - B] = P[A] - P[A \cap B] = \frac{3}{6} - \frac{1}{6} = \frac{2}{6}$$



Concepto de **variable aleatoria** (VA)

- Por **variable** entendemos aquí la acepción matemática, es decir, se trata de un **valor numérico** que puede ser cambiante de una observación a otra
Como los valores numéricos pueden ser discretos (=recuentos) o continuos (=medidas) hablaremos de **variables discretas** y de **variables continuas**
- Por **aleatoria** entendemos que dicho valor numérico **depende en todo o en parte del azar**
- Entonces definir una **variable aleatoria** consiste en asignar un **valor numérico** al resultado de un **experimento aleatorio**

Hablaremos de

- Variable aleatoria **discreta** (VAD) ← recuentos cuyo valor está afectado por el azar (ej: nº de hijos,...)
- Variable aleatoria **continua** (VAC) ← medidas cuyo valor está afectado por el azar (ej: peso,...)
- **Concepto de categorización de una VA:** Los **modelos estadísticos** (o matemáticos en general) solo pueden desarrollarse con valores numéricos (no con categorías nominales), por lo tanto, la forma de estudiar los **datos de tipo nominal** es transformarlos en variables discretas, y esto se hace **contando** cuantas veces aparece cada categoría (es decir, su frecuencia)
Por ejemplo: Para estudiar la distribución por sexos (sexo=dato de **tipo nominal**) de los afectados por una lesión medular se estudia el **número de hombres** (o equivalentemente el número de mujeres) que están afectados por dicha lesión, obteniendo así una **variable aleatoria discreta**.
- Indicar qué valores puede tomar la VA y la probabilidad con que toma cada uno de ellos supone indicar la **distribución de probabilidad** de dicha variable

Vamos a profundizar en el concepto de modelo de **distribución de probabilidad** de variables aleatorias estudiando algunos patrones concretos (=modelos): **Normal** (para VAC), **Binomial** y **Poisson** (para VAD)

Definición de Variable Aleatoria

Cuando los resultados de un experimento aleatorio son numéricos (o se pueden convertir en números), se dice que el resultado es una variable aleatoria (v.a.), porque sus valores numéricos varían al azar. Por ejemplo, la altura y el peso de una persona, el número de sesiones de fisioterapia tras una lesión, etc. Tipos de variables aleatorias:

a). Discretas: son aquellas v.a. que toman valores aislados, por ejemplo 0, 1, 2,... Suelen hacer referencia a experimentos en los que se cuenta el número de veces que ocurre algo, por ejemplo el número de sesiones de fisioterapia tras una lesión. También se puede definir una v.a. discreta cuando el resultado de un experimento es categórico, por ejemplo si se estudia el estado de un paciente después de un tratamiento, entonces se puede definir la v.a. discreta como “peor” (= 0), “igual” (= 1) y “mejor” (= 2).


b). Continuas: son aquellas v.a. que toman valores en un intervalo de posibles valores. Por ejemplo, el peso de una persona adulta sana será un valor entre (por ejemplo) 50 y 100 kg.

Histogramas vivientes

Distribución de la estatura de 175 hombres reclutados por el ejército inglés a finales del siglo XIX

Tomado de Blakeslee & Hered (1914)
por Ayala & Kiger (1984) *Modern Genetics*

Ambas imágenes representan la **distribución de la estatura** de un colectivo diferente en épocas diferentes. (A la izda. están los más bajos y a la dcha los individuos más altos)



¿Tienen algo en común estas dos **distribuciones de frecuencias** de la estatura?

¿Qué aspecto puede esperarse de la distribución si se hiciera con los compañeros de clase?





Solución:



Qué es un modelo de distribución de probabilidad


Consideremos cuatro muestras de una VAC (como la *estatura* o el *nivel de colesterol*)

¿Tienen algo en común estas distribuciones de frecuencias correspondientes a cuatro **muestras aleatorias** tomadas de la misma población?







¿Cómo es el **patrón poblacional** que genera estos datos?

¿Corresponden a un mismo **modelo**



de distribución de la variable?



¿Qué es un **modelo** de distribución de probabilidad

1. ¿Qué ocurre con la forma de la distribución si cada vez observamos más datos?


$n=25$

$n=100$


$n=250$

$n=1000$


2. Conforme aumentamos el número de observaciones es posible considerar cada vez **más intervalos más estrechos**.



3. La cuestión es si en el **límite** (muchos intervalos, muy estrechos) se perfila siempre **un mismo patrón** (suave) de la distribución



4. ¿Es posible establecer un **modelo matemático** $f(x)$ (una expresión matemática manejable) que represente bien la forma como se **distribuye** la VA en la **población**?



Si existe $f(x)$, entonces dicho **modelo caracterizará** a la **distribución de toda la población** y resulta una **herramienta valiosísima** para hacer **inferencia**

Qué es un modelo de distribución de probabilidad

Utilidad de los modelos de distribución de probabilidad

- Los modelos caracterizan –cuando son correctos– el comportamiento de la VA estudiada en la población
- Un modelo de distribución de probabilidad permite determinar la probabilidad de que la VA estudiada tome determinados valores.

Por ejemplo: $P(\text{talla} < 170 \text{ cm})$; $P(180 \leq \text{nivel de colesterol} \leq 210)$,
 $P(\text{nº de seropositivos al observar a 300 individuos sea} > 2)$, etc.



Caracterización de los modelos de distribución de probabilidad

- Un modelo de distribución de probabilidad será una expresión matemática en la que intervendrá la VA X que está siendo caracterizada y unos valores constantes que son **los parámetros del modelo**.
- Cuando un modelo es adecuado para representar la distribución de una población, sus parámetros suelen tener un **significado físico** en relación a dicha población.

Tipos de modelos de distribución de probabilidad

- Modelos de distribución para VAC: el modelo fundamental es el **modelo de distribución normal**
- Modelos de distribución para VAD: son de interés los modelos **Binomial** y de **Poisson**

Además de los indicados hay muchos más modelos que sirven para caracterizar fenómenos concretos (distribución uniforme, exponencial,...)



Veremos algunos modelos que se dan en llamar **distribuciones en el muestreo** y que son herramientas (más abstractas) para la *inferencia*, como son las distribuciones **t-student**, χ^2 , **F de Snédecor**, etc... que usaremos más adelante en este curso.

Variable aleatoria discreta: función de probabilidad

La **función de probabilidad** de una v.a. discreta es una función que asigna a cada valor de la variable la probabilidad con la que toma ese valor. Para que una v.a. discreta esté perfectamente determinada es necesario conocer los valores que puede tomar y sus probabilidades. Ejemplos:

Cuadro 3.1 Ejemplos de variables aleatorias discretas.

Ej. 3.1 $X \equiv$ Número de resultados + en 3 pruebas clínicas realizadas, de forma independiente, en pacientes con una patología (cada prueba da + en 3 de cada 4 de estos pacientes).

X	0	1	2	3
$P(X)$	1/64	9/64	27/64	27/64

Ej. 3.2 $X \equiv$ Número de meses de terapia especializada aplicada en pacientes con un determinado tipo de traumatismo.

X	0	1	2	3	≥ 4
$P(X)$	0,40	0,22	0,17	0,11	0,10

$$P(X = r) = \binom{n}{r} p^r (1-p)^{n-r}, \quad r = 0, 1, 2, \dots, n$$

Cuadro 3.2 Distribución de frecuencias y distribución de probabilidad.**Tabla 3.1.** Distribución de frecuencias de X en una **muestra** de 200 pacientes.

X	$f(X)$	$h(X)$
0	82	0,41
1	46	0,23
2	32	0,16
3	20	0,10
≥ 4	20	0,10
Total	200	1

Tabla 3.2. Distribución de probabilidad de X en una **población**.

X	0	1	2	3	≥ 4
$P(X)$	0,40	0,22	0,17	0,11	0,10

$X \equiv$ Número de meses de terapia especializada aplicada en pacientes con un determinado tipo de traumatismo.

$f(X) \equiv$ Frecuencia absoluta de X .

$h(X) \equiv$ Frecuencia relativa de X .

$P(X) \equiv$ Probabilidad de X .

Cuadro 3.3 Ejemplos de modelos de probabilidad con categorías.**Ej. 3.3**

Modelo de probabilidad para el sexo en individuos que reciben un tratamiento específico de kinesioterapia en una población.

Sexo	Varón	Hembra
Probabilidad	0,4	0,6


Ej. 3.4

Modelo de probabilidad para el nivel de calidad de las salas de fisioterapia de Atención Primaria en una población.


Nivel de calidad	Buena	Satisfactoria	Deficiente	Mala
Probabilidad	0,30	0,40	0,20	0,10

Variable aleatoria continua: función de densidad

La función de densidad, representada como $f(x)$, caracteriza a una v.a. continua y es una función matemática que describe el comportamiento de la variable a medio o largo plazo. La función de densidad permite calcular probabilidades. Gráficamente:




Cuando el tamaño muestral n es suficientemente grande, el histograma perfila una curva: la función de densidad $f(x)$. La función de densidad tiene una expresión matemática, dando lugar a un modelo teórico de distribución de probabilidad de una variable aleatoria continua. Ejemplo:



$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right\}$$

El modelo de distribución **normal**



Cuando el **modelo de distribución Normal** se utiliza para representar la **distribución de probabilidad** de una población (en términos de la variable aleatoria X), los **parámetros** del modelo tienen una relación directa con parámetros descriptivos de tal población:

$\mu \rightarrow$ Media* de la variable aleatoria X

$\sigma \rightarrow$ Desviación típica de X


$\sigma^2 \rightarrow$ Varianza de X

Se indica: $X \rightarrow N(\mu; \sigma)$


$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\}$$

$f(x)$ es la **función de densidad** de la **distribución normal** o **gaussiana** (= Campana de Gauss)

El **modelo Normal** contempla 2 parámetros:



La probabilidad asociada a dicho modelo es **un área bajo la curva** definida por el mismo



* Es frecuente hablar también en términos de **Esperanza Matemática** de X

Modelo de distribución Normal


El **cálculo de probabilidades** = **cálculo de áreas** bajo la curva $f(x)$ se hace mediante **cálculo integral**, por tanto, la probabilidad de que la variable se encuentre entre dos valores concretos x_a y x_b viene dada por:

$$P(x_a \leq x \leq x_b) = \int_{x_a}^{x_b} f(x) dx$$

¡¡ **Difícil** !!

Para facilitar esto (sin resolver integrales) se utilizan las **tablas de la distribución normal tipificada**

Algunas áreas de especial interés son (de forma aproximada):



Tipificación


Tipificar una observación es una forma de **estandarizarla** en relación a un **grupo de referencia**

Si $X \rightarrow N(\mu; \sigma)$ entonces $Z = \frac{X - \mu}{\sigma}$ se dice que es la **tipificación de X** y verifica

$$Z \rightarrow N(0; 1) \quad \begin{cases} \mu_Z = 0 \\ \sigma_Z = 1 \end{cases}$$

Interés de la tipificación:

- Permite requerir solamente una tabla de la distribución normal, la de la distribución **normal estándar** o $N(0,1)$
- **Estandarizar** las observaciones eliminando sus dimensiones y de acuerdo a un grupo de referencia, permitiendo localizar a la observación en el grupo (análogo a lo que hacen los **percentiles**) y comparar con valores tipificados de otras variables



Distribución Normal típica o estándar

La v.a. normal típica o estándar tiene una media igual a 0 y una desviación típica (y varianza) igual a 1. Se representa como z , esto es

$$z \rightarrow N(0, 1)$$

Una v.a. Normal de media μ y desviación típica σ se puede transformar en una v.a. Normal típica ($\mu = 0, \sigma = 1$) mediante una transformación denominada tipificación. La tipificación de una v.a. consiste en

$$z = \frac{x - \mu}{\sigma}$$

La v.a. Normal tipificada está tabulada:

La tipificación se puede realizar para cualquier variable aleatoria (continua o discreta) que tenga una media μ y desviación típica σ . También se puede realizar con valores muestrales, tomando $\bar{x}$ y s en lugar de μ y σ .

Ejemplo. Si la estatura de los españoles (x) sigue una distribución Normal, $x \rightarrow N(170, 10)$, ¿entre qué estaturas está el 95% de los españoles?

$$1 - \alpha = 0.95 \Rightarrow \alpha = 0.05 \Rightarrow z_{\alpha} = 1.96$$

$$x \in \mu \pm z_{\alpha} \sigma \Rightarrow x \in 170 \pm 1.96 \times 10 \Rightarrow \text{de } 150.4 \text{ a } 189.6$$

La tipificación se utiliza para dar valores normales variables (por ejemplo, estaturas, glucosa, colesterol, presión, ...). También se utiliza para comparar variables que no son comparables, pues una variable tipificada no tiene dimensiones, por ejemplo: Supongamos que el peso (variable p) sigue una distribución Normal $p \rightarrow N(69, 4)$ y la estatura (e) sigue una distribución Normal $e \rightarrow N(170, 6)$; si un individuo pesa 72 kg y mide 173 cm, ¿es más pesado que alto?

$$z_p = \frac{72 - 69}{4} = 0,75 \quad , \quad z_e = \frac{173 - 170}{6} = 0,50$$

Como $z_p = 0,75 > z_e = 0,50$, el individuo es más pesado que alto.

Dos distribuciones discretas de especial relevancia:

Distribución **Binomial**

- Distribución asociada a las **proporciones**

Ejemplo de uso:

Si la prevalencia del síndrome metabólico (SM) en diabéticos es del 52.4% ¿qué número de afectados del por el SM se espera encontrar al observar una muestra de 200 individuos diabéticos? ¿Cuál es la probabilidad de encontrar en dicha muestra más afectados por el SM que los esperados?

Distribución de **Poisson**

- Distribución asociada a los **recuentos** por unidad de tiempo, volumen, área,...

Ejemplo de uso

Se viene observando que por término medio hay 3 lesiones de rodilla por semana durante la temporada de esquí en Sierra Nevada. ¿Cuál es la probabilidad de que el número de lesiones de rodilla en una semana de la temporada sea superior a la media observada?

Distribución Binomial

Definición

Consideramos la presencia de una característica A en una población de tamaño N individuos (se trata entonces de una variable binaria o dicotómica con modalidades presente/ausente respecto a A). En ella una proporción del $p \times 100\%$ presentan la característica A y el resto, el $1-p = q \times 100\%$ no la presentan. Si de ella tomamos una muestra de tamaño n , y anotamos el número de individuos de la muestra que presentan la característica A, entonces la VA discreta X es **Binomial** siempre que se cumpla una de estas dos condiciones:

- $N \rightarrow \infty$ Es decir, la población es suficientemente grande
- $N > 40$ y n/N (fracción de muestreo) $\leq 0,10$. Es decir, la población no es tan grande pero la muestra es de tamaño despreciable respecto a ella

Se indica $X \rightarrow B(n, p)$

Parámetros: la distribución tiene dos parámetros

n : el número de casos observados o de pruebas realizadas

p : la proporción de éxitos en la población


Valor esperado (media) y varianza de X

Valor esperado*: np

Varianza: npq

* Se habla de **esperanza matemática**

Modelo Binomial



X = nº de observaciones en la muestra con A presente

$$\Downarrow \\ X \rightarrow B(n, p)$$

Función de probabilidad de X

$$P(X = x) = \binom{n}{x} p^x q^{n-x}, \quad x=0,1,2,\dots,n$$

Distribución Binomial. Ejemplo

¡¡No se exigen estos cálculos. Se trata de ver solo el razonamiento!!

complemento

Según los datos de la Encuesta Nacional de Salud de 2012, el 21.7% de la población española de 15 a 24 años fuma diariamente (independientemente del sexo). Se dispone de una muestra de $n=15$ personas de tal edad. Observe que:

$$X = \text{número de fumadores}; \quad X \rightarrow B(15; 0.217) \rightarrow P(X = x) = \binom{15}{x} 0.217^x (1 - 0.217)^{15-x}; \quad x = 0, 1, 2, \dots, 15$$

Número esperado de fumadores en la muestra: $np = 15 \times 0.217 = 3.25$ (aproximadamente tres)

$$\text{Probabilidad de no encontrar ninguno: } P(X = 0) = \binom{15}{0} 0.217^0 (1 - 0.217)^{15} = 0.025 \quad (2.5\%)$$

Probabilidad de encontrar **alguno**:

$$P(X > 0) = 1 - P(X = 0) = 1 - 0.025 = 0.974 \quad (97.4\%)$$

Probabilidad de encontrar **2 o 3**: $P(X = 2) + P(X = 3) =$


$$\binom{15}{2} 0.217^2 (1 - 0.217)^{15-2} + \binom{15}{3} 0.217^3 (1 - 0.217)^{15-3} =$$

$$0.206 + 0.247 = 0.452 \quad (45.2\%)$$

Probabilidad de encontrar entre cero y 15 fumadores = 1
(=100%) ¿por qué?

Diagrama de probabilidad de la $B(15, 0.217)$

$P(X = x)$



Distribución de Poisson

Definición

Si X es una VAD que representa alguno de los siguientes recuentos

- El número de sucesos que ocurren independientemente y de forma no simultánea en el tiempo
- El número de partículas distribuidas al azar en una gran cantidad de medio
- El número de casos con una **rara característica** A cuando se observa un número grande de sujetos (= **ley de los sucesos raros**, una binomial con p pequeño, menor a 0.05, y n grande, mayor a 20)

entonces X tiene una distribución de Poisson

Se indica $X \rightarrow P(\lambda)$

Parámetros: la distribución tiene un solo parámetro

λ : el número medio de ocurrencias por unidad de tiempo, volumen, etc.

Valor esperado (media) y varianza de X

Valor esperado*: λ	}	En la distribución de Poisson se da la circunstancia particular de que ¡la media y la varianza de la VA coinciden!
Varianza: λ		

Modelo de Poisson



$X = \text{nº de sucesos independientes que ocurren por unidad de tiempo, área, volumen, ...}$



$X \rightarrow P(\lambda)$

Función de probabilidad de X

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!} \quad x=0,1,2,3,\dots$$

Distribución de Poisson. Ejemplo

¡¡No se exigen estos cálculos. Se trata de ver solo el razonamiento!!

complemento

Por término medio se registran en España 1.5 lesiones medulares al día.

Si asumimos que el número de lesiones medulares al día tiene es una VAD que se ajusta a una distribución de Poisson con parámetro $\lambda=1.5$, observe que:

$$X = \text{número de lesiones/día} \quad X \rightarrow P(1.5) \rightarrow P(X = x) = \frac{e^{-1.5} 1.5^x}{x!}; \quad x = 0, 1, 2, \dots$$

Número esperado de lesiones en un día cualquiera: $\lambda = 1.5$ (entre una y dos)

Probabilidad de que un día no se observe **ninguna** lesión: $P(X = 0) = \frac{e^{-1.5} 1.5^0}{0!} = 0.223 \quad (22.3\%)$

Probabilidad de que un día se observe **alguna** lesión:


$$P(X > 0) = 1 - P(X = 0) = 1 - 0.223 = 0.777 \quad (77.7\%)$$

Probabilidad de observar **2 o 3**: $P(X = 2) + P(X = 3) =$


$$\frac{e^{-1.5} 1.5^2}{2!} + \frac{e^{-1.5} 1.5^3}{3!} = 0.251 + 0.125 = 0.376 \quad (37.6\%)$$

Probabilidad de encontrar cero o más lesiones = 1
(=100%) ¿por qué?

Diagrama de probabilidad de la $P(1.5)$



Estudiamos una
Variable Aleatoria X
Por ejemplo, el nivel de
colesterol




(1) Las muestras se eligen **al azar**
(las K muestras tienen la misma
probabilidad de aparecer)

(2) Todas las **medidas descriptivas**
son **variables aleatorias** (además
continuas)

Muestra	tamaño	media
1	n	$\bar{X}_1$
2	n	$\bar{X}_2$
$\vdots$	$\vdots$	$\vdots$
K	n	$\bar{X}_K$

(3) ¿Se puede decir algo de la
distribución que tienen las **medias**
muestrales?



Teorema del Límite Central (TLC)

IMPORTANTE


- Resultado de importancia fundamental en Inferencia Estadística
- Justifica por qué la campana de Gauss se suele llamar distribución “**normal**” (en relación a su abundancia)
- En esencia se trata de lo siguiente:

1. Si una variable aleatoria surge como la **suma** de variables aleatorias **independientes** de magnitud similar **con distribución normal** entonces el resultado también tiene **distribución normal**
2. Si una variable aleatoria surge como la **suma** de variables aleatorias **independientes** de magnitud similar con **distribución desconocida** entonces el resultado tiene **distribución aproximadamente normal** siempre que haya un número de sumandos suficientemente grande (se considera “suficiente” a partir de 60)


En la naturaleza muchas variables toman valores que son la suma de muchos factores

- Los errores de medida son suma de muchos factores, se consideran normales
- Las variables fisiológicas (en individuos sanos) toman valores que son fruto de la suma de muchos factores (herencia, dieta, modo de vida,...), se suele considerar que estas variables tienen distribución normal

1



2



Teorema del límite central


- La **media muestral** es una variable aleatoria continua que se obtiene como la suma de n valores de magnitud similar

$$\bar{X} = \frac{\sum x_i}{n}$$

Entonces:


- Si la variable es normal, la media también.
¿Con qué parámetros?

$$X \rightarrow N(\mu; \sigma) \Rightarrow \bar{X} \rightarrow N\left(\mu; \frac{\sigma}{\sqrt{n}}\right)$$



- La media de las medias, es también la media poblacional, **la posición no cambia**
 - La **dispersión** de la media se reduce en la medida en que el tamaño de muestra aumenta; la media gana **robustez**, ahora estamos viendo cómo lo hace
- Si la variable no tiene distribución normal, la media muestral tiene distribución aproximadamente normal cuando el tamaño muestral (n) es *suficientemente grande* (mayor a 60).

$$X \rightarrow ?? \Rightarrow \bar{X} \xrightarrow[n \geq 60]{\text{aprox.}} N\left(\mu; \frac{\sigma}{\sqrt{n}}\right)$$



Este resultado es muy importante. En inferencia, lo que más vamos a usar es la media. Si se puede considerar que la distribución de la media se adapta a un modelo normal, entonces se dispone de una herramienta muy potente. En breve **toda inferencia basada en la normalidad es fácil de realizar**

Población: Conjunto de *individuos* -o más genéricamente *unidades*- sobre los que se desea hacer alguna afirmación (el objeto de nuestro estudio).

¿Cómo definir las?

La población objetivo del estudio debe **definirse** mediante

- Condiciones de **inclusión**: qué requisitos se deben cumplir los sujetos para pertenecer a la misma Ej. *Personas de ambos sexos con edad superior a 80 años*
- Condiciones de **exclusión**: Características que no se deben cumplir. Ej. *Padecer algún tipo de traumatismo discapacitante*


Las poblaciones, en su totalidad, son inaccesibles

¿Cómo estudiarlas?

El concepto de población implica la connotación de **gran tamaño** lo que supone un gran esfuerzo estudiarlas en su totalidad (imposibilidad física y económica)

En general, las poblaciones son **dinámicas**:

- Hay individuos que se incorporan (inmigración, nacimiento)
- Hay individuos que desaparecen de ella (emigración, muerte)
- Hay individuos que cambian su estatus (pueden dejar de verificar las condiciones de inclusión o exclusión)



Las poblaciones, en su totalidad, son difícilmente descriptibles

¿Cómo caracterizarlas?

Las poblaciones suelen caracterizarse en términos de determinados **parámetros**, en función de ellos será posible responder a determinadas preguntas

Ejemplo

Pregunta

¿Es la población infantil más obesa?

¿Ha disminuido el número de seropositivos del VIH?

Parámetro de interés

← **Media** del IMC


← **Prevalencia** del VIH

Inferencia

Ante la imposibilidad de estudiar a toda la población, se debe considerar un subconjunto de ella: una **muestra**

Para generalizar (extrapolar) a toda la población la información suministrada por la muestra obtenida a partir de ella es necesaria una forma de **razonamiento inductivo**: la **inferencia estadística**

El cálculo de probabilidades y los modelos de distribución de probabilidad constituyen una herramienta fundamental para poder realizar la inferencia. A menudo hay que establecer determinados **supuestos** acerca de cómo se distribuye la variable estudiada en la población



La muestra debe estar bien escogida, debe **representar** a toda la **población objetivo** de forma que sea una imagen lo más fiel posible de la misma.

El **tamaño de la muestra NO** garantiza su representatividad. Lo que si es cierto es que una muestra mayor tendrá más contenido informativo que una muestra pequeña. Un aspecto fundamental en lo que sigue es conocer qué aspectos están condicionados por el tamaño muestral.

Formas de obtener los datos de la población

Dos formas de obtener la información

- **Muestreo:** Se **observan** individuos de la población sin que el investigador establezca de antemano valores de ninguna variable.
 - Un estudio cuyos datos se obtienen por muestreo es un **estudio observacional**
 - Los estudios observacionales solo permiten hablar de **asociación** entre variables, nunca de relaciones **causales**
Ejemplo: Se podría decir que la prevalencia del cáncer de pulmón está asociada con el consumo de tabaco, pero no que fumar provoca cáncer
- **Experimentación:** el investigador fija de antemano valores de una o varias variables (=variables **explicativas** o **tratamientos** o **factores**) y observa el nivel de otras (=variables **respuesta**).
 - La asignación de individuos a cada nivel del factor se debe hacer de forma **aleatorizada**
 - Los **ensayos clínicos** son estudios de este tipo: un grupo de individuos recibe un tratamiento y otro grupo actúa como **grupo control**
 - La forma de planificar la experiencia es el **Diseño experimental**. (toda una disciplina estadística)

Sesgo = Tendencia de la muestra a diferir de la población de la que se extrae

Algunos sesgos peligrosos

- **Sesgo de selección.** Debido a la exclusión sistemática de una parte de la población
- **Sesgo de medida o de respuesta.** Uso de métodos de medida inadecuados (ej. Cuestionario no válido)
- **Sesgo por falta de respuesta.** Debido a la falta de información de individuos que fueron seleccionados para pertenecer a la muestra

Resume VA

En todos los problemas de Estadística que se van a estudiar en los siguientes temas, se pretenderá conocer el valor de los parámetros de una v.a. o de varias v.a. Por tanto, todos los problemas serán expresados en función de una v.a. (o de varias v.a.) y de los parámetros que las caracterizan. Así:

- Si tenemos una v.a. X que sigue una distribución Normal, está se caracterizará por μ y σ , que son parámetros cuyos valores son desconocidos (pues hacen referencia a toda la población objeto de estudio). El objetivo será intentar conocer (estimar) los valores de μ y σ a partir de los datos observados en una muestra.
- Si tenemos una v.a. X Binomial, está se caracterizará por n y p , donde n es conocido (tamaño de la muestra) y p es un parámetro cuyo valor es desconocido (pues hace referencia a toda la población objeto de estudio). El objetivo será intentar conocer (estimar) el valor de p a partir de los datos observados en la muestra de tamaño n .

Definición de **muestra aleatoria**

Para que la muestra sea **representativa** de la población objeto de estudio, es preciso que sea extraída de ella de modo que:

- Todos los individuos de la población tengan la misma probabilidad de ser seleccionados e incluidos en la muestra (**igual probabilidad**).
- La selección de un individuo no influya para nada en la selección o no de otro individuo cualquiera (**independencia**)

Una muestra elegida así se dice que es una **muestra aleatoria simple**

Forma de escoger una muestra aleatoria

1. Tener determinada la población objeto del estudio. (con condiciones explícitas de *inclusión* y de *exclusión*).
2. Tener identificados a cada uno de los individuos de esa población y asignado a cada uno de ellos un número.
3. Elegir, por un **mecanismo que represente suficientemente bien al azar**, una muestra de los individuos de la población.

La reproducción del azar se hace mediante la generación de **números aleatorios**

- Tablas de números aleatorios
- Generación de números aleatorios por ordenador o calculadora de bolsillo

Las tablas de números aleatorios.

Una tabla de números aleatorios es en una lista de dígitos del 0 al 9 con las siguientes características:

1. Cada dígito tiene la misma probabilidad de aparecer en cada posición de la tabla (**igual probabilidad**)
2. La presencia o ausencia de un dígito dado en determinada posición no condiciona para nada a los dígitos que le siguen o que le preceden (**independencia**)

Tabla de números aleatorios

Selección aleatoria de $n=10$ individuos de una población de tamaño $N=800$

Tabla de números aleatorios				
✓ 034	7437386	3696473661	4698637162	3326168045
977	4246762	4281145720	4253323732	2707360751
✓ 167	6622766	5650267107	3290797853	1355385859
✓ 125	6859926	9696682731	0503729315	5712101421
✓ 555	9563564	3854824622	3162430990	0618443253
✓ 162	2779439	4954435482	1737932378	8735209643
844	2175331	5724550688	7704744767	2176335025
✓ 630	1637859	1695556719	9810507175	1286735807
✓ 332	1123429	7864560782	5242074438	1551001342
✓ 576	0863244	0947279654	4917460962	9052847727
✓ 181	8079246	4417165809	7983861962	0676500310
✓ 266	2389775	8416074499	8311463224	2014858845
234	2406474	8297777781	0745321408	3298940772
523	6281995	5092261197	0056763138	8022025353
378	5943512	8339500830	4234079688	5442068798
702	9171213	4033203826	1389510374	1776371304
566	2183735	9683508775	9712259347	7033240354
994	9572277	8842954572	1664361600	0443186679
160	8150472	3327143409	4559346849	1272073445
311	6933243	5027898719	2015370049	5285666044
683	4301370	5574307740	4422788426	0433460952
745	7256576	5929976860	7191386754	1358182476
274	2378653	4855906572	9657693610	9646924245
003	9682961	6637322030	7784570329	1045650426
				1104966724


Otros esquemas de muestreo

complemento

A menudo la población se subdivide en **grupos** antes de realizar el muestreo aleatorio simple.

Dos tipos de agrupaciones:

- **Estratos:** Subconjuntos **homogéneos** de la población que son **internamente heterogéneos** según algún criterio (variable de estratificación)
Ejemplo: son estratos los grupos definidos por sexo, tramos de edad,...
- **Conglomerados:** Subconjuntos **heterogéneos** de la población que son **internamente homogéneos** bajo algún criterio (variable de estratificación)
Ejemplo: Son conglomerados los grupos definidos por ciudades, centros hospitalarios, colegios,...



Idea intuitiva de un posible esquema de **muestreo polietápico**:

Conocidos los conglomerados y los estratos de la población

1. Selección aleatoria de conglomerados
2. División en estratos dentro de cada conglomerado
3. Selección de sujetos dentro de cada estrato de cada conglomerado

1. Selección aleatoria de hospitales
2. En cada hospital hay Auxiliares, Personal de Enfermería y Médicos
3. Selección aleatoria de un nº determinado de Auxiliares, de Enfermeros/as y de Médicos

Tipos de inferencia

Dos facetas de la **Inferencia Estadística**:

1. Estimación de parámetros puntual y por intervalo de confianza

1.1 Se trata de asignar valores a determinados parámetros poblacionales de interés.

A menudo los parámetros poblacionales se corresponden con parámetros de una distribución de probabilidad

¿Cuál es el nivel medio de colesterol en la población infantil? $\rightarrow$ ¿ μ ? de una $N(\mu, \sigma)$

¿Cuál es la prevalencia del síndrome metabólico en la población? $\rightarrow$ ¿ p ? de una $B(n, p)$

¿Cuál es el número medio de llamadas al 061 al día? $\rightarrow$ ¿ λ ? de $P(\lambda)$

1.2 La incertidumbre de la estimación del parámetro se acompaña de un intervalo de confianza

2. Contraste (test) de hipótesis

Se trata de decidir si un enunciado (hipótesis estadística) es soportado por la evidencia empírica o no.

Las hipótesis estadísticas se formulan en términos de los parámetros poblacionales, que a menudo se corresponden con parámetros de una distribución de probabilidad

¿Esta relacionada la capacidad aeróbica con el sexo? $\rightarrow$ ¿ $\mu_h = \mu_m$?

¿Ha variado la prevalencia del síndrome metabólico en la población en la última década? $\rightarrow$ ¿ $p_1 = p_2$?