

ESTADÍSTICA

Grado en Fisioterapia

Tema III

Teoría de la estimación

Pedro Femia Marzo (autor) & Miguel Angel Luque Fernandez (actualización)
Unidad de Bioestadística – Facultad de Medicina
Universidad de Granada



Introducción

Recordemos que:

- Lo que interesa estudiar es a la **población** ← la población en su conjunto es inaccesible
- La población ha de caracterizarse de alguna manera “operativa” ← parámetros poblacionales
- Se necesita algún tipo de técnica que permita extender las conclusiones extraídas a partir de una o varias muestras a toda la población ← **Inferencia Estadística**.

Veremos **dos tipos** de inferencia que permiten dar respuesta a dos tipos de problemas diferentes:

- Teoría de la **Estimación** → ¿Cuál es el tiempo medio que tarda en hacer efecto un fármaco?
- Teoría de los **Contrastes de Hipótesis** → El tratamiento A ¿es igual de efectivo que el tratamiento B?

En ambos - Se estudia a la población a través de sus **parámetros**

- El **tamaño de muestra** jugará un papel relevante que siempre habrá que tener en cuenta

La **Teoría de la Estimación** es la parte de la **Inferencia Estadística** que trata de determinar el valor de los parámetros poblacionales.

Distinguiremos **dos formas de estimación**:

- Estimación **puntual** ← lo mejor que se puede decir del parámetro a partir de la muestra reduciendo la información a **un solo valor**
- Estimación por **intervalo** ← la mejor manera de explotar la información contenida en la muestra de cara a conocer entre qué valores debe encontrarse el parámetro. En lugar de un solo valor, se da un conjunto de ellos.

En la estimación puntual se trata de asignar al parámetro poblacional un único valor; que será un valor aproximado y que depende de la muestra

Conceptos de estimador y de estimación

Un **estimador de un parámetro** es una **función** de las observaciones de la muestra que permite dar valores apropiados para ese parámetro.

Notación: se utiliza el acento circunflejo sobre el símbolo del parámetro poblacional para aludir a su estimador

$\hat{\mu}$ es el estimador puntual de μ

Cuando se haya obtenido la muestra y determinado un valor para μ a partir de ella, se dice entonces que ese valor es una **estimación** de μ .

En la práctica los estimadores habituales son (*método analógico*):

Hay más métodos de estimación, como el método de *mínimos cuadrados* que veremos en el último tema

Parámetros poblacionales de interés

Media	μ
Desviación típica	σ
Proporción	π



Estimadores puntuales

Media muestral	$\bar{x} = \hat{\mu}$
Desviación típica muestral	$s = \hat{\sigma}$
Proporción muestral*	$p = \hat{\pi}$


* En adelante usaremos p en lugar de π para mantener la misma notación que en los resúmenes

Problema que presenta el uso de estimadores puntuales:

El problema de los estimadores puntuales es que solo dan una idea de lo que puede valer el parámetro que estimamos, sin conocer como de buena es la aproximación; es decir, simplemente proporcionan un valor (de los muchos posibles) que puede proponerse como valor del parámetro.

Por ejemplo:

Considere la población de estudiantes de la Universidad de Granada. Estamos interesados en investigar el valor del parámetro μ = '**peso medio de los estudiantes de la UGR**'. Para ello seleccionamos aleatoriamente **dos muestras** de 20 estudiantes cada una y obtenemos el valor del peso medio en cada caso. **¿coincidirán las dos medias muestrales?** ¿cuál es **mejor como estimación**? ¿qué **error** se comete al asumir como valor de μ el ofrecido por una de estas medias?



$$\left. \begin{array}{l} \text{Muestra } M_1 : \bar{x}_1 = 67Kg \\ \text{Muestra } M_2 : \bar{x}_2 = 71Kg \end{array} \right\} \Rightarrow \text{¿}\mu\text{?}$$

La **estimación puntual** supone **reducir toda la información muestral a un solo valor**. Es obvio que dicho valor difícilmente coincidirá de forma exacta con el del parámetro poblacional

Intuitivamente **una muestra de tamaño grande** es **preferible a otra de tamaño menor** ¿por qué? (en la estimación puntual no se aprecia esto)

La **estimación por IC** implica asumir que

- Es prácticamente imposible (por improbable) que valor único dado por el estimador puntual coincida con el valor del parámetro poblacional
- Es mejor dar un **conjunto de valores probables** para el parámetro, en lugar de uno solo
- Existe un **error de estimación** que en la estimación puntual no se pone de manifiesto

La estimación por IC consiste en asignar al parámetro poblacional desconocido un intervalo de valores, digamos (a, b) entre los cuales está dicho parámetro con una cierta probabilidad que denominaremos **nivel de confianza** y que se representa por $(1-\alpha)$. De aquí que α sea el **nivel de error** o probabilidad de que el intervalo obtenido no contenga al parámetro.

Diremos entonces que (a, b) es un **intervalo de confianza** para el parámetro μ construido al $(1-\alpha)\%$ de confianza (o al $\alpha\%$ de error) si se verifica que;


$$P(a \leq \mu \leq b) = 1 - \alpha$$

La **confianza de un intervalo** debe **interpretarse** en el sentido siguiente: Por cada 100 intervalos que construyamos para estimar un mismo parámetro (a partir de otras tantas muestras aleatorias y para un valor α prefijado), en promedio el $(1-\alpha)\%$ de los intervalos obtenidos recogerán en su interior al verdadero valor del parámetro, mientras que el $\alpha\%$ restante, por cosas del azar, pueden resultar 'equivocados'. En la práctica se construye un único IC, así que si elegimos un nivel de confianza $(1-\alpha)\%$ grande, por ejemplo del 95%, entonces nuestra esperanza es que dicho intervalo sea uno de los 95 de cada 100 'acertados' y no uno de los 5 de cada 100 (en promedio) que no contienen al valor del parámetro.

Estimación por intervalo de confianza (IC)


Ejemplo: Se trata de estudiar el nivel de glucosa en sangre en la población cuyos valores aparecen en el recuadro sombreado (esta población es pequeñísima, pero nos vale como ejemplo). Seleccionamos **de forma aleatoria** 5 muestras de tamaño $n = 5$ y elaboramos, en cada caso, el intervalo de confianza para el nivel medio de glucemia (consideraremos un nivel de confianza del 95%). Observemos los resultados:

Población	Muestra	Datos	$\bar{x}$	s	Intervalo (95% conf.)
108 118	M1	123 125 118 125 113	120.80	5.215	(114.325 ; 127.275)
112 120	M2	124 110 115 133 112	118.80	9.576	(106.912 ; 130.688)
123 133	M3	125 113 117 123 124	120.40	5.177	(113.973 ; 126.827)
109 127	M4	133 110 136 125 110	122.80	12.357	(107.459 ; 138.141)
121 125	M5	118 113 117 110 112	114.00	3.391	(109.790 ; 118.210) !
136 115					
124 117					
113 125					
118 117					
129 110					



 $\mu = 120$

- Las estimaciones puntuales varían de muestra a muestra
- Los 5 intervalos tienen diferente amplitud ¿por qué?
- Los cuatro primeros intervalos contienen al verdadero valor de la media (que, excepcionalmente, por conocer a toda la población sabemos que vale 120), sin embargo, en la 5ª muestra los valores obtenidos son, por azar, más bajos de la cuenta y dan lugar a un intervalo que ¡no contiene a μ !




Intervalos contruidos a nivel de confianza del 95% $\rightarrow P(a \leq \mu \leq b) = 1 - \alpha = 0.95$

Cuidado: El parámetro no “cae” en el intervalo. Es el intervalo el que intenta **contener al parámetro**


Para un IC dado, se espera que esto ocurra con una probabilidad de $1 - \alpha$ (la **confianza** del intervalo)

Además del nivel de confianza los IC tienen un **nivel de precisión:** δ (su radio)



Interesan intervalos fiables y precisos (estrechos $\rightarrow \delta$ pequeño).

El nivel de confianza lo establece el investigador de antemano. La precisión no $\rightarrow$ habrá que estudiar de qué depende



Definición: *Nivel de confianza* $(1-\alpha)$

Llamamos **nivel de confianza** $(1-\alpha)$ a la **probabilidad** de que un intervalo de confianza contenga al **verdadero valor del parámetro poblacional**.


Intervalos de confianza a estudiar:

- IC para la media μ de una variable cuantitativa X


Distinguimos dos casos:

- X es una VA con distribución normal
- X es una VA con distribución desconocida
- IC para el parámetro p asociado a la distribución binomial (X es ahora una VAD)


$$X \rightarrow N(\mu; \sigma)$$



$$X \not\rightarrow N(\mu; \sigma)$$



$$X \rightarrow B(n; p)$$



Los métodos estadísticos permiten construir IC para cualquier parámetro (en el adelante se verá alguno más). Siempre que se hable de **estimar** un parámetro debe pensarse en **obtener su IC** (no basta con el estimador puntual)

Intervalos de confianza para la media de una variable cuantitativa

1. ¿Qué se puede decir de la **normalidad** de la variable estudiada X ?

- La variable X tiene distribución normal $\rightarrow$ Su media $\bar{x}$ tiene entonces distribución normal (lo que sigue vale siempre)
- La variable X no tiene distribución normal $\rightarrow$ Su media $\bar{x}$ tiene distribución normal si $n \geq 60$
 - Si $n \geq 60 \rightarrow$ lo que sigue vale de forma aproximada (mejor cuanto mayor sea n)
 - Si $n < 60 \rightarrow$ no se puede estimar μ con los métodos que se exponen aquí

2. **Información muestral:**

- n (tamaño muestral)
- $\bar{x}$ (media muestral)
- s (desviación típica muestral) $\leftarrow$ Observe el detalle de que s es el estimador puntual de σ , que normalmente es un parámetro desconocido (si no se conoce μ , es muy raro conocer σ)

3. **Nivel de confianza** $1-\alpha$

Lo fija el investigador de antemano. NO depende del tamaño muestral

En general se establece al 95% ($\alpha=0.05$). Otros valores habituales son el 90% ($\alpha=0.10$) y el 99% ($\alpha=0.01$)

Intervalos de confianza para la media de una **variable cuantitativa**

4. Expresión del **IC** para estimar μ

$$IC(\mu) = \bar{x} \pm t_{\alpha;n-1} \frac{s}{\sqrt{n}}$$

Equivalentemente

$$P\left(\bar{x} - t_{\alpha;n-1} \frac{s}{\sqrt{n}} \leq \mu \leq \bar{x} + t_{\alpha;n-1} \frac{s}{\sqrt{n}}\right) = 1 - \alpha$$

Condición de **validez**

Si X normal, vale siempre, si no es normal solo es válido como aproximación si $n \geq 60$ (la aproximación que mejora cuanto mayor sea n)


¿Quién es $t_{\alpha;n-1}$?

La distribución t-student está vinculada a la distribución normal. Se trata de una normal corregida por el hecho de no conocer σ y utilizar s (su estimador puntual) en su lugar.

El efecto de la corrección es tanto mayor cuanto menor sea el tamaño de muestra. Para muestras grandes, la t y la normal coinciden

$n-1$ son los grados de libertad de la distribución

Para un α prefijado ¿quién es mayor z_α de la normal o t_α de la t-student?



Distribución t de student

Distribución t de student

¿Cómo obtener un valor $t_{\alpha;n-1}$?

Supongamos una muestra de 10 observaciones:

$$n = 10 \Rightarrow n - 1 = 9 = g.l.$$

Para una confianza del 95% :

$$(1 - \alpha) = 0.95$$

Entonces $\alpha = 0.05$

De aquí se obtiene

$$t_{0.05;9} = 2.262$$

Si no aparecen los gl que buscamos, lo correcto es interpolar, pero aquí bastará con tomar los anteriores de la tabla (nunca más de los que tengamos)

$$n \rightarrow \infty \Rightarrow t = N(0,1)$$

α g.l	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.001
1	1.000	1.376	1.963	3.078	6.314	12.706	31.821	63.657	636.619
2	0.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	31.598
3	0.765	0.978	1.250	1.638	2.353	3.182	4.541	5.841	12.929
4	0.741	0.941	1.190	1.533	2.132	2.776	3.747	4.604	8.610
5	0.727	0.920	1.156	1.476	2.015	2.571	3.365	4.032	6.869
6	0.718	0.906	1.134	1.440	1.943	2.447	3.143	3.707	5.959
7	0.711	0.896	1.119	1.415	1.895	2.365	2.998	3.499	5.408
8	0.706	0.889	1.108	1.397	1.860	2.306	2.896	3.355	5.041
9	0.703	0.883	1.100	1.383	1.833	2.262	2.821	3.250	4.781
10	0.700	0.879	1.093	1.372	1.812	2.228	2.764	3.169	4.587
11	0.697	0.876	1.088	1.363	1.796	2.201	2.718	3.106	4.437
12	0.695	0.873	1.083	1.356	1.782	2.179	2.681	3.055	4.318
13	0.694	0.870	1.079	1.350	1.771	2.160	2.650	3.012	4.221
14	0.692	0.868	1.076	1.345	1.761	2.145	2.624	2.977	4.140
15	0.691	0.866	1.074	1.341	1.753	2.131	2.602	2.947	4.073
16	0.690	0.865	1.071	1.337	1.746	2.120	2.583	2.921	4.015
17	0.689	0.863	1.069	1.333	1.740	2.110	2.567	2.898	3.965
18	0.688	0.862	1.067	1.330	1.734	2.101	2.552	2.878	3.922
19	0.688	0.861	1.066	1.328	1.729	2.093	2.539	2.861	3.883
20	0.687	0.860	1.064	1.325	1.725	2.086	2.528	2.845	3.850
21	0.686	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.819
22	0.686	0.858	1.061	1.321	1.717	2.074	2.508	2.819	3.792
23	0.685	0.858	1.060	1.319	1.714	2.069	2.500	2.807	3.767
24	0.685	0.857	1.059	1.318	1.711	2.064	2.492	2.797	3.745
25	0.684	0.856	1.058	1.316	1.708	2.060	2.485	2.787	3.725
26	0.684	0.856	1.058	1.315	1.706	2.056	2.479	2.779	3.707
27	0.684	0.855	1.057	1.314	1.703	2.052	2.473	2.771	3.690
28	0.683	0.855	1.056	1.313	1.701	2.048	2.467	2.763	3.674
29	0.683	0.854	1.055	1.311	1.699	2.045	2.462	2.756	3.659
30	0.683	0.854	1.055	1.310	1.697	2.042	2.457	2.750	3.646
35	0.682	0.852	1.052	1.306	1.690	2.030	2.438	2.724	3.592
40	0.681	0.851	1.050	1.303	1.684	2.021	2.423	2.705	3.551
45	0.680	0.850	1.049	1.301	1.679	2.014	2.412	2.690	3.521
50	0.679	0.849	1.047	1.299	1.676	2.009	2.403	2.678	3.497
60	0.679	0.848	1.046	1.296	1.671	2.000	2.390	2.660	3.461
80	0.678	0.846	1.043	1.292	1.664	1.990	2.374	2.639	3.417
100	0.677	0.845	1.042	1.290	1.660	1.984	2.364	2.626	3.391
∞	0.674	0.842	1.036	1.282	1.645	1.960	2.326	2.576	3.291

```
# CUANTILES DISTRIBUCION T-STUDENT
```

```
qt(c(0.975), df=9, lower.tail=TRUE)
```

```
[1] 2.262157
```

```
https://www.geogebra.org/m/AHdhBiGA
```

Intervalos de confianza para la media de una **variable cuantitativa**

Fijar α implica, para un tamaño de muestra dado, fijar $t_{\alpha;n-1}$

Si $\bar{x} \pm t_{\alpha;n-1} \frac{s}{\sqrt{n}}$ es el intervalo para μ , $\delta = t_{\alpha;n-1} \frac{s}{\sqrt{n}}$ es su **precisión**

<https://www.geogebra.org/m/Kcq3UxwZ>

De qué depende la precisión


Si $\alpha \uparrow \Rightarrow t_{\alpha} \downarrow \Rightarrow \delta \downarrow$

→ Si aumenta el error, **aumenta** la precisión

Si $n \uparrow \Rightarrow t_{\alpha} \downarrow$ y $\delta \downarrow \Rightarrow \delta \downarrow$

→ Si aumenta el tamaño de muestra **aumenta** la precisión

→ Por otra parte, cuanto mayor sea la variabilidad, menor será la precisión (esto no es controlable)



5. Como garantizar una precisión $\delta_{deseada}$

Es necesario disponer de información previa = **Muestra piloto** que proporcione una estimación de la variabilidad que se puede encontrar en la población

Tamaño mínimo de muestra para estimar μ :
$$n \geq \left(\frac{t_{\alpha;n_{piloto}-1} S_{piloto}}{\delta_{deseada}} \right)^2$$

Como la información dada por la muestra piloto es una variable aleatoria (s) la fórmula es una aproximación cuyo resultado se debe comprobar después


Intervalos de confianza para la media de una variable cuantitativa

Intervalos contruidos a nivel de confianza del 95% $\rightarrow P(a \leq \mu \leq b) = 1 - \alpha = 0.95$

$$\bar{x} - t_{\alpha;n-1} \frac{s}{\sqrt{n}} \quad \bar{x} \quad \bar{x} + t_{\alpha;n-1} \frac{s}{\sqrt{n}}$$

Se espera, con un 95% de probabilidad (=confianza) que el intervalo obtenido contenga a μ

Es decir, que sea uno de los 95 de cada 100 intervalos que contienen al verdadero valor del parámetro poblacional



Intervalos de confianza para la media de una **variable cuantitativa**

Ejemplo:

Para determinar el nivel medio de colesterol en la población de estudiantes universitarios de primer año en la UGR se tomó una muestra al azar de 10 de ellos, en la que se obtuvieron los valores siguientes (en mg/dl):

162, 176, 169, 165, 171, 169, 172, 168, 167, 175

1) Suponemos que el nivel de colesterol es una VAC con distribución normal

2) Información muestral: $n = 10$; $\bar{x} = 169.40$; $s = 4.30$

3) Fijamos una confianza del 95% $\Rightarrow \alpha = 0.05$ y $t_{0.05;9} = 2.262$

4) Entonces, con una confianza del 95% $\mu \in \bar{x} \pm t_{\alpha;n-1} \frac{s}{\sqrt{n}} \Rightarrow \mu \in 169.40 \pm 2.262 \frac{4.30}{\sqrt{10}}$

$$\mu \in 169.4 \pm 3.08 \text{ mg / dl} \Rightarrow \mu \in (166.32; 172.48) \text{ mg / dl}$$

5) lo que **se interpreta** diciendo que el nivel medio de colesterol en los estudiantes de primer curso de la UGR debe de ser un valor comprendido entre 166.32 y 172.48 mg/dl con una probabilidad o nivel de confianza del 95%. La precisión de la estimación es de 3.08 mg/dl

¿Qué hay que hacer para tener una precisión de 5 mg/dl? $\rightarrow$ ¡Nada! La precisión obtenida es mejor (mayor)

¿Qué hay que hacer para tener una precisión de 1 mg/dl? $\rightarrow$ Aumentar el tamaño de muestra. Veamos a cuanto:

$$n \geq \left(\frac{t_{\alpha;n_{pilot}-1} s_{pilot}}{\delta_{deseada}} \right)^2 = \left(\frac{2.262 \cdot 4.30}{1.0} \right)^2 \rightarrow 95$$

Se necesitarían 85 individuos más. Esta fórmula es aproximada. Una vez aumentada la muestra habría que comprobar que la precisión es la deseada

Intervalo de confianza para la **proporción binomial**

Información muestral:

- Tamaño de muestra = n , de los cuales
- x casos cumplen con la característica de interés
- $n - x$ casos no cumplen con la característica de interés

el **estimador puntual** de la proporción de casos que verifican la característica de interés es


$$\hat{p} = x / n$$

¿Qué relación tiene esta expresión con la frecuencia relativa?

Obviamente $\hat{q} = 1 - \hat{p} = (n - x) / n$ estima puntualmente a la proporción complementaria.

En estos problemas, el uso de la distribución binomial puede resultar complicado (se habla de **métodos exactos**). Lo habitual es que si x y $n - x$ son valores suficientemente grandes se construya el intervalo de confianza para p utilizando la distribución normal (se habla de **métodos aproximados** o **asintóticos**)

Recordemos:
Modelo Binomial



Muestra
de tamaño n
($n/N \leq 0.10$)

$X = n^\circ$ de observaciones en
la muestra con A presente



$$X \rightarrow B(n, p)$$

Pero, ¿cuánto vale p ?

Intervalo de confianza para la **proporción binomial**

Fijado α de antemano consideramos tres métodos (en orden de preferencia)

- **Método de Wilson:** Si $x > 5$ y $(n - x) > 5$ ← Cuando se pueda usar es el mejor

$$p \in \frac{1}{n + z_{\alpha}^2} \left((x \pm 0.5) + \frac{z_{\alpha}^2}{2} \pm z_{\alpha} \sqrt{\frac{z_{\alpha}^2}{4} + (x \pm 0.5) \left(1 - \frac{x \pm 0.5}{n} \right)} \right)$$

- **Wald ajustado:** Válido siempre, pero es preferible el de Wilson cuando se puede aplicar

$$p \in \frac{1}{n + 4} \left[(x + 2) \pm \left(z_{\alpha} \sqrt{\frac{(x + 2)(n - x + 2)}{n + 4}} \right) \right]$$

- **Método de Wald:** Si $x > 20$ y $(n - x) > 20$ ← Cuando se dan estas condiciones es una aproximación que funciona tanto mejor cuanto mayores sean x y $n - x$. Es el peor de los tres expuestos y uno de los que más se usan tradicionalmente

$$p \in \hat{p} \pm \left(z_{\alpha} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} + \frac{1}{2n} \right)$$

Si hay **condiciones de validez** deben ser comprobarlas **siempre**

Siempre se debe indicar cuál ha sido el método utilizado

En estas expresiones z_{α} es el valor de la distribución normal correspondiente al $(1 - \alpha)\%$ de confianza (observe que ahora no hablamos de grados de libertad).

Distribución normal estándar

¿Cómo buscar un valor z_{α} ?

Para una confianza del 95% :

$$(1 - \alpha) = 0.95$$

Entonces

$$\alpha = 0.05$$

Así que tenemos que


$$z_{0.05} = 1.96$$

α	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	∞	2.576	2.326	2.170	2.054	1.960	1.881	1.812	1.751	1.695
0.1	1.645	1.598	1.555	1.514	1.476	1.440	1.405	1.372	1.341	1.311
0.2	1.282	1.254	1.227	1.200	1.175	1.150	1.126	1.103	1.080	1.058
0.3	1.036	1.015	0.994	0.974	0.954	0.935	0.915	0.896	0.878	0.860
0.4	0.842	0.824	0.806	0.789	0.772	0.755	0.739	0.722	0.706	0.690
0.5	0.674	0.659	0.643	0.628	0.613	0.598	0.583	0.568	0.553	0.539
0.6	0.524	0.510	0.496	0.482	0.468	0.454	0.440	0.426	0.412	0.399
0.7	0.385	0.372	0.358	0.345	0.332	0.319	0.305	0.292	0.279	0.266
0.8	0.253	0.240	0.228	0.215	0.202	0.189	0.176	0.164	0.151	0.138
0.9	0.126	0.113	0.100	0.088	0.075	0.063	0.050	0.038	0.025	0.013

Tabla para los pequeños valores de α										
α	0.002	0.001	0.000 1	0.000 01	0.000 001	0.000 000 1				
z_{α}	3.090	3.291	3.891	4.417	4.892	5.327				

Observe que z_{α} es el percentil $1-\alpha/2$ de la distribución:

<https://www.geogebra.org/m/upke9x5y>



$$\alpha = 0.05 = 0.0 + 0.05 \Rightarrow Z_{0.05} = 1.96$$

Para buscar un valor de α con dos decimales se debe sumar la primera columna (primer decimal) y la primera fila (segundo decimal)

```
# NC 90%
```

```
qnorm(0.95)
```

```
[1] 1.644854
```

```
# NC 95%
```

```
qnorm(0.975)
```

```
[1] 1.959964
```

```
# NC 98%
```

```
qnorm(0.99)
```

```
[1] 2.326348
```

```
# NC 99%
```

```
qnorm(0.995)
```

```
[1] 2.575829
```

```
# NC 95%
```

```
qnorm(c(0.975), mean=0, sd=1, lower.tail=TRUE)
```


```
[1] 1.959964
```

Intervalo de confianza para la **proporción binomial**

Precisión del intervalo

Obtenido el intervalo, que tendrá la forma (a, b) , la precisión de la estimación puede obtenerse como sigue si el **intervalo es simétrico** (métodos de Wald y Wald ajustado):

$$\delta = \frac{(b-a)}{2}$$




Observación: El IC de Wilson no es simétrico y el valor anterior es una aproximación. En cualquier caso, **la precisión es un valor expresable porcentualmente**.

Tamaño de muestra

El **tamaño mínimo de muestra** para obtener una precisión deseada δ , para α prefijado, puede determinarse de forma general o considerando la información dada por una muestra piloto:

- Sin información previa (tamaño necesario en el *peor* de los casos): $n \geq \frac{z_{\alpha}^2 \times 0.25}{\delta_{deseada}^2}$
- Con información previa (muestra piloto): $n \geq \frac{z_{\alpha}^2 \times \tilde{p}(1-\tilde{p})}{\delta_{deseada}^2}$

La expresión sin información es exacta por no depender de ninguna muestra. El precio a pagar es que normalmente da lugar a un n muy grande. Si se usa la información de una muestra piloto, la estimación de n no es exacta y hay que comprobar que se obtiene la precisión deseada. **Si el IC contiene a 0.5, las dos expresiones coinciden**, y la información no aporta ninguna ventaja para reducir n



Intervalo de confianza para la **proporción binomial**

Ejemplo:

De 150 estudiantes de primer curso de grado universitario que se han encuestado, 33 fuman habitualmente. ¿Cuál es la prevalencia del tabaquismo en este colectivo?. Se desea obtener la estimación con una precisión del 10%

1) Valores muestrales: $n = 150$; $x = 33$; $n - x = 150 - 33 = 117$

La estimación puntual la prevalencia del tabaquismo vendrá dada por p

$$\hat{p} = x/n = 33/150 = 0.220 \quad (22.0\%)$$

De modo que el porcentaje de no fumadores está estimado por

$$\hat{q} = 1 - \hat{p} = 0.780 \quad (= 78.0\%)$$

2) Fijamos el nivel de confianza al 95% $\Rightarrow \alpha = 0.05$ y $Z_{0.05} = 1.96$

3) Validez y elección del método: Como $x=33$ y $n-x=117$ son mayores a 5, se puede utilizar el método de Wilson

$$p \in \frac{1}{150 + 1.96^2} \left((33 \pm 0.5) + \frac{1.96^2}{2} \pm 1.96 \sqrt{\frac{1.96^2}{4} + (33 \pm 0.5) \left(1 - \frac{33 \pm 0.5}{150} \right)} \right)$$

$$\text{Límite inferior: } \frac{1}{150 + 1.96^2} \left((33 - 0.5) + \frac{1.96^2}{2} - 1.96 \sqrt{\frac{1.96^2}{4} + (33 - 0.5) \left(1 - \frac{33 - 0.5}{150} \right)} \right) = 0.15826$$

$$\text{Límite superior: } \frac{1}{150 + 1.96^2} \left((33 + 0.5) + \frac{1.96^2}{2} + 1.96 \sqrt{\frac{1.96^2}{4} + (33 + 0.5) \left(1 - \frac{33 + 0.5}{150} \right)} \right) = 0.29642$$

Intervalo de confianza para la proporción binomial

Ejemplo (continuación):


$$95\%-IC_{\text{Wilson}}(p) = (15.8\%; 29.6\%)$$

Solución por los otros métodos

$$95\%-IC_{\text{Wald ajust}}(p) = (16.1\%; 29.3\%)$$

$$95\%-IC_{\text{Wald}}(p) = (15.0\%; 29.0\%)$$

- 4) **Interpretación** de los resultados: La prevalencia del tabaquismo entre los estudiantes de primer curso universitario es, con un 95% de probabilidad, un valor que debe estar comprendido entre el 15.8% y el 29.6%. La **precisión** de la estimación es del 6.9% $\leftarrow (0.29642 - 0.15826)/2$
- 5) Respecto a la precisión pedida del $\delta = 10\%$, nuestros resultados tienen una precisión **mayor**, (6.9% es mayor precisión que 10%) por lo tanto no hay que considerar ningún aumento del tamaño de muestra. Si quisiéramos una precisión del 5%, entonces sí que habría que considerar un aumento del tamaño de muestra



Sin considerar la información previa:

$$n \geq \frac{z_{\alpha}^2 \times 0.25}{\delta_{deseada}^2} = \frac{1.96^2 \times 0.25}{0.05^2} \rightarrow 385$$

Considerando la información previa: $\begin{cases} \tilde{p} = 0.296 \\ 1 - \tilde{p} = 0.704 \end{cases}$ $\tilde{p}$ Es el valor del IC=(0.158; 0.296) más próximo a 0.5

$$n \geq \frac{z_{\alpha}^2 \times \tilde{p}(1 - \tilde{p})}{\delta_{deseada}^2} = \frac{1.96^2 \times 0.296(0.704)}{0.05^2} \rightarrow 317$$

Sin aprovechar la información dada por la muestra piloto

Un posible esquema de trabajo

Identifique claramente **qué parámetro** se trata de estimar.

Identifique claramente la **información muestral** y el **estimador puntual** correspondiente. Proporcione la estimación puntual (e interprétela).

Establezca el **nivel de confianza** ($1-\alpha$) (si no hay motivos para hacer otra cosa consideramos el 95%)

Compruebe si se cumplen las **condiciones de validez** que pudiera haber, por ejemplo, al estimar una media, la normalidad de la variable o si no es normal que $n > 60$. Al estimar una proporción que x y $n-x$ son mayores al valor que es requisito de la fórmula que se vaya a utilizar

Escriba la expresión del intervalo de confianza y **realice los cálculos** necesarios para obtenerlo.

Interprete los resultados obtenidos, indicando claramente

- cuál es el **intervalo** (no olvide las **unidades de medida**)
- cuál es la **precisión** obtenida (también tiene unidades de medida)
- el nivel de **confianza** con que se ha construido.

Si se trata de obtener una precisión dada de antemano δ_{deseada} compruebe si la precisión obtenida es mayor: $d < \delta_{\text{deseada}}$ de ser así, no hay que hacer nada más (la muestra actual es suficiente). En caso contrario (si $d \geq \delta_{\text{deseada}}$) se debe determinar el tamaño de muestra necesario para cumplir con esta especificación

Ejercicios

Estimación de medias (suponer que la v.a. es normal)

Muestra											Datos						n	media	desv.	t	Lim inf	Lim. Sup	precisión Observada	para $\delta =$	n =
M1	2.6	2.4	2.7	3.2	3.4	3.5	3.2	3.6	3.4	3.5	10	3.150	0.428	2.262	2.844	3.456	0.306	0.2	23.4	24					
M2	12	21	15	11	13	12	18				7	14.571	3.690	2.447	11.158	17.984	3.413	1.7	28.2	29					
M3	3.75	7.75	3.88	3.67	9.2	0.77	8.61	2.46	2.68		9	4.752	3.000	2.306	2.446	7.058	2.306	1.2	33.2	34					
M4	75.53	58.7	52.32	18.05	23.41	71.21	62.85	46.2	21.58	0.38	10	43.023	25.546	2.262	24.749	61.297	18.274	9.1	40.3	41					
M5	6.93	6.34	4.69	7.79	3.26	0.98	8.86	5.29	8.35		9	5.832	2.563	2.306	3.862	7.803	1.970	1.0	34.9	35					
M6	0.59	0.28	0.46	0.37	0.23	0.11	0.27	0.6			8	0.364	0.175	2.365	0.217	0.510	0.146	0.1	17.1	18					
M7	0.54	0.98	0.74	0.69	0.2	0.98	0.51	0.54			8	0.648	0.260	2.365	0.430	0.865	0.217	0.1	37.8	38					
M8	1	2	3.6	1.4	8.1	1.3	7.6				7	3.571	3.047	2.447	0.754	6.389	2.818	1.4	28.4	29					
M9	0.04	0.08	0.4	0.17	0.21	0.86	0.38	0.96			8	0.388	0.348	2.365	0.097	0.678	0.291	0.1	67.5	68					
M10	3.49	64.5	19.08	65.67	8.46	52.36	27.6	37.3	11.44		9	32.212	24.002	2.306	13.763	50.662	18.450	9.2	36.2	37					
M11	0.31	0.92	0.29	0.91	0.94	0.55	0.64	0.63			8	0.649	0.262	2.365	0.430	0.868	0.219	0.1	38.4	39					
M12	0.73	0.61	0.82	0.11	0.51	0.57	0.69				7	0.577	0.231	2.447	0.364	0.790	0.213	0.1	31.8	32					

Estimación de proporciones

Ej:	Muestra		Método	Validez	IC(-)	IC(+)	d	%			Precisión deseada (%)	Tamaño necesario	
	n	x						IC(-)	IC(+)	d		Con inf	Sin inf
1	113	42	Wilson	Si	0.284	0.468	0.092	28.41%	46.81%	9.20%	5%	383	385
			Wald	Si	0.278	0.465	0.094	27.82%	46.52%	9.35%			
			Wald Ajustado	Si	0.288	0.464	0.088	28.83%	46.38%	8.78%			
2	11	6	Wilson	No	0.246	0.819	0.286	24.56%	81.86%	28.65%	7%	196	196
			Wald	No	0.206	0.885	0.340	20.57%	88.52%	33.97%			
			Wald Ajustado	Si	0.281	0.786	0.252	28.09%	78.58%	25.25%			
3	30	24	Wilson	Si	0.609	0.916	0.154	60.87%	91.60%	15.36%	7%	187	196
			Wald	No	0.640	0.960	0.160	64.02%	95.98%	15.98%			
			Wald Ajustado	Si	0.622	0.907	0.143	62.21%	90.73%	14.26%			
4	150	103	Wilson	Si	0.605	0.758	0.077	60.51%	75.85%	7.67%	10%	92	97
			Wald	Si	0.609	0.764	0.078	60.91%	76.42%	7.76%			
			Wald Ajustado	Si	0.608	0.755	0.074	60.83%	75.54%	7.36%			
5	63	32	Wilson	Si	0.380	0.635	0.127	38.01%	63.48%	12.73%	3%	1068	1068
			Wald	Si	0.377	0.639	0.131	37.65%	63.93%	13.14%			
			Wald Ajustado	Si	0.388	0.627	0.120	38.78%	62.72%	11.97%			