

ESTADÍSTICA

Grado en Fisioterapia

Tema V

**Tests con una muestra para
la media y la proporción
(complemento)**

Pedro Femia Marzo (autor) & Miguel Angel Luque Fernandez (update)

Unidad de Bioestadística – Facultad de Medicina

Universidad de Granada

Estudio de la normalidad

- La distribución normal es un modelo de distribución de probabilidad para variables continuas
- Generalmente interesa más la **normalidad de la distribución de la media** de la variable que de la variable en si.

Recordemos que:

La media de una VA con distribución normal también tiene distribución normal (con dispersión menor cuanto mayor es el tamaño de la muestra n)

$$\text{Si } X \rightarrow N(\mu; \sigma) \Rightarrow \bar{X} \rightarrow N(\mu; \sigma/\sqrt{n})$$

La media de una VA con distribución desconocida, tiene una distribución aproximadamente normal si el tamaño de muestra es $n \geq 60$. La dispersión disminuye y la calidad de la aproximación aumenta cuanto mayor sea el tamaño de la muestra n (Teorema del Límite Central)


$$\text{Si } X \rightarrow ?? \Rightarrow \bar{X} \xrightarrow[n \geq 60]{\text{aprox.}} N(\mu; \sigma/\sqrt{n})$$

- En la práctica:




- Si el tamaño de muestra es $n \geq 60$ ← La normalidad de la distribución de la media muestral viene avalada por el **teorema del límite central**, incluso si la variable es discreta (en tal caso se debe incluir una corrección por continuidad (cpc)) por lo tanto usamos **T-Student**
- Si el tamaño de muestra es $n < 60$:
 - si la variable es continua: estudiar su normalidad estadística ← Análisis gráfico + Test de normalidad
 - si la variable es discreta: no deben utilizarse a priori métodos basados en la distribución normal usaríamos **Chi cuadrado Test o Test Exacto de Fisher**

Estudio de la normalidad

- Se trata de un problema que puede ser difícil de resolver. Especialmente si el tamaño de muestra es pequeño
- Se deben combinar los test de hipótesis con métodos gráficos



- Muchos métodos que requieren que la variable sea normal, a menudo funcionan bien si la desviación no es muy severa → Observar la simetría de la distribución



- (A) Asimetría positiva
Muchos "tienen" poco y pocos "tienen" mucho
- (B) Mezcla de 2 grupos heterogéneos
- (C) ¿Normal?

Test de normalidad de D'Agostino

1. Test de D'Agostino. Hipótesis a contrastar

$$\begin{cases} H_0 : \text{La variable tiene distribución normal} \\ H_1 : \text{La variable NO tiene distribución normal} \end{cases}$$

En todos los tests de normalidad, H_0 es siempre "La variable es normal"

2. Estadístico de contraste

$$D_{\text{exp}} = \frac{\sum i x_{(i)} - (n+1)(\sum x_i)/2}{n\sqrt{n(n-1)s^2}} \quad (\text{Confrontar con la tabla de D'Agostino})$$

COMPLEMENTO

3. Ejemplo de cálculo

COMPLEMENTO

	X_i	$X_{(i)}$	i	$i X_{(i)}$
1	2.1	1.3	1	1.3
2	8.6	2.1	2	4.2
3	6.1	2.6	3	7.8
4	3.5	3.4	4	13.6
5	6.2	3.5	5	17.5
6	3.4	4.9	6	29.4
7	5.5	5.5	7	38.5
8	9.7	6.1	8	48.8
9	1.3	6.2	9	55.8
10	2.6	8.5	10	85.0
11	8.5	8.6	11	94.6
12	4.9	9.7	12	116.4

$H_0: x$ tiene distribución normal

$$n = 12$$

$$\sum x_i = 62.37$$

$$\sum i x_{(i)} = 512.06$$

$$s^2 = 7.40$$

$$D_{\text{exp}} = 0.2844$$

$$0.10 < p < 0.20 \quad \leftarrow \text{¿conclusión?}$$

El peligro de las muestras pequeñas

n pequeño




Test poco potente



No se rechaza H_0



¡La variable es normal!



Distribución observada de x
(Diagrama de puntos)

Test para una media

1. Si la variable X tiene distribución normal Si $X \rightarrow N(\mu; \sigma)$


entonces $\Downarrow$

2. Su media también tiene distribución normal $\bar{X} \rightarrow N(\mu; \sigma/\sqrt{n})$

$\Downarrow$

3. Tipificando: $\frac{(\bar{X} - \mu)}{\sigma/\sqrt{n}} \rightarrow N(0;1) \Leftrightarrow (\bar{X} - \mu) \rightarrow N\left(0; \frac{\sigma}{\sqrt{n}}\right)$

Tipificación de la media muestral



Ahora interviene la **información dada por la hipótesis nula H_0**

4. Si H_0 es cierta $\mu = \mu_0 \Rightarrow \frac{(\bar{X} - \mu_0)}{\sigma/\sqrt{n}} \rightarrow N(0;1)$ de este modo tenemos un criterio para decidir si


la diferencia entre la información muestral ($\bar{X}$) y la propuesta de la hipótesis nula ($\mu = \mu_0$) son muy discrepantes o no (un valor tipificado es “*auto informativo*”) $\Rightarrow$

5. Solo falta eliminar al *parámetro perturbador* σ (la desviación típica poblacional, que es desconocida)

Si sustituimos σ por su estimador puntual $\hat{\sigma} = s$ obtenemos*

$$t = \frac{(\bar{X} - \mu_0)}{s/\sqrt{n}} \rightarrow t\text{-Student}$$

$$z = \frac{(\bar{X} - \mu_0)}{\sigma/\sqrt{n}} \rightarrow N(0,1)$$



Esta cantidad es una función de los valores muestrales que nos permite decidir en favor o en contra de la hipótesis nula a raíz de la evidencia muestral. Se denomina **estadístico de contraste** o **cantidad experimental**. Habitualmente se indica t_{exp} (o F_{exp} , χ^2_{exp} ,... según la distribución usada)

* Recordar que la distribución *t-Student* constituye una “corrección” de la distribución normal necesaria para muestras pequeñas ($n < 100$) cuando σ es desconocido (siempre, en gral.)

Inferencia Estadística: Tests de hipótesis

Contrastes para una población Normal:

Contrastes sobre la **media una sola muestra**

La estatura X de los individuos varones residentes en una pequeña región sigue una distribución normal. Deseamos contrastar la hipótesis de que el valor medio de X es 175 cm, con el nivel de significación de 0,05. Para ello se han elegido 90 personas al azar, obteniéndose una altura media de 172 y desviación típica muestral de 5.3 cm. ¿Qué decisión deberíamos tomar?

Información poblacional


X : "Estatura de individuos varones"

$X \rightarrow N(\mu, \sigma)$

$$\left. \begin{array}{l} H_0 : \mu = 175 \\ H_1 : \mu \neq 175 \end{array} \right\} Z = \frac{\bar{X} - \mu_0}{S / \sqrt{n}} \rightarrow N(0,1)$$

$$z_{\text{exp}} = \frac{172 - 175}{5.3 / \sqrt{90}} = -5.369$$

$$z_{\text{teórica}} = z_{0.025} = 1.96$$



Rechazamos H_0

-5.3

-1.96

1.96

Información muestral

$n = 90$ $\alpha = 0.05$

$\bar{X} = 172$

$s = 5.3$

Existe evidencia empírica de que no podemos asumir esa altura media

Ejemplo:

Según la encuesta nacional de salud de 2012, la prevalencia del tabaquismo en los estudiantes de primer curso universitario es del 22%. Para estudiar si ha variado en 2013 se ha tomado una muestra de 300 estudiantes de los cuales: 48 son fumadores, 239 no lo son y el resto no contestan. ¿Puede afirmarse que la proporción de fumadores en este sector de la población ha cambiado respecto a 2012?

1. Información muestral:

Tamaño de muestra original = 300; pero solo contestan $239+48=287 = n$

$$\begin{cases} n = 287 \\ x = 48 \\ n-x = 239 \end{cases}$$

2. Hipótesis: se trata de comprobar si la prevalencia ha cambiado respecto al valor propuesto $p_0=0.22$

$$\begin{cases} H_0: p = p_0 \\ H_1: p \neq p_0 \end{cases} \rightarrow \begin{cases} H_0: p = 0.22 \\ H_1: p \neq 0.22 \end{cases} \begin{matrix} \leftarrow \text{La prevalencia no ha cambiado} \\ \leftarrow \text{La prevalencia si ha cambiado} \end{matrix}$$

Fijamos el error de tipo I a un nivel $\alpha=0.05$, de manera que declararemos significativo a todo resultado que de lugar a un nivel de significación $P \leq \alpha=0.05$

3. Condiciones de validez: debe cumplirse que

$$\begin{cases} np_0 > 5 \\ n(1-p_0) = nq_0 > 5 \end{cases} \rightarrow \begin{cases} np_0 = 287 \times 0.22 = 63.14 \\ nq_0 = 287 \times 0.78 = 223.86 \end{cases}$$

Se cumple: podemos aplicar el método
(de lo contrario no podemos seguir)

4. Evidencia muestral: el estadístico de contraste:

$$z_{\text{exp}} = \frac{|x - np_0| - 0.5}{\sqrt{np_0q_0}} = \frac{|48 - 287 \times 0.22| - 0.5}{\sqrt{287 \times 0.22 \times 0.78}} = 2.086$$

Test con una proporción

COMPLEMENTO

5. **Nivel de significación** (se obtiene de la tabla de la distribución normal): $0.03 < P < 0.04$

6. **Interpretación:** el resultado es **significativo**, es decir que rechazamos la hipótesis nula de que la prevalencia en 2013 es la misma que la observada en 2012

Lecturas posibles (y equivalentes) de este valor de P

- La probabilidad de equivocarnos al rechazar la hipótesis nula con estos datos es menor al 4%. Como esta probabilidad es menor a $\alpha=5\%$, el nivel de error es tolerable y en consecuencia rechazamos H_0
- Si H_0 es cierta, es decir si la prevalencia es del 22% en 2013, la probabilidad de observar una muestra como la actual, o más discrepante con dicha hipótesis, es del 4%. Consideramos que esa probabilidad es baja ($<\alpha$) y en consecuencia rechazamos H_0

7. **Análisis de la significación.** Como rechazamos la H_0 no puede asumirse que la prevalencia es el valor propuesto, ¿Qué valor toma entonces dicho parámetro? ← **IC para una proporción**

Método	IC(-)	IC(+)	d	Validez	%		
					IC(-)	IC(+)	d
Wilson	0.12698	0.21665	0.04483	Si	12.70%	21.67%	4.48%
Wald	0.12233	0.21217	0.04492	Si	12.23%	21.22%	4.49%
Wald Ajustado	0.12848	0.21516	0.04334	Si	12.85%	21.52%	4.33%

Confianza: 95%

Atendiendo al método de Wilson, la prevalencia del tabaquismo es, con un 95% de probabilidad, un valor comprendido entre el 12.7% y el 21.7%. Podemos asumir que ha disminuido respecto al 22% del año anterior. Obsérvese como $p_0=0.22$ no está en el IC para p

Test con una proporción

COMPLEMENTO

$$\begin{cases} n = 200 \\ x = 33 \\ n-x = 167 \end{cases}$$

¿Y si los datos muestrales hubieran sido?

$$\begin{cases} np_0 > 5 \\ n(1-p_0) = nq_0 > 5 \end{cases} \rightarrow \begin{cases} np_0 = 200 \times 0.22 = 44 \\ nq_0 = 200 \times 0.78 = 156 \end{cases} \quad \text{El método es válido}$$

$$z_{\text{exp}} = \frac{|x - np_0| - 0.5}{\sqrt{np_0 q_0}} = \frac{|33 - 200 \times 0.22| - 0.5}{\sqrt{200 \times 0.22 \times 0.78}} = 1.792 \rightarrow 0.07 < P < 0.08 \rightarrow$$

El resultado no es significativo. No podemos rechazar la hipótesis nula con estos datos, aunque hay **indicios de significación**.

Observemos ahora el 95%-IC para p

Método	IC(-)	IC(+)	d	Validez	%		
					IC(-)	IC(+)	d
Wilson	0.11782	0.22541	0.05380	Si	11.78%	22.54%	5.38%
Wald	0.11106	0.21894	0.05394	Si	11.11%	21.89%	5.39%
Wald Ajustado	0.11983	0.22330	0.05173	Si	11.98%	22.33%	5.17%

Confianza: 95%

Atendiendo al IC del método de Wilson:

- El valor p_0 pertenece al IC: $0.22 \in (0.1178; 0.2254)$
- El valor de este intervalo es el de apreciar que la prueba no encuentra diferencias entre un 22% y un 11.78% (el límite del IC mas discrepante). Como esto puede ser una discrepancia muy grande (11% es la mitad de 22%) observamos un síntoma de falta de potencia del test. La aceptación de H_0 no resulta fiable y sería recomendable aumentar el tamaño de muestra (para ganar potencia)

La **determinación del tamaño de muestra** requiere fijar de antemano:

- El nivel de error α asumible
- La potencia deseada (o de forma equivalente el nivel de error asumible β)
- La mínima diferencia con p_0 a detectar (δ)

Considerando el valor más cercano a 0.5 de $p_1 = p_0 \pm \delta \longrightarrow n \geq \left(\frac{z_\alpha \sqrt{p_0 q_0} + z_{2\beta} \sqrt{p_1 q_1}}{\delta} \right)^2$

- Por ejemplo, si interesa declarar significativa una diferencia del 6% con una potencia del 90% a un error α del 5%

$$\alpha = 0.05 \rightarrow z_\alpha = 1.96$$

$$\theta = 1 - \beta = 0.90; \beta = 0.10 \rightarrow z_{2\beta} = z_{0.20} = 1.282$$

$$\delta = 0.06$$

$$p_0 \pm \delta = 0.22 \pm 0.06 = \begin{cases} 0.16 \\ 0.28 = p_1 \end{cases} \text{ Por ser el más cercano a 0.5}$$

$$n \geq \left(\frac{1.96 \sqrt{0.22 \times (1 - 0.22)} + 1.282 \sqrt{0.28 \times (1 - 0.28)}}{0.06} \right)^2 = 534.6 \rightarrow 535$$

Son necesarias más de 534 observaciones (=535)