

ESTADÍSTICA

Grado en Fsioterapia

Tema VIII

Regresión y correlación

Pedro Femia Marzo (autor) & Miguel Angel Luque Fernandez (update)
Unidad de Bioestadística – Facultad de Medicina


Universidad de Granada



Motivación

Problema: A continuación figuran las medidas del índice de masa corporal (IMC) y el porcentaje de peso graso (determinado en laboratorio) de una muestra de 12 adolescentes (8 hombres y 5 mujeres) con una edad comprendida entre 15 y 19 años.

#	IMC	% graso
1	20,36	17,36
2	20,34	12,72
3	20,05	11,65
4	23,07	17,81
5	23,94	19,34
6	27,45	29,70
7	22,17	24,19
8	24,37	15,26
9	22,18	28,41
10	17,30	8,87
11	21,72	25,62
12	19,29	20,91




- ¿**Existe relación** entre el IMC y el porcentaje de masa grasa?
- De ser así, ¿es **intensa** la relación? ¿existe algún **modelo** que permita caracterizar tal relación?
- Sabiendo el IMC de una persona ¿es posible hacer algún tipo de **pronóstico** sobre su % graso?*
- En tal caso ¿es **fiable** tal pronóstico?


* El $IMC = \text{peso (kg)} / (\text{talla (m)})^2$ es una medida fácil de calcular, el % de masa grasa no tanto, requiere la instrumentación adecuada.

El primer paso: Diagrama de dispersión o nube de puntos

¿ Aporta alguna información sobre la distribución de una de las variables el hecho de conocer qué valores toma la otra?



El primer paso: Diagrama de dispersión o nube de puntos



- Se dice que hay **correlación** si hay algún tipo de **asociación**. Es decir, cuando el cambio en una variable se acompaña por un cambio “sistemático” en la otra. Mediante un **coeficiente de correlación** se cuantifica la **fuerza de la asociación**.
- Por **regresión** se alude a un **modelo** (= expresión matemática) que permite caracterizar *cómo* cambia una de las variables cuando cambia la otra. Un modelo de regresión permite no solo describir la forma del cambio, también pronosticar el valor esperado de una de las variables a partir del valor que toma la otra.

El diagrama de dispersión permite hacer una primera valoración sobre ambas cuestiones.

Rol de las variables y tipos de muestreo

Rol de las variables

- Una variable actúa como variable **explicativa**, **regresora** o **independiente** (habitualmente se indica como x)
- La otra variable es la variable **explicada** o **dependiente** (habitualmente se representa por y)

Tipo de Muestreo

Cada individuo aporta una pareja de datos (muestras apareadas) solo que, en general, se trata de variables diferentes (aunque no necesariamente). Hay dos formas posibles de obtener los datos:


- **Muestreo de tipo I** (de una muestra aleatoria de individuos se observan ambas variables) ← **observación** (es el caso del ejemplo que estamos considerando). Las dos variables pueden desempeñar el rol de variable explicativa.
- **Muestreo de tipo II** (fijados de antemano los valores de x , se observan los de y) ← **experimentación** (el rol de las variables no es intercambiable)

Asociación no implica causalidad



Que dos variables estén asociadas no supone necesariamente que una sea la causa de la otra.

Ejemplo, consideremos niños con edad ≤ 12 meses


Relación causal unidireccional



Influencia (causal) mutua



Asociación espuria



El muestreo de tipo I solo permite hablar de asociación (en el sentido de *covariación*), no de causalidad. Para establecer una relación causal, el muestreo debe ser de tipo II

El modelo de regresión como *modelo estadístico*

Que y se relacione con x se expresa, de la forma general: $y = f(x)$ (esto es un modelo)

Para establecer, o especificar, el **modelo** deberemos concretar la forma que toma $f(x)$

En cualquier caso, $y = f(x)$ debe poder representar una **relación no determinista** → para los mismos valores de x no se observan necesariamente los mismos valores de y

En el ámbito científico se presentan básicamente dos tipos de modelos:

Modelos mecanicistas

- Se establecen a partir del **conocimiento íntimo** del proceso (ej. Ecuación de Michaelis-Menten)
- Son **deterministas** → para un mismo valor de x se obtiene siempre la misma y
- Experimentalmente nunca se observarán los datos exactamente como los predice el modelo mecanicista (A), siempre habrá error de medida y otros factores *no asignables* que hacen que las observaciones presenten cierta variabilidad en torno al valor pronosticado por dicho modelo (B)

Modelos estadísticos



Se pueden expresar

$$y = \text{componente determinista} + \text{componente aleatorio}$$

(forma de la dependencia de y respecto a x) (influencia de causas no asignables)

- El **componente determinista** puede corresponder a un **modelo mecanicista** (sugerido por el conocimiento del mecanismo que relaciona las variables) o por un **modelo empírico** (sugerido por los propios datos, la forma que toma la *nube de puntos*)
- El **componente aleatorio** es el responsable de la **variabilidad** observada en los datos respecto al componente determinista. En general (nosotros lo haremos así), se asume que se trata de una variable aleatoria con **distribución normal** y **media cero** (los errores por exceso se compensan con los errores por defecto)


Efecto del componente aleatorio




	x	y
#	IMC	% graso
1	20,36	17,36
2	20,34	12,72
3	20,05	11,65
4	23,07	17,81
5	23,94	19,34
6	27,45	29,70
7	22,17	24,19

Para valores similares de x se observan diferentes valores de y


Diagnóstico del diagrama de dispersión




Relación lineal inversa




Relación lineal directa




Relación no lineal
(monotónica)




Relación no lineal
(no monotónica)




Ausencia de relación



Heterocedasticidad




Observación influyente
(pero que mantiene el modelo lineal)




Observaciones atípicas
(no mantienen el modelo lineal)


Algunos modelos (con base determinista o sugeridos por los datos) de uso frecuente




Lineal




Polinómico



Potencial



Hiperbólico
(Michaelis-Menten)




Sigmoidal
(Hill)



Diagnóstico del diagrama de dispersión

Qué se debe observar en un diagrama de dispersión

1. Si **hay relación** o no entre las variables




2. En caso de haber relación, si es **lineal** o **no lineal**




3. En caso de haber relación lineal $\rightarrow$ al aumentar x aumenta o disminuye linealmente la media de y pero, ¿cambia también la variabilidad de y al cambiar x (**heterocedasticidad***) ?

La heterocedasticidad es un fenómeno frecuente y perjudica la *calidad* del modelo




homocedasticidad



heterocedasticidad

4. ¿Hay puntos **anómalos** respecto al modelo que viene sugerido por la mayoría de los datos?





Observación
influyente
(pero no anómala)

Observación
anómala e influyente
(afecta mucho al modelo)

5. ¿Hay observaciones **influyentes**?

El nivel de influencia de una observación viene dado por su distancia a la media de la variable explicativa, cuanto más alejada esté de $\bar{x}$, más influyente resulta sobre el modelo.



* - *cedasticidad* procede del griego *skedasis* que quiere decir *dispersión*

El Modelo de Regresión Lineal

Desde el punto de vista algebraico

Ecuación general de la línea recta: $y = a + b x$

2 parámetros $\begin{cases} b = \text{pendiente} \text{ (= inclinación de la recta)} \\ a = \text{ordenada en el origen (valor de } y \text{ cuando } x=0) \end{cases}$

Punto de vista estadístico

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Los dos parámetros descritos constituyen el **componente determinista** del modelo, que caracteriza la forma en que y depende de x . Además, el modelo presenta un **componente aleatorio** que es el responsable de la variabilidad observada en y para un mismo valor de x , ambos componentes son **aditivos**

$$\begin{array}{c} \boxed{y} = \boxed{\beta_0 + \beta_1 x} + \boxed{\varepsilon} \\ \text{Respuesta} = \text{componente determinista} + \text{componente aleatorio} \end{array}$$

Ajustar el modelo estadístico consiste en **estimar** los parámetros que constituyen el componente determinista para caracterizar cómo afecta x a y




$$\hat{\beta}_0 + \hat{\beta}_1 x = a + b x$$

Se espera que el valor promedio del **componente aleatorio** ε sea cero (los excesos se compensan con los defectos). Interesa estimar su **varianza** σ_ε^2 ya que es la responsable de la variabilidad observada en la respuesta respecto al componente determinista

$$S_R^2 = \hat{\sigma}_\varepsilon^2 \quad (\text{es la } \textbf{varianza residual})$$

$\hat{y}$ será el **valor esperado de** y (inferencia sobre y) dado un valor de x

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \rightarrow \hat{y} = a + b x$$



El Modelo de Regresión Lineal

Interpretación de los parámetros

$$\hat{y} = a + b x$$

Coefficiente de regresión: cuánto (y cómo) cambia y por una unidad de aumento en x

Constante: cuánto vale y para $x=0$ según el modelo (no siempre tiene sentido interpretarlo).

El coeficiente más relevante es el **coeficiente de regresión** (la pendiente)

$b > 0$ El aumento en x va acompañado por un aumento en y
Asociación lineal directa o positiva




$b < 0$ El aumento en x va acompañado por una reducción en y
Asociación lineal inversa o negativa

$b \approx 0$ Los valores de y no tienen relación con los que toma x
Falta de asociación lineal

¡Cuidado! Un coeficiente de regresión $b = 0$ no se traduce necesariamente en **independencia** entre las variables, solo en la **falta de asociación lineal**

Relevancia del modelo lineal


- Es el más simple (si un modelo simple caracteriza bien los datos, siempre es preferible a uno más complejo y con más parámetros)
- Muchas relaciones no lineales se pueden transformar en lineales
- En un intervalo de variación reducido, el cambio observado es “más o menos” lineal




Ajuste del modelo lineal. Método de mínimos cuadrados

Ajustar el modelo lineal quiere decir **estimar** cuánto valen sus parámetros: los dos coeficientes de la recta (a y b) y la varianza de regresión (o varianza residual)

¿Cuál de los dos es mejor modelo para caracterizar la relación entre las dos variables, A o B?



Criterio de mínimos cuadrados



$$\text{Residuo}_i = (\text{valor observado})_i - (\text{valor pronosticado por el modelo})_i$$

La mejor recta, en el sentido de ser la más “próxima” a todos los datos es aquella en la que la suma de residuos al cuadrado es la mínima posible. Es decir, $\hat{y} = a + b x$ es aquella que verifica que $\sum e_i^2 = \sum (y_i - \hat{y}_i)^2$ es el mínimo

Además de estimar los dos coeficientes del modelo, será necesario estimar la **varianza de regresión** S_R^2 , que es la varianza de los residuos y estima a la varianza del componente aleatorio ε

$$s_R^2 = \hat{\sigma}_\varepsilon^2$$

Ajuste del modelo lineal. Método de mínimos cuadrados

Cálculos necesarios en el método de mínimos cuadrados

#	IMC	% graso
1	20.36	17.36
2	20.34	12.72
3	20.05	11.65
4	23.07	17.81
5	23.94	19.34
6	27.45	29.70
7	22.17	24.19
8	24.37	15.26
9	22.18	28.41
10	17.30	8.87
11	21.72	25.62
12	19.29	20.91

$n = 12$

Para x

$$\sum x_i = 262.24$$

$$\sum x_i^2 = 5809.61$$

$$\bar{x} = 21.85$$

$$s_x^2 = 7.163 \quad (s_x = 2.676)$$

Para x e y : $\sum x_i y_i = 5186.48$

Para y

$$\sum y_i = 231.84$$

$$\sum y_i^2 = 4969.65$$

$$\bar{y} = 19.32$$


$$s_y^2 = 44.591 \quad (s_y = 6.678)$$

$$(xx) = \sum x_i^2 - \frac{(\sum x_i)^2}{n} = 78.79 \quad (= (n-1)s_x^2)$$

$$(yy) = \sum y_i^2 - \frac{(\sum y_i)^2}{n} = 490.50 \quad (= (n-1)s_y^2)$$

$$(xy) = \sum x_i y_i - \frac{\sum x_i \sum y_i}{n} = 120.01$$

* $s_{xy} = \frac{1}{n-1} \left(\sum x_i y_i - \frac{\sum x_i \sum y_i}{n} \right)$ es la **covarianza** entre x e y



Ajuste del modelo lineal. Método de mínimos cuadrados

Estimación de los coeficientes y de la varianza de regresión

#	IMC	% graso
1	20.36	17.36
2	20.34	12.72
3	20.05	11.65
4	23.07	17.81
5	23.94	19.34
6	27.45	29.70
7	22.17	24.19
8	24.37	15.26
9	22.18	28.41
10	17.30	8.87
11	21.72	25.62
12	19.29	20.91

$$n = 12$$

$$\sum x_i = 262.24$$

$$\sum y_i = 231.84$$

$$\sum x_i^2 = 5809.61$$

$$\sum y_i^2 = 4969.65$$

$$\sum x_i y_i = 5186.48$$

$$\bar{x} = 21.85$$

$$\bar{y} = 19.32$$

$$s_x^2 = 7.163$$

$$s_y^2 = 44.591$$

$$(xx) = 78.79$$

$$(yy) = 490.50$$

$$(xy) = 120.01$$

$$b = \frac{(xy)}{(xx)} = \frac{120.01}{78.79} = 1.523$$

$$\bar{y} = a + b \bar{x} \rightarrow a = \bar{y} - b \bar{x}$$

$$a = 19.32 - 1.52 \times 21.85 = -13.96$$

$$\hat{y} = a + b x$$

$$\hat{y} = -13.96 + 1.52 x$$


Modelo lineal estimado

Varianza de regresión

$$s_R^2 = \frac{1}{n-2} \left((yy) - \frac{(xy)^2}{(xx)} \right) = \frac{1}{12-2} \left(490.50 - \frac{120.01^2}{78.79} \right) = 30.773$$

o también:

$$s_R^2 = \frac{1}{n-2} ((yy) - b(xy)) = \frac{1}{12-2} (490.50 - 1.52 \cdot 120.01) = 30.773$$



¡Importante!

A la pregunta:

Se responde con:

(En cualquier caso, el paso preliminar es siempre el diagnóstico del diagrama de dispersión)

• ¿Cuál es la relación lineal entre x e y ?	—————>	Expresión del modelo ajustado : $\hat{y} = a + b x$
• ¿Es significativa la relación lineal entre x e y ?	—————>	Test de regresión lineal , o también Test de correlación lineal (en realidad son el mismo test)
• ¿Cuánto cambia y por unidad de aumento en x ?	—————>	IC para el coeficiente de regresión : $IC(\beta)$
• ¿Cuánto vale y para un valor dado de $x = x_0$?	—————>	Pronósticos sobre $y x=x_0$
• ¿Cuánto vale x para un valor dado de $y = y_0$?	—————>	ii Pronósticos sobre $x y=y_0$!!
• ¿Es intensa la asociación (lineal) entre x e y ?	—————>	Coeficiente de correlación lineal r
• ¿Son buenos los pronósticos realizados con el modelo de regresión lineal?	—————>	Coeficiente de determinación R^2

Inferencias con el modelo

Test de regresión lineal


¿Hay relación lineal entre x e y ?

Para el modelo $y = \beta_0 + \beta_1 x + \varepsilon$

Hipótesis $\begin{cases} H_0 : \beta_1 = 0 & \text{no hay asociación lineal (la recta es horizontal)} \\ H_1 : \beta_1 \neq 0 \end{cases}$

$$\text{Estadístico: } t_{\text{exp}} = \frac{|b|}{\sqrt{s_R^2/(xx)}} = \frac{|b|}{s_R} \sqrt{(xx)}$$

El nivel de significación p se busca en la distribución t-Student con $n-2$ g.l.



En el ejemplo: $t_{\text{exp}} = |1.52| \sqrt{\frac{78.79}{30.77}} = 2.437 \text{ (10 g.l.)} \longrightarrow 0.03 < p < 0.04$

Hay un cambio significativo en el % graso al cambiar el IMC

IC para el coeficiente de regresión

$$IC_{(1-\alpha)}(\beta_1) = b \pm t_{\alpha;n-2} \sqrt{\frac{s_R^2}{(xx)}}$$

¿Cuánto cambia y por unidad de aumento en x ?

Recuérdese que una vez hecho un t -test, el IC es inmediato:


IC = numerador de la $t_{\text{exp}} \pm t_{\alpha;n-2}$ denominador de la t_{exp}

(el numerador sin el valor absoluto)

En el ejemplo:

$$IC_{95\%}(\beta_1) = 1.523 \pm 2.228 \times 0.625 = (0.13; 2.92)$$


Por cada unidad de aumento en el IMC, el % graso aumenta ($b > 0$) un valor que debe ser mayor a 0.13 unidades y menor a 2.92 unidades con un 95% de probabilidad (confianza)




Inferencias con el modelo

Pronósticos

¿Cuánto vale y para un valor dado de $x = x_0$?



El peligro de las extrapolaciones



- Los pronósticos deben hacerse dentro del rango observado de la variable explicativa, es decir, deben tener carácter *interpolador*, nunca *extrapolador* (mas allá del rango observado no sabemos cómo es la relación entre las variables)
- Estimación puntual de un pronóstico: Para un valor $x = x_0$ tal que $x_{\min} \leq x_0 \leq x_{\max}$ el pronóstico dado por el modelo de regresión lineal, es
$$\hat{y} = a + b x_0$$
- **Intervalos de confianza.** Se puede hacer inferencia a dos niveles:
 - respecto a valores medios esperados $\rightarrow$ **bandas de confianza**
 - respecto a valores individuales $\rightarrow$ **intervalos de predicción**
- La precisión de estos pronósticos es mayor cuanto mayor sea la proximidad de x_0 a la media $\bar{x}$

Inferencias con el modelo

Pronósticos (continuación)


¿Cuánto vale y para un valor dado de $x = x_0$?

En el ejemplo, veamos diferentes situaciones:

- ¿Cuánto es el valor esperado del % graso para una persona de entre 15 y 19 años con un IMC=26?

La edad se encuentra en el rango observado

$$\text{IMC}_{\min} < 26 < \text{IMC}_{\max}$$



El modelo SI permite estimarlo


(solo damos la estimación puntual, pero sería procedente dar el intervalo de confianza)

$$\hat{y} = -13.96 + 1.52 \cdot x$$

$$\text{IMC} = -13.96 + 1.52 \times 26 = 25.56$$

- ¿Cuánto es el valor esperado del % graso para una persona de entre 30 años con un IMC=26?

La edad NO se encuentra en el rango observado




El modelo NO permite estimarlo

- ¿Cuánto es el valor esperado del % graso para una persona de entre 15 y 19 años con un IMC=32?

La edad se encuentra en el rango observado

$$32 > \text{IMC}_{\max}$$



El modelo NO permite estimarlo

Inferencias con el modelo

Pronósticos sobre x dado un valor de y

¿Cuánto vale x para un valor dado de $y = y_0$?

Que se pueda hacer o no depende del tipo de muestreo:

- **Si el muestreo es de tipo I** (las dos variables observadas)

Se trata de invertir el rol de las variables (como x e y son variables aleatorias se puede hacer)

Partiendo de: $(xx) = 78.79$ $(yy) = 490.50$ $(xy) = 120.01$ $\bar{x} = 21.85$ $\bar{y} = 19.32$

Regresión de y sobre x ($y|x$)

$$b = \frac{(xy)}{(xx)} = \frac{120.01}{78.79} = 1.523 \quad \bar{y} = a + b \bar{x} \rightarrow a = \bar{y} - b \bar{x} \quad a = 19.32 - 1.52 \times 21.85 = -13.96$$

$$\hat{y} = a + b x \rightarrow \hat{y} = -13.96 + 1.52 x$$

Regresión de x sobre y ($x|y$)

$$b' = \frac{(xy)}{(yy)} = \frac{120.01}{490.50} = 0.245 \quad \bar{x} = a' + b' \bar{y} \rightarrow a' = \bar{x} - b' \bar{y} \quad a' = 21.85 - 0.245 \times 19.32 = 17.12$$

$$\hat{x} = a' + b' y \rightarrow \hat{x} = 17.12 + 0.245 y$$

Como antes, la inferencia $\hat{x} = 17.12 + 0.245 y_0$

solo se puede hacer si $y_{\min} \leq y_0 \leq y_{\max}$

- **Si el muestreo es de tipo II** (los valores de la variable explicativa están fijados de antemano)

No se puede elaborar el modelo de regresión de $x|y$ (ahora x no es una variable aleatoria)

El problema se aborda mediante **calibración lineal** (no lo vemos aquí)

Correlación y correlación lineal

¿Es intensa la relación entre x e y ?

Se dice que entre dos variables (cuantitativas) hay **correlación** si hay **asociación**, es decir:

- Si valores altos (bajos) de una de las variables se acompañan con valores altos (bajos) de la otra. En este caso se dice que la **correlación** es **directa** o **positiva**
- Si valores altos (bajos) de una de las variables se acompañan de valores bajos (altos) de la otra. Ahora la **correlación** es **inversa** o **negativa**

Un **coeficiente de correlación** es un índice que mide la fuerza de asociación entre dos variables cuantitativas

En general se representa a estos coeficientes como:



- ρ (*rho* del alfabeto griego) para aludir a la fuerza de asociación **poblacional**
- r para aludir a su **estimador muestral**: $r = \hat{\rho}$

Coeficientes de correlación de Pearson y de Spearman

Si la asociación entre las variables es de tipo lineal, el coeficiente adecuado es el **coeficiente de correlación lineal de Pearson (ρ)**. Este coeficiente es el más habitual y se alude a él simplemente por r

Si la asociación entre las variables es de tipo no lineal pero monótonica (siempre creciente o decreciente, sin forma de U o de U invertida), el coeficiente anterior no es adecuado, pero puede calcularse el **coeficiente de correlación de Spearman (ρ_s)**

- Se alude a él como **coeficiente de correlación no paramétrico** (con frecuencia se usa cuando las variables no tienen distribución normal)
- **No veremos su cálculo**, aunque la interpretación se hace igual que la del coeficiente de Pearson (quitando ahora el calificativo *lineal*)



El coeficiente de Pearson no es válido aquí

Correlación lineal

¿Es intensa la relación lineal entre x e y ?








Valores posibles (válido para el coeficiente ρ_S de Spearman)

$$-1 \leq \rho \leq 1$$


De un coeficiente de correlación se debe interpretar:

(válido para el coeficiente ρ_S de Spearman eliminando la palabra *lineal*)

- Su signo $\left\{ \begin{array}{l} \rho > 0 \quad \text{Asociación lineal } \mathbf{positiva:} \text{ cuando } x \uparrow \Rightarrow y \uparrow \\ \rho < 0 \quad \text{Asociación lineal } \mathbf{negativa:} \text{ cuando } x \uparrow \Rightarrow y \downarrow \end{array} \right.$
- Su magnitud $\left\{ \begin{array}{l} |\rho| \rightarrow 0 \quad \text{Falta de asociación lineal} \\ |\rho| \rightarrow 1 \quad \text{Asociación lineal perfecta} \end{array} \right.$



La **falta de correlación lineal** no es lo mismo que la **independencia** (esta es una condición mucho más fuerte). La variable y no depende de x en **(a)** pero si en **(b)**, donde la dependencia es no lineal. En este último caso r no es un coeficiente válido.



Ni el coeficiente de correlación de Pearson ni el de Spearman son válidos aquí.

Correlación lineal


¿Es intensa la relación lineal entre x e y ?

Estimación (puntual):

$$\hat{\rho} = r \quad \text{con} \quad r = \frac{(xy)}{\sqrt{(xx)(yy)}}$$

El coeficiente de **correlación** tiene el mismo signo que el coeficiente de **regresión**: que es el signo de (xy) (el numerador de la covarianza)

En el ejemplo:



$$\begin{aligned} (xx) &= 78.79 \\ (yy) &= 490.50 \\ (xy) &= 120.01 \end{aligned} \quad r = \frac{120.01}{\sqrt{78.79 \times 490.50}} = 0.610$$

Test de correlación:

¿Hay relación lineal entre x e y ?; Este test es **equivalente** al test de regresión $H_0: \beta_1=0$

Hipótesis $\begin{cases} H_0 : \rho = 0 & \text{no hay asociación lineal (la recta de regresión es horizontal, es decir, } \beta_1=0) \\ H_1 : \rho \neq 0 \end{cases}$


Estadístico: $t_{\text{exp}} = \sqrt{\frac{(n-2)r^2}{1-r^2}}$ Se busca en la distribución t-Student con $n-2$ g.l.

En el ejemplo:

$$t_{\text{exp}} = \sqrt{\frac{(12-2)0.61^2}{1-0.61^2}} = 2.43 \quad (10 \text{ g.l.}) \longrightarrow 0.03 < p < 0.04$$

¿Es bueno el modelo de regresión a la hora de realizar pronósticos sobre y dado x ?

Se expresa como R^2 y se suele utilizar como un índice de la calidad de los pronósticos dados por la recta de regresión (se puede expresar en %) y habitualmente se considera como una medida de la calidad del ajuste dado por la recta de regresión



Variabilidad total de y : $VT = VE + VNE$

$R^2 = \frac{VE}{VT}$ El **coeficiente de determinación** es la proporción de variabilidad observada en y que queda explicada por su relación lineal con x


En la práctica se puede calcular como el cuadrado del coeficiente de correlación lineal: $R^2 = (r)^2$

En el ejemplo: $R^2 = (0.610)^2 = 0.373 \rightarrow$ El 37.3% de la variabilidad observada en el porcentaje graso viene determinada (o explicada) por su relación lineal con el IMC. El 100–37.3=62.7% restante es variabilidad no explicada

Comentarios finales

En la práctica, lo habitual es que en el análisis participen más de dos variables

Diagrama de dispersión matricial



Matriz de correlaciones

		IMC	% GRASO	colesterol total	pliegue abdominal (mm)
índice de masa corporal (kg/m²)	Correlación de Pearson	1	,610*	,163	,654*
	Sig. (bilateral)		,035	,613	,021
	N	12	12	12	12
% GRASO (DURNIN & WOMERSLEY, 1974)	Correlación de Pearson	,610*	1	-,143	,943**
	Sig. (bilateral)	,035		,658	,000
	N	12	12	12	12
colesterol total	Correlación de Pearson	,163	-,143	1	,095
	Sig. (bilateral)	,613	,658		,768
	N	12	12	12	12
pliegue abdominal (mm)	Correlación de Pearson	,654*	,943**	,095	1
	Sig. (bilateral)	,021	,000	,768	
	N	12	12	12	12

*. La correlación es significativa al nivel 0,05 (bilateral).

** La correlación es significativa al nivel 0,01 (bilateral).

La correlación de una variable consigo misma es, lógicamente, $r=1$

$$\hat{y} = b_0 + b_1 x_1$$

Modelo de regresión lineal simple (solo hay una variable explicativa)

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_k x_k$$

Modelo de regresión lineal múltiple (hay un conjunto de k variables explicativas o regresoras)

oOo

Fin de la asignatura