

Probabilidad y Variables Aleatorias con R

Tema II (Parte I) — Fundamentos de Probabilidad y Variables Aleatorias

Miguel Angel Luque-Fernández

2026-01-01

Probabilidad y Variables Aleatorias



UNIVERSIDAD
DE GRANADA

Grado en Fisioterapia

CC BY 4.0 · Miguel Angel Luque-Fernández

Miguel Angel Luque-Fernández · maluque.netlify.app

Dpto. Estadística e Investigación Operativa · Universidad de Granada

De la descripción al modelo

Conexión T01→T02: En el Tema 1 aprendiste a **describir** una muestra (tablas, gráficos, estadísticos). Ahora damos el salto a **modelar** la población: necesitamos un lenguaje para cuantificar la incertidumbre y la variabilidad. Ese lenguaje es la **probabilidad**.

T01 — Descriptiva	→	T02 — Probabilidad
Resumir lo observado	→	Modelar lo no observado
$\bar{x}$, s , histograma	→	$P(A)$, distribuciones, densidad
«¿Cómo son mis datos?»	→	«¿Qué modelo siguen mis datos?»

Objetivos de aprendizaje — Tema 2



Tip

Al finalizar este tema sabrás:

1. Distinguir los enfoques frecuentista, axiomático y bayesiano de la probabilidad
2. Aplicar las reglas básicas: complemento, unión, intersección, probabilidad condicional
3. Usar el Teorema de Bayes para actualizar diagnósticos clínicos
4. Identificar qué distribución (Normal, Binomial, Poisson) modela cada situación clínica
5. Calcular probabilidades con `pnorm()`, `pbinom()`, `ppois()` y sus equivalentes BioEstatR
6. Interpretar Z-scores para comparar mediciones de distintos pacientes

Las tres caras de la probabilidad — Frecuentista, axiomática y Bayesiana

Tres enfoques complementarios para definir la probabilidad:

Enfoque	Definición	Fundador(es)	Uso en Fisioterapia
Frecuentista	$P(A) = \lim_{n \rightarrow \infty} n_A/n$	von Mises, Fisher	Estimar tasas de recuperación poblacionales
Axiomática	P satisface 3 axiomas (Kolmogorov 1933)	Kolmogorov	Base matemática de TODA la estadística
Bayesiana	$P(A B) = \frac{P(B A)P(A)}{P(B)}$	Bayes, Laplace	Actualizar diagnósticos con evidencia clínica

Relación entre los tres enfoques: - El enfoque **frecuentista** define probabilidad como frecuencia relativa a largo plazo $\rightarrow P(A) = \lim_{n \rightarrow \infty} n_A/n$ - Kolmogorov demostró que esta definición satisface los **axiomas** de la teoría de la probabilidad $\rightarrow$ base matemática rigurosa - El enfoque **bayesiano** usa esos mismos axiomas pero interpreta $P(A)$ como grado de creencia, actualizable con el Teorema de Bayes

En Fisioterapia: usamos el enfoque frecuentista para estudios poblacionales, el bayesiano para razonamiento clínico, y ambos descansan sobre los axiomas de Kolmogorov.

Introducción a la probabilidad

- La probabilidad es una **medida numérica** de la posibilidad de que ocurra un evento
- Se denota como $P(A)$, donde A es el evento
- Se expresa como un número entre **0** (imposibilidad) y **1** (certeza)
- El enfoque **frecuentista**: $P(A)$ es el límite de la frecuencia relativa cuando $n \rightarrow \infty$

¿Por Qué Necesito la Probabilidad como Fisioterapeuta?

Cada día tomas decisiones bajo incertidumbre:

- Un paciente con lumbalgia: ¿probabilidad de que mejore con ejercicio terapéutico?
- Un test de Lasegue positivo: ¿probabilidad de que realmente tenga hernia discal?
- Lees un artículo: “El tratamiento A es significativamente mejor que B ($P = 0.03$)”. ¿Es fiable?

La probabilidad te da las herramientas para:

- **Cuantificar** la incertidumbre clínica
- **Actualizar** tus creencias con nueva evidencia (Bayes)
- **Interpretar** críticamente la literatura científica
- **Comunicar** riesgos a tus pacientes de forma comprensible

“La estadística es el arte de tomar decisiones en presencia de incertidumbre.” — Stephen Senn

Experimento aleatorio: Proceso que puede repetirse bajo condiciones idénticas, tiene al menos dos resultados posibles, y cuyo resultado no puede predecirse con certeza.

Espacio muestral (Ω): Conjunto de todos los resultados posibles.

Evento (A): Subconjunto del espacio muestral.

Concepto frecuentista de probabilidad y regla de Laplace

Enfoque frecuentista:

$$P(A) = \lim_{n \rightarrow \infty} \frac{n_A}{n}$$

Regla de Laplace (resultados equiprobables):

$$P(A) = \frac{\text{casos favorables}}{\text{casos posibles}}$$

Ejemplo — Dado de 6 caras:

$$P(3) = 1/6 \quad P(\text{par}) = 3/6 = 1/2 \quad P(> 4) = 2/6$$

```
P_3 <- 1/6; P_par <- 3/6; P_mayor_4 <- 2/6
cat("P(3) =", P_3, "\nP(par) =", P_par, "\nP(>4) =", P_mayor_4)
```

$$P(3) = 0.1666667$$

$$P(\text{par}) = 0.5$$


$$P(>4) = 0.3333333$$

Ley de los grandes números

La frecuencia relativa converge a la probabilidad teórica cuando $n \rightarrow \infty$.

Simulación: Aleatorización de pacientes a Fisioterapia Manual (FM) vs Ejercicio Terapéutico (ET).

```
set.seed(123)
par(mfrow=c(2,3), mar=c(3,3,2,1))
for(n in c(10, 100, 500, 1000, 5000, 10000)){
  assign <- rbinom(n, 1, 0.5)
  plot(cumsum(assign)/(1:n), type="l", col="steelblue", ylim=c(0,1),
       main=paste("n =",n), xlab="Ensayos", ylab="Proporción FM")
  abline(h=0.5, col="darkgreen", lty=2)
}
```



```
par(mfrow=c(1,1))
```

Axiomas de Kolmogorov (1933)

1. **No negatividad:** $P(A) \geq 0$ para todo evento A
2. **Normalización:** $P(\Omega) = 1$
3. **Aditividad:** Si $A_1, A_2, \dots$ son mutuamente excluyentes: $P(\bigcup_i A_i) = \sum_i P(A_i)$

💡 Tip

¿Qué significa esto? Los tres axiomas son el “contrato” mínimo que debe cumplir cualquier probabilidad. Todo lo demás (complemento, unión, Bayes...) se deduce de ellos. No necesitas memorizarlos — solo entender que son la base lógica de todo lo que sigue.

Ejemplo clínico — Diagnósticos excluyentes en consulta de fisioterapia:

Diagnóstico	Frecuencia	Probabilidad
Lumbalgia	40	0.40
Cervicalgia	35	0.35
Omalgia	25	0.25
Total	100	1.00

$$\sum_i P(A_i) = 0.40 + 0.35 + 0.25 = 1.00$$

i Note

Consecuencias algebraicas de los axiomas

De los tres axiomas se deducen **todas** las reglas de la probabilidad:

De los axiomas a las propiedades

Regla	Fórmula	Derivación
Complemento	$P(\bar{A}) = 1 - P(A)$	$A \cup \bar{A} = \Omega, A \cap \bar{A} = \emptyset$ $P(A) + P(\bar{A}) = P(\Omega) = 1$
Probabilidad del vacío	$P(\emptyset) = 0$	$\emptyset = \bar{\Omega} \quad P(\emptyset) = 1 - P(\Omega) = 0$
Cota superior	$P(A) \leq 1$	$P(A) = 1 - P(\bar{A}) \leq 1$ pues $P(\bar{A}) \geq 0$
Unión general	$P(A \cup B) =$ $P(A) + P(B) - P(A \cap B)$	Partición: $A \cup B = A \cup (B \cap \bar{A})$, con A y $B \cap \bar{A}$ excluyentes

💡 Tip

¿Por qué importa esto? No necesitas memorizar las derivaciones — solo saber que TODO en probabilidad (complemento, unión, Bayes, distribuciones) se deduce lógicamente de estos tres axiomas. Son el “ADN” de la estadística.

Complemento

En clínica, a menudo es más fácil calcular la probabilidad de que algo NO ocurra. La regla del complemento nos permite obtener una probabilidad a partir de la otra.

$$P(\bar{A}) = 1 - P(A)$$

Ejemplo clínico: El 30% de pacientes en consulta de fisioterapia tienen HTA.

$$P(\text{HTA}) = 0.30 \Rightarrow P(\text{no HTA}) = 1 - 0.30 = 0.70$$

```
cat("P(no HTA) =", 1 - 0.30, "→ El 70% no presentan HTA")
```

P(no HTA) = 0.7 → El 70% no presentan HTA

Unión de eventos — Regla de la suma

Cuando nos preguntamos por la probabilidad de que ocurra al menos uno de varios eventos clínicos, necesitamos la regla de la suma.

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$


Ejemplo clínico — Comorbilidad en 100 pacientes de fisioterapia:

40 con HTA, 30 con Diabetes tipo 2, 10 con ambas condiciones.

```
par(mar=c(2,2,2,2))
plot(NA, xlim=c(-2.2,2.2), ylim=c(-1.8,1.8), axes=F, xlab="", ylab="",
     main="Diagrama de Venn: Comorbilidad HTA y DM")
theta <- seq(0, 2*pi, length=200)
polygon(-0.4+1.3*cos(theta), 1.3*sin(theta), col=rgb(0,0,1,0.2), border="steelblue", lwd=2)
polygon( 0.4+1.3*cos(theta), 1.3*sin(theta), col=rgb(0,0.5,0.3,0.2), border="coral", lwd=2)
text(-1, 0.3, "HTA\n(30 solo)", col="steelblue", font=2, cex=0.9)
```

```
text( 1, 0.3, "DM\n(20 solo)", col="darkgreen", font=2, cex=0.9)
text( 0,-0.3, "Ambas\n(10)", font=2, cex=0.9)
text(-2, -1.5, "P(HTA DM) = 0.40+0.30-0.10 = 0.60", pos=4, cex=0.85)
```

Diagrama de Venn: Comorbilidad HTA y DM



$$P(\text{HTA} \cup \text{DM}) = 0.40 + 0.30 - 0.10 = 0.60$$

$$P(\text{HTA} \cup \text{DM}) = \frac{40}{100} + \frac{30}{100} - \frac{10}{100} = 0.60$$

```
cat("P(HTA  DM) =", 40/100 + 30/100 - 10/100, "→ 60 pacientes")
```

$P(\text{HTA} \cup \text{DM}) = 0.6 \rightarrow 60 \text{ pacientes}$

Diagramas de Venn — Complemento, unión e intersección

```
par(mfrow=c(1,3), mar=c(2.5, 3, 3.5, 1))
theta <- seq(0, 2*pi, length=400)

# arcos para la lente de intersección
a <- acos(0.35)
ang_r <- seq(pi-a, pi+a, length=200)
ang_l <- seq(-a, a, length=200)

# símbolos y fuente Unicode
U <- intToUtf8(8746)
I <- intToUtf8(8745)
par(family = "") # fuente del sistema por defecto

# Panel 1: COMPLEMENTO
plot(NA, xlim=c(-1.5,1.5), ylim=c(-1.5,1.5), axes=F, xlab="", ylab="",
     main=bquote(bold("Complemento:") ~ P(bar(A)) == 1 - P(A)),
     cex.main=1.05)
rect(-1.5, -1.5, 1.5, 1.5, col=rgb(0.18,0.53,0.76,0.22), border="#2c3e50", lwd=2.5)
polygon(cos(theta), sin(theta), col="white", border="#2e86c1", lwd=3.5)
text(0, 0, "A", cex=2.5, font=2, col="#2e86c1")
text(1.3, 1.25, expression(bar(A)), cex=1.8, col="#2e86c1", font=2)
text(0, -1.45, "P( $\bar{A}$ ) = zona coloreada fuera de A", cex=0.75, col="grey40")

# Panel 2: UNIÓN - todo verde (círculos + intersección)
plot(NA, xlim=c(-1.5,1.5), ylim=c(-1.5,1.5), axes=F, xlab="", ylab="",
     main=bquote(bold("Union:") ~ P(A * .(U) * B) == P(A) + P(B) - P(A * .(I) * B)),
     cex.main=1.05)
polygon(-0.35+cos(theta), sin(theta), col=rgb(0.12,0.52,0.29,0.50), border="#1e8449", lwd=3)
polygon( 0.35+cos(theta), sin(theta), col=rgb(0.12,0.52,0.29,0.50), border="#1e8449", lwd=3)
text(-0.85, 0, "A", cex=2, font=2, col="#1e8449")
text( 0.85, 0, "B", cex=2, font=2, col="#1e8449")
text(0, -1.45, bquote(P(A * .(U) * B) == " toda la zona verde"), cex=0.75, col="grey40")

# Panel 3: INTERSECCIÓN
plot(NA, xlim=c(-1.5,1.5), ylim=c(-1.5,1.5), axes=F, xlab="", ylab="",
     main=bquote(bold("Intersección:") ~ P(A * .(I) * B)),
     cex.main=1.05)
polygon(-0.35+cos(theta), sin(theta), col="white", border="#2c3e50", lwd=2.5)
polygon( 0.35+cos(theta), sin(theta), col="white", border="#2c3e50", lwd=2.5)
text(-0.85, 0, "A", cex=2, font=2, col="#2c3e50")
```






```

text( 0.85, 0, "B", cex=2, font=2, col="#2c3e50")
polygon(c(0.35+cos(ang_r), -0.35+cos(ang_l)),
        c(sin(ang_r), sin(ang_l)),
        col=rgb(0.80,0.18,0.15,0.90), border=NA)
text(0, 0.2, bquote(A * .(I) * B), cex=1.4, font=2, col="white")
text(0, -1.45, bquote(P(A * .(I) * B) == " solo zona roja"), cex=0.75, col="grey40")

```

Complemento: $P(\bar{A}) = 1 - P(A)$ **Union:** $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Intersección: $P(A \cap B)$



```

par(mfrow=c(1,1))

```

💡 Tip

Para el estudiante: $\cup$ = unión = **O** (A o B ocurre, o ambos). $\cap$ = intersección = **Y** (A y B ocurren simultáneamente). El complemento $\bar{A}$ = todo lo que **NO** es A. En la figura: **azul** = complemento $\bar{A}$, **verde** = unión $A \cup B$, **rojo** = intersección $A \cap B$.

Inclusión-exclusión para tres eventos

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$$

Ejemplo clínico — Tres comorbilidades (n=100 pacientes de fisioterapia):

Condición	n	Intersecciones	n
HTA (A)	40	$A \cap B$	10
DM (B)	30	$A \cap C$	8
Obesidad (C)	20	$B \cap C$	5
		$A \cap B \cap C$	3

$$|A \cup B \cup C| = 40 + 30 + 20 - (10 + 8 + 5) + 3 = 90 - 23 + 3 = 70$$

70 de cada 100 pacientes presentan al menos una de las tres condiciones.


Probabilidad condicional — Visualización con diagrama de Venn

Recuperación de lumbalgia según sexo (n=200):


```
par(mfrow=c(1,2), mar=c(2,3,3,2))
# Panel 1: P(Recuperado | Mujer)
plot(NA, xlim=c(-1.5,1.5), ylim=c(-1.5,1.5), axes=F, xlab="", ylab="",
     main="P(Recuperado | Mujer)")
# Espacio muestral: solo mujeres (120)
rect(-1.5,-1.5,1.5,1.5, col=rgb(1,0.7,0.7,0.3), border="pink", lwd=2)
text(0,1.3,"Mujeres (120)",col="darkgreen",font=2,cex=1.1)
# Recuperadas: 72
theta <- seq(0,2*pi,length=200)
polygon(0.6*cos(theta), 0.6*sin(theta), col=rgb(0,0.6,0,0.4), border="darkgreen", lwd=2)
text(0,0,"Recuperadas\n72/120\n= 60%",font=2,cex=1,col="darkgreen")
```

```
# Panel 2: P(Recuperado | Hombre)
plot(NA, xlim=c(-1.5,1.5), ylim=c(-1.5,1.5), axes=F, xlab="", ylab="",
     main="P(Recuperado | Hombre)")
rect(-1.5,-1.5,1.5,1.5, col=rgb(0.7,0.7,1,0.3), border="steelblue", lwd=2)
text(0,1.3,"Hombres (80)",col="steelblue",font=2,cex=1.1)
polygon(0.6*cos(theta), 0.6*sin(theta), col=rgb(0,0.6,0,0.4), border="darkgreen", lwd=2)
text(0,0,"Recuperados\n32/80\n= 40%",font=2,cex=1,col="darkgreen")
```

P(Recuperado | Mujer)



P(Recuperado | Hombre)



```
par(mfrow=c(1,1))
```

La probabilidad condicional reduce el espacio muestral al subconjunto condicional.

Probabilidad condicional

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

Ejemplo clínico — Recuperación de lumbalgia según sexo (n=200):

	Recuperado (R)	No recuperado	Total
Mujer	72	48	120
Hombre	32	48	80
Total	104	96	200

$$P(R \mid \text{Mujer}) = \frac{72/200}{120/200} = \frac{72}{120} = 0.60$$

$$P(R \mid \text{Hombre}) = \frac{32/200}{80/200} = \frac{32}{80} = 0.40$$

```
cat("P(Recuperado | Mujer) =", 72/120,  
    "\nP(Recuperado | Hombre) =", 32/80)
```

$P(\text{Recuperado} \mid \text{Mujer}) = 0.6$

$P(\text{Recuperado} \mid \text{Hombre}) = 0.4$

Independencia de eventos

Cuando dos eventos no se influyen mutuamente, podemos simplificar los cálculos. Pero necesitamos un criterio formal para determinarlo.

A y B son **independientes** si $P(A \cap B) = P(A) \cdot P(B)$, o equivalentemente si $P(A \mid B) = P(A)$.

Ejemplo clínico — Ejercicio Terapéutico y Mejoría (n=100):

	Mejoría (M)	No mejoría	Total
Ejercicio (E)	30	20	50
Sin ejercicio	20	30	50
Total	50	50	100

$$P(M) = 50/100 = 0.50 \quad P(M \mid E) = 30/50 = 0.60$$

$P(M \mid E) = 0.60 \neq 0.50 = P(M) \rightarrow$ **NO son independientes.** El ejercicio terapéutico está **asociado** con la mejoría.

Probabilidad total — Visualización: Partición del espacio muestral

El espacio muestral Ω se **particiona** en B_1, B_2, B_3 (excluyentes, $\cup B_i = \Omega$). El evento A se distribuye a través de todas las particiones:

$$P(A) = P(A \mid B_1) \cdot P(B_1) + P(A \mid B_2) \cdot P(B_2) + P(A \mid B_3) \cdot P(B_3)$$

```
par(mar=c(3, 2, 5, 2), bg="white")
plot(NA, xlim=c(-0.5, 16.5), ylim=c(-0.8, 11), axes=F, xlab="", ylab="",
     main="Teorema de la Probabilidad Total - Partición de  $\Omega$  y Evento A")

# colores verde-azul
col_0_fill <- "#f8fafb"
col_0_bord <- "#1a3a4a"
col_B1_fill <- rgb(0.35, 0.75, 0.55, 0.30) # verde suave
col_B1_bord <- "#1e6e3e"
col_B2_fill <- rgb(0.30, 0.68, 0.75, 0.30) # verde-azulado
col_B2_bord <- "#1a5c6e"
col_B3_fill <- rgb(0.25, 0.50, 0.80, 0.30) # azul medio
col_B3_bord <- "#1a4070"
col_A_fill <- rgb(0.15, 0.35, 0.60, 0.25) # azul profundo semitransparente
col_A_bord <- "#0f2a4a"
col_lbl <- "#0d3b66"

#  $\Omega$  - rectángulo exterior
xL <- 0.5; xR <- 15.5; yB <- 0.3; yT <- 10.0
rect(xL, yB, xR, yT, col=col_0_fill, border=col_0_bord, lwd=4)
text(1.2, yT - 0.25, expression(Omega), cex=2.0, font=2, col=col_0_bord)

# Particiones (60%, 30%, 10% del ancho de  $\Omega$ )
w <- xR - xL
b1r <- xL + w * 0.60
b2r <- b1r + w * 0.30

rect(xL, yB, b1r, yT, col=col_B1_fill, border=col_B1_bord, lwd=3)
text(xL + w*0.30, yT - 0.25, expression(B[1]), cex=1.6, col=col_B1_bord, font=2)
text(xL + w*0.30, yT - 0.65, "(Bajo riesgo, 60%)", cex=1.2, col=col_B1_bord)

rect(b1r, yB, b2r, yT, col=col_B2_fill, border=col_B2_bord, lwd=3)
text(b1r + w*0.15, yT - 0.25, expression(B[2]), cex=1.6, col=col_B2_bord, font=2)
text(b1r + w*0.15, yT - 0.65, "(Moderado, 30%)", cex=1.2, col=col_B2_bord)
```

```

rect(b2r, yB, xR, yT, col=col_B3_fill, border=col_B3_bord, lwd=3)
text(b2r + w*0.05, yT - 0.25, expression(B[3]), cex=1.5, col=col_B3_bord, font=2)
text(b2r + w*0.05, yT - 0.65, "(Alto, 10%)", cex=1.1, col=col_B3_bord)

# Evento A - elipse dentro de  $\Omega$  que cubre las 3 particiones
theta <- seq(0, 2*pi, length=300)
cx <- (xL + xR) / 2; cy <- (yB + yT) / 2
rx <- w * 0.47; ry <- (yT - yB) * 0.43
x_ell <- cx + rx*cos(theta)
y_ell <- cy + ry*sin(theta)
polygon(x_ell, y_ell, col=col_A_fill, border=col_A_bord, lwd=4)
text(cx, cy, "Evento A\n(Recuperación)", cex=1.3, col=col_A_bord, font=2)

# Etiquetas: intersecciones y probabilidades condicionadas
text(xL + w*0.30, cy + 0.9, expression(A * " " * B[1] * ":"), cex=1.25, col=col_A_bord, font=2)
text(xL + w*0.30, cy - 0.6, expression(P(A * "|" * B[1]) == 0.90), cex=1.2, col=col_lbl)


text(b1r + w*0.15, cy + 0.9, expression(A * " " * B[2] * ":"), cex=1.25, col=col_A_bord, font=2)
text(b1r + w*0.15, cy - 0.6, expression(P(A * "|" * B[2]) == 0.70), cex=1.2, col=col_lbl)

text(b2r + w*0.05, cy + 0.9, expression(A * " " * B[3] * ":"), cex=1.15, col=col_A_bord, font=2)
text(b2r + w*0.05, cy - 0.6, expression(P(A * "|" * B[3]) == 0.40), cex=1.15, col=col_lbl)

# Fórmula de probabilidad total (debajo de  $\Omega$ )
text((xL + xR)/2, yB - 0.35,
      expression(P(A) == P(A * "|" * B[1]) * " . " * P(B[1]) ~+~
                  P(A * "|" * B[2]) * " . " * P(B[2]) ~+~
                  P(A * "|" * B[3]) * " . " * P(B[3])),
      cex=1.4, col=col_A_bord, font=2)
text((xL + xR)/2, yB - 0.8,
      "P(Recuperación) = 0.90 × 0.60 + 0.70 × 0.30 + 0.40 × 0.10 = 0.79",
      cex=1.25, font=2, col=col_A_bord)

```

Teorema de la Probabilidad Total — Partición de Ω y Evento A



Probabilidad total — Ejemplo: Recuperación en fisioterapia


Contexto clínico: Tres grupos de riesgo en rehabilitación de lumbalgia:

Grupo de riesgo	$P(B_i)$	$P(R B_i)$	Aporte $P(R B_i) \cdot P(B_i)$
Bajo (sin comorbilidades)	0.60	0.90	0.54
Moderado (una comorbilidad)	0.30	0.70	0.21
Alto (múltiples comorbilidades)	0.10	0.40	0.04
Total	1.00		$P(R) = 0.79$

```

aporte <- c(0.54, 0.21, 0.04)
names(aporte) <- c("Bajo\n(0.60×0.90)", "Moderado\n(0.30×0.70)", "Alto\n(0.10×0.40)")
bp <- barplot(aporte, col=c("darkgreen","gold","coral"),
              main="Aportes a P(Recuperación) = 0.79",
              ylab="Probabilidad", ylim=c(0,0.6))
text(bp, aporte+0.02, aporte, font=2, cex=1.2)
abline(h=0.79, col="steelblue", lwd=2, lty=2)

```



```
cat("P(Recuperación) =", 0.6*0.9+0.3*0.7+0.1*0.4, "→ 79% de los pacientes se recuperan")
```

$P(\text{Recuperación}) = 0.79 \rightarrow 79\%$ de los pacientes se recuperan

Teorema de la probabilidad total

! Important

Si $B_1, B_2, \dots, B_k$ son **mutuamente excluyentes** y cubren todo el espacio muestral ($\cup_i B_i = \Omega$), entonces para cualquier evento A :

$$P(A) = \sum_{i=1}^k P(A | B_i) \cdot P(B_i)$$

La probabilidad total es la **suma ponderada** de las probabilidades condicionadas a cada estrato, usando como pesos las proporciones de cada estrato en la población.

Teorema de Bayes

! Important

Permite **actualizar** la probabilidad de una hipótesis A con nueva evidencia B :

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$

Usando Probabilidad Total en el denominador:

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B | A) \cdot P(A) + P(B | NoA) \cdot P(NoA)}$$

- $P(A)$: probabilidad **a priori** (antes de observar B)
- $P(B | A)$: **verosimilitud** de observar B si A es cierta
- $P(A | B)$: probabilidad **a posteriori** (actualizada con B)
- $P(B)$: probabilidad total de B (normalizador)

Bayes — Ejemplo: Test diagnóstico

Enunciado: Prevalencia de enfermedad $P(D) = 0.01$ (1%). Test con sensibilidad $P(+ | D) = 0.99$ (99%) y especificidad $P(- | NoD) = 0.95$ (95%).

Si una persona da positivo, ¿probabilidad de que tenga la enfermedad?

Paso 1 — Probabilidad total de dar positivo:

$$P(+) = P(+ | D) \cdot P(D) + P(+ | NoD) \cdot P(NoD)$$

$$P(+) = 0.99 \times 0.01 + 0.05 \times 0.99 = 0.0099 + 0.0495 = 0.0594$$

Paso 2 — Aplicar Bayes:


$$P(D | +) = \frac{P(+ | D) \cdot P(D)}{P(+)} = \frac{0.99 \times 0.01}{0.0594} = \frac{0.0099}{0.0594} = 0.1667$$

```
P_D <- 0.01; P_NoD <- 0.99
P_Pos_given_D <- 0.99; P_Pos_given_NoD <- 0.05
P_Pos <- (P_Pos_given_D * P_D) + (P_Pos_given_NoD * P_NoD)
P_D_given_Pos <- (P_Pos_given_D * P_D) / P_Pos
cat("P(+)      =", round(P_Pos, 4),
    "\nP(D | +) =", round(P_D_given_Pos, 4),
    "\n→ Solo el 16.7% de los positivos tienen la enfermedad")
```

```
P(+)      = 0.0594
P(D | +) = 0.1667
→ Solo el 16.7% de los positivos tienen la enfermedad
```

```
# Visualización: matriz de confusión
par(mfrow=c(1,2), mar=c(4,4,3,1))
# Panel 1: Barras de composición del test
vp <- P_Pos_given_D * P_D; fp <- P_Pos_given_NoD * P_NoD
vn <- (1-P_Pos_given_NoD) * P_NoD; fn <- (1-P_Pos_given_D) * P_D
m <- matrix(c(vp, fp, vn, fn), 2, dimnames=list(
  c("D+ (Enfermo)", "D- (Sano)"), c("Test +", "Test -")))
barplot(m, beside=TRUE, col=c("coral", "steelblue"),
  main=paste0("VPP=", round(vp/(vp+fp)*100,1), "% VPN=", round(vn/(vn+fn)*100,1), "%"),
  ylab="Probabilidad", ylim=c(0,0.9))
legend("topright", c("Enfermo", "Sano"), fill=c("coral", "steelblue"), bty="n", cex=0.8)
# Panel 2: Árbol simplificado
plot(NA, xlim=c(0,10), ylim=c(0,10), axes=F, xlab="", ylab="",
  main="Árbol de decisión diagnóstica")
text(5, 9.5, "Paciente", font=2, cex=1.2)
arrows(5, 9, 2.5, 7, lwd=2, col="coral")
arrows(5, 9, 7.5, 7, lwd=2, col="steelblue")
text(2.5, 8, paste0("D+ (", P_D*100, "%)"), col="coral", font=2)
text(7.5, 8, paste0("D- (", P_NoD*100, "%)"), col="steelblue", font=2)
rect(1, 3, 4, 6, col=rgb(1,0,0,0.1), border="coral")
text(2.5, 4.5, paste0("VPP\n", round(vp/(vp+fp)*100,1), "%"), font=2, cex=0.8)
rect(6, 3, 9, 6, col=rgb(0,0,1,0.1), border="steelblue")
text(7.5, 4.5, paste0("VPN\n", round(vn/(vn+fn)*100,1), "%"), font=2, cex=0.8)
```

VPP=16.7% VPN=100% Árbol de decisión diagnós



```
par(mfrow=c(1,1))
```

Warning

A pesar de la alta sensibilidad (99%), el VPP es solo **16.7%** porque la **baja prevalencia** (1%) hace que los falsos positivos dominen: $P(+ | NoD) \times P(NoD) = 0.0495 > P(+ | D) \times P(D) = 0.0099$.

Si $P(Recuperado | Mujer) = 60\%$ y $P(Recuperado | Hombre) = 40\%$, ¿significa esto que el sexo causa la diferencia en recuperación? ¿Qué otra explicación podría haber?

En el ejemplo, $P(M | E) = 0.60$ y $P(M) = 0.50$. ¿Qué necesitarías cambiar en la tabla para que Ejercicio y Mejoría fueran independientes?

Teorema de Bayes — Perspectiva histórica

Thomas Bayes (1701–1761)

- Ministro presbiteriano y matemático inglés en Tunbridge Wells
- Su ensayo “*An Essay towards solving a Problem in the Doctrine of Chances*” fue publicado **póstumamente en 1763** por su amigo Richard Price
- Bayes abordó el problema inverso: conocidos los resultados, ¿cuál es la probabilidad de sus causas?

Pierre-Simon Laplace (1749–1827)

- Redescubrió y generalizó el teorema de forma independiente (1774, 1812)
- Lo aplicó a problemas astronómicos, demográficos y jurídicos
- Formuló la versión moderna que usamos hoy con probabilidad total en el denominador

Note

Ironía histórica: Bayes nunca publicó su teorema en vida. Hoy lleva su nombre una rama entera de la estadística que él nunca imaginó.

Tip

Dato clave: Laplace aplicó el teorema de Bayes para estimar la masa de Saturno y la población de Francia, mostrando que la inferencia probabilística inversa funciona tanto para el cosmos como para los censos.

Del teorema de Bayes a la estadística Bayesiana

Important

El teorema de Bayes es la **piedra angular** de la estadística bayesiana: un paradigma donde la probabilidad representa **grado de creencia** (incertidumbre subjetiva), y no solo frecuencia a largo plazo.

El flujo bayesiano:

$$\underbrace{P(\theta)}_{\text{Distribución a priori}} \times \underbrace{P(\text{datos} \mid \theta)}_{\text{Verosimilitud}} \propto \underbrace{P(\theta \mid \text{datos})}_{\text{Distribución a posteriori}}$$

Concepto	Enfoque Frecuentista	Enfoque Bayesiano
Parámetro θ	Fijo, desconocido	Variable aleatoria
Probabilidad	Frecuencia a largo plazo	Grado de creencia
Inferencia	Estimadores, IC, p-valores	Distribución a posteriori, intervalos creíbles
Información previa	No se incorpora formalmente	Se modela explícitamente con la <i>priori</i>
Interpretación IC	“El 95% de los IC contienen θ ”	“Hay 95% de probabilidad de que θ esté en el intervalo”

En Fisioterapia: La estadística bayesiana permite actualizar probabilidades diagnósticas con cada nueva prueba o signo clínico — el razonamiento clínico es inherentemente bayesiano.

El test tiene 99% de sensibilidad pero el VPP es solo 16.7%. ¿Qué cambiaría si la prevalencia fuera del 10% en lugar del 1%?

De la Probabilidad a las Variables Aleatorias

Conexión: Hasta ahora hemos cuantificado la incertidumbre de eventos clínicos mediante reglas de probabilidad. Las variables aleatorias nos permiten modelizar esa incertidumbre matemáticamente, asignando números a los resultados y describiendo su distribución.

Respiro visual — Incertidumbre en la práctica clínica



Figure 1: Fisioterapeuta evaluando a un paciente

Cada paciente es único. La probabilidad nos da el lenguaje para cuantificar la incertidumbre clínica y tomar decisiones informadas.

De la Probabilidad a las Variables Aleatorias

Hasta aquí hemos modelado **eventos** (A, B, intersecciones, condicionales). Ahora damos el salto a modelar **variables**: magnitudes clínicas que varían de paciente a paciente. Una variable aleatoria asigna un número a cada resultado incierto.

En T01 (Descriptiva)	En T02 (Probabilidad)
$\bar{x}$ — media muestral	$\mu = E(X)$ — esperanza poblacional
s^2 — varianza muestral	$\sigma^2 = \text{Var}(X)$ — varianza poblacional
s — desviación típica muestral	$\sigma = \text{SD}(X)$ — desviación típica poblacional
$\hat{p}$ — proporción muestral	$p = P(X \in A)$ — probabilidad poblacional
Describías tu muestra	Modelas la población

Variable aleatoria — Definición

Para modelar matemáticamente la incertidumbre clínica, necesitamos asignar valores numéricos a los resultados inciertos: esto es una variable aleatoria.

Note

Una **variable aleatoria (VA)** es una función que asigna un valor numérico a cada resultado de un experimento aleatorio.

Tipos de variables aleatorias:

Tipo	Descripción	Ejemplo en Fisioterapia
Discreta	Toma valores aislados (contables)	Nº de sesiones hasta mejoría
Continua	Toma cualquier valor en un intervalo	Rango de movimiento (grados)

Función de probabilidad / densidad: Describe el comportamiento probabilístico de la VA. Para discretas usamos la **función de masa** $P(X = x)$. Para continuas, la **función de densidad** $f(x)$ donde el área bajo la curva entre a y b es $P(a \leq X \leq b)$.

Función de masa de probabilidad — Va discreta

Note

f.m.p.: $P(X = x) = f(x)$ asigna una probabilidad a cada valor posible de una VA discreta.


Propiedades: (1) $P(X = x) \geq 0$ para todo x ; (2) $\sum_x P(X = x) = 1$

Ejemplo clínico: $X = \text{n}^\circ$ de pacientes con mejoría en 3 tratados ($p = 0.5$)

x	0	1	2	3
$P(X = x)$	$1/8 = 0.125$	$3/8 = 0.375$	$3/8 = 0.375$	$1/8 = 0.125$

```
x <- 0:3; px <- dbinom(x, 3, 0.5)
bp <- barplot(px, names=x, col="seagreen", ylim=c(0,0.45),
  main="Función de Masa de Probabilidad - VA Discreta",
  xlab="x (nº pacientes con mejoría)", ylab="P(X = x)")
text(bp, px+0.02, paste0(px*8, "/8 = ", px), font=2, cex=0.95)
abline(h=0, col="grey")
```


Función de Masa de Probabilidad — VA Discreta



Verificación: $\sum P(X = x) = 0.125 + 0.375 + 0.375 + 0.125 = 1.00$

Esperanza matemática — Va discreta

i Note

$$E(X) = \sum_i x_i \cdot P(X = x_i)$$

La esperanza es el **valor esperado** o **media poblacional** de la VA.

Ejemplo (mejoría en 3 pacientes):

x_i	$P(X = x_i)$	$x_i \cdot P(X = x_i)$
0	1/8	$0 \times 1/8 = 0$
1	3/8	$1 \times 3/8 = 3/8$
2	3/8	$2 \times 3/8 = 6/8$
3	1/8	$3 \times 1/8 = 3/8$

$$E(X) = 0 + \frac{3}{8} + \frac{6}{8} + \frac{3}{8} = \frac{12}{8} = 1.5$$

Interpretación: En promedio se espera que **1.5 de cada 3 pacientes** muestren mejoría.

Varianza — Va discreta

i Note

$$\text{Var}(X) = E[(X - \mu)^2] = \sum_i (x_i - \mu)^2 \cdot P(X = x_i)$$

Fórmula alternativa: $\text{Var}(X) = E(X^2) - [E(X)]^2$

Ejemplo (mejoría, $\mu = 1.5$):

x_i	$P(X = x_i)$	$(x_i - 1.5)^2$	$(x_i - 1.5)^2 \cdot P(X = x_i)$
0	1/8	2.25	$2.25 \times 1/8 = 0.281$
1	3/8	0.25	$0.25 \times 3/8 = 0.094$
2	3/8	0.25	$0.25 \times 3/8 = 0.094$
3	1/8	2.25	$2.25 \times 1/8 = 0.281$

$$\text{Var}(X) = 0.281 + 0.094 + 0.094 + 0.281 = 0.75$$

```
x <- 0:3; px <- dbinom(x, 3, 0.5)
mu <- sum(x*px)
cat("E(X) =", mu, "  Var(X) =", sum((x-mu)^2*px),
    "\nVerificación: n·p·(1-p) =", 3*0.5*0.5)
```

E(X) = 1.5 Var(X) = 0.75

Verificación: $n \cdot p \cdot (1-p) = 0.75$

Función de distribución acumulativa (f.d.a.)

Note


$$F(x) = P(X \leq x)$$

La f.d.a. acumula la probabilidad desde $-\infty$ hasta x . Es **no decreciente**, $\lim_{x \rightarrow -\infty} F(x) = 0$, $\lim_{x \rightarrow \infty} F(x) = 1$, y $P(a < X \leq b) = F(b) - F(a)$.

f.d.a. de la Normal — Cálculo de Probabilidades

```
mu <- 30; sigma <- 8
curve(pnorm(x, mu, sigma), mu-24, mu+24, lwd=3, col="steelblue",
      main=expression(paste("f.d.a. Normal: F(x) = P(X ≤ x), N(30,", 8^2, ")")),
      xlab="Fuerza de presión (kg)", ylab="F(x)")
abline(h=c(0,0.5,1), lty=3, col="grey"); abline(v=mu, lty=2, col="darkgreen")
# Marcar F(22)
arrows(22, 0, 22, pnorm(22, mu, sigma), col="darkgreen", lwd=2, length=0.1)
points(22, pnorm(22, mu, sigma), pch=19, col="darkgreen", cex=1.5)
text(22, pnorm(22,mu,sigma)+0.05, paste0("F(22) = ", round(pnorm(22,mu,sigma),3)), col="darkgreen")
```

f.d.a. Normal: $F(x) = P(X \leq x)$, $N(30, 8^2)$



$$F(22) = P(X \leq 22) = \Phi\left(\frac{22 - 30}{8}\right) = \Phi(-1) = 0.159$$


f.d.a. — VA Discreta vs VA Continua

```
par(mfrow=c(1,2), mar=c(4,4,3,1))


# DISCRETA: Binomial(10, 0.4) - funcion escalonada
x_d <- 0:10; Fx_d <- pbinom(x_d, 10, 0.4)
plot(x_d, Fx_d, type="s", lwd=3, col="steelblue",
     main="f.d.a. Discreta - Binomial(10,0.4)",
     xlab="x", ylab="F(x)", ylim=c(0,1), xlim=c(-0.5,10.5))
abline(h=c(0,0.5,1), lty=3, col="grey"); points(x_d, Fx_d, pch=19, col="steelblue", cex=1.2)
```

```
# CONTINUA: Normal(0,1) - función continua
curve(pnorm(x), -4, 4, lwd=3, col="seagreen",
      main="f.d.a. Continua - Normal(0,1)",
      xlab="x", ylab="F(x)", ylim=c(0,1))
abline(h=c(0,0.5,1), lty=3, col="grey"); abline(v=0, lty=3, col="grey")
points(0, 0.5, pch=19, col="darkgreen", cex=1.5)
```

f.d.a. Discreta — Binomial(10, 0.5)



f.d.a. Continua — Normal(0,1)



```
par(mfrow=c(1,1))
```

VA Discreta: $F(x) = \sum_{x_i \leq x} P(X = x_i) \rightarrow$ **función escalonada**, salta en cada valor posible

VA Continua: $F(x) = \int_{-\infty}^x f(t)dt \rightarrow$ **función continua suave**, sin saltos

Función de densidad — Va continua

Note

$$P(a \leq X \leq b) = \text{área bajo } f(x) \text{ entre } a \text{ y } b$$

La probabilidad es el **área bajo la curva** de la función de densidad $f(x)$.

Propiedades: (1) $f(x) \geq 0$; (2) área total bajo $f(x) = 1$; (3) $P(X = c) = 0$ para cualquier c


Tip

Notación: El símbolo $\int_a^b f(x)dx$ significa “área bajo la curva $f(x)$ entre a y b ”. En este curso **siempre usaremos R** (`pnorm`, `dnorm`, `pt`, `pchisq`) en lugar de calcular integrales a mano.

```
set.seed(123)
ROM <- rnorm(500, mean=150, sd=20)
hist(ROM, col="steelblue", border="white", breaks=25, freq=FALSE,
     main="f.d.p. - ROM de Hombro (n=500)",
     xlab="Grados de flexión", ylab="Densidad de probabilidad f(x)", cex.lab=1.1)
curve(dnorm(x, 150, 20), add=TRUE, col="darkgreen", lwd=3)

# Sombrear P(130 < X < 170)
xr <- seq(130, 170, 0.5); yr <- dnorm(xr, 150, 20)
polygon(c(xr, rev(xr)), c(yr, rep(0, length(yr))), col=rgb(0,0.5,0.3,0.25), border=NA)
text(150, 0.003, paste("P(130 < X < 170) =",
  round(pnorm(170,150,20)-pnorm(130,150,20),3)), font=2, cex=1.1, col="darkgreen")
```

f.d.p. — ROM de Hombro (n=500)



Esperanza y varianza — Va continua

Note

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx \quad \text{Var}(X) = \int_{-\infty}^{\infty} (x - \mu)^2 \cdot f(x) dx$$

Ejemplo — ROM de hombro ($\mu = 150$, $\sigma = 20$):

```
set.seed(123)
ROM <- rnorm(10000, 150, 20)
cat("E(X) teórica = 150°   E(X) simulada =", round(mean(ROM),1), "°",
    "\nVar(X) teórica = 400   Var(X) simulada =", round(var(ROM),1),
    "\n teórica = 20°       simulada =", round(sd(ROM),1), "°")
```


$E(X)$ teórica = 150° $E(X)$ simulada = 150°
 $\text{Var}(X)$ teórica = 400 $\text{Var}(X)$ simulada = 398.9
 teórica = 20° simulada = 20°

```

# Comparación de dos VA continuas con distinta dispersión
curve(dnorm(x, 150, 10), 110, 190, col="steelblue", lwd=3,
      main=expression(paste("Dos VA Normales: misma ", mu, ", distinta ", sigma)),
      xlab="Grados ROM", ylab="f(x)", cex.lab=1.1)
curve(dnorm(x, 150, 25), 110, 190, col="seagreen", lwd=3, add=TRUE)
abline(v=150, lty=2, col="grey")
legend("topright", c(expression(sigma==10), expression(sigma==25)),
      col=c("steelblue","seagreen"), lwd=3, bty="n", cex=1.2)
text(150, 0.04, expression(mu==150), pos=1, cex=1.1)

```

Dos VA Normales: misma μ , distinta σ



Interpretación: Ambas tienen la misma esperanza ($\mu = 150^\circ$), pero la distribución naranja


($\sigma = 25$) tiene **mayor dispersión** que la azul ($\sigma = 10$).

Comparativa: Discreta vs continua — Conceptos análogos


Concepto	VA Discreta	VA Continua
Función de probabilidad	f.m.p.: $P(X = x)$	f.d.p.: $f(x)$
Probabilidad en intervalo	$\sum_{x \in [a,b]} P(X = x)$	$\int_a^b f(x) dx$
Probabilidad puntual	$P(X = x) \geq 0$	$P(X = x) = 0$
f.d.a.	$F(x) = \sum_{x_i \leq x} P(X = x_i)$	$F(x) = \int_{-\infty}^x f(t) dt$
Normalización	$\sum_x P(X = x) = 1$	$\int_{-\infty}^{\infty} f(x) dx = 1$
Esperanza $E(X)$	$\sum x_i \cdot P(X = x_i)$	$\int x \cdot f(x) dx$
Varianza $\text{Var}(X)$	$\sum (x_i - \mu)^2 \cdot P(X = x_i)$	$\int (x - \mu)^2 \cdot f(x) dx$

```
par(mfrow=c(1,2), mar=c(4,4,3,1))
# Discreta: Binomial
x <- 0:10
plot(x, dbinom(x,10,0.5), type="h", lwd=4, col="steelblue",
     main="VA Discreta: Binomial(10,0.5)", xlab="x", ylab="P(X=x)")
# Continua: Normal
curve(dnorm(x), -4, 4, lwd=3, col="seagreen",
     main="VA Continua: Normal(0,1)", xlab="x", ylab="f(x)")
```

VA Discreta: Binomial(10,1



VA Continua: Normal(0,1



```
par(mfrow=c(1,1))
```

Las cuatro funciones de R para distribuciones

Prefijo	Función	Fórmula	Ejemplo (Normal)
d	Densidad/Masa	$f(x)$	<code>dnorm(x, mean, sd)</code>
p	Distribución acumulada	$F(x) = P(X \leq x)$	<code>pnorm(q, mean, sd)</code>
q	Cuantil (percentil)	$F^{-1}(p)$	<code>qnorm(p, mean, sd)</code>
r	Aleatorio	Genera n valores	<code>rnorm(n, mean, sd)</code>

💡 Tip

Este patrón se repite para todas las distribuciones: `dbinom`, `pbinom`, `qbinom`, `rbinom`; `dpois`, `ppois`, `qpois`, `rpois`, etc.

Ejercicio Clínico — Tema II (Parte I)

Contexto: El 15% de pacientes en consulta tienen lumbalgia crónica. Un test tiene sensibilidad 90% y especificidad 85%.

1. Si un paciente da positivo, ¿probabilidad de tener lumbalgia?
2. ¿Por qué el VPP es bajo pese a la alta sensibilidad?

💡 Tip


Solución

1. $VPP = \frac{0.90 \times 0.15}{0.90 \times 0.15 + 0.15 \times 0.85} = \frac{0.135}{0.2625} = 51.4\%$
2. La baja prevalencia (15%) hace que los falsos positivos sean casi tan numerosos como los verdaderos positivos, reduciendo el VPP al 51.4%

```
prev <- 0.15; sens <- 0.90; spec <- 0.85
vpp <- (sens*prev) / (sens*prev + (1-spec)*(1-prev))
vpn <- (spec*(1-prev)) / (spec*(1-prev)+(1-sens)*prev)

# Visualización
par(mfrow=c(1,2), mar=c(4,4,3,1))
# Panel 1: Árbol de probabilidades
labels <- c("Enfermo\n(15%)", "Sano\n(85%)")
bp <- barplot(c(prev, 1-prev), names=labels, col=c("coral","steelblue"),
              main="Prevalencia de lumbalgia", ylab="Proporción", ylim=c(0,1))
text(bp, c(prev,1-prev)+0.05, paste0(round(c(prev,1-prev)*100,1),"%"), font=2, cex=1.2)

# Panel 2: Rendimiento del test
vp <- sens*prev; fp <- (1-spec)*(1-prev); vn <- spec*(1-prev); fn <- (1-sens)*prev
m <- matrix(c(vp, fn, fp, vn), 2, dimnames=list(c("Positivo","Negativo"), c("Enfermo","Sano")))
barplot(m, beside=TRUE, col=c("coral","steelblue"),
        main=paste0("Test: VPP=", round(vpp*100,1), "% VPN=", round(vpn*100,1), "%"),
        ylab="Probabilidad", ylim=c(0,0.8))
legend("topright", c("Positivo","Negativo"), fill=c("coral","steelblue"), bty="n", cex=0.8)
```



```
par(mfrow=c(1,1))
```

```
cat("VPP =", round(vpp*100,1), "%\nVPN =", round(vpn*100,1), "%")
```

VPP = 51.4 %

VPN = 98 %

Código del Tema II (Parte I) — Resumen Organizado

Probabilidad básica

```
# Regla de Laplace
P_3 <- 1/6          # P(sacar un 3 en un dado)
P_par <- 3/6         # P(sacar par)

# Complemento
P_HTA <- 0.30
P_no_HTA <- 1 - P_HTA # P(no HTA) = 0.70

# Unión de eventos (inclusión-exclusión)
P_A <- 40/100; P_B <- 30/100; P_AB <- 10/100
P_A_union_B <- P_A + P_B - P_AB # 0.60
```

Probabilidad condicional y Bayes

```
# Probabilidad condicional
P_R_given_M <- 72/120 # P(Recuperado | Mujer) = 0.60
P_R_given_H <- 32/80  # P(Recuperado | Hombre) = 0.40

# Teorema de Bayes - Test diagnóstico
prev <- 0.15          # Prevalencia
sens <- 0.90          # Sensibilidad
spec <- 0.85          # Especificidad

vpp <- (sens * prev) / (sens * prev + (1 - spec) * (1 - prev))
vpn <- (spec * (1 - prev)) / (spec * (1 - prev) + (1 - sens) * prev)
cat("VPP =", round(vpp * 100, 1), "%")
cat("VPN =", round(vpn * 100, 1), "%")
```

Variables aleatorias

```
# VA Discreta - Binomial
x <- 0:3
px <- dbinom(x, 3, 0.5) # P(X = x)
```

```

Ex <- sum(x * px)          # Esperanza
Varx <- sum((x - Ex)^2 * px) # Varianza

# VA Continua - Normal
mu <- 30; sigma <- 8; x_obs <- 22
z <- (x_obs - mu) / sigma # Z-score
p_bajo <- pnorm(x_obs, mu, sigma) # P(X ≤ 22)

# Las 4 funciones de R para distribuciones
dnorm(x, mu, sigma) # Densidad f(x)
pnorm(q, mu, sigma) # Distribución F(q) = P(X ≤ q)
qnorm(p, mu, sigma) # Cuantil
rnorm(n, mu, sigma) # Generar n valores aleatorios

```