Probabilidad y Variables Aleatorias con R

Tema II (Parte II) — La Distribución Normal, Modelos Discretos y Aproximaciones

Miguel Angel Luque-Fernández

2026-01-01

Herramientas Computacionales para Distribuciones

Conexión: R dispone de funciones específicas para cada distribución de probabilidad. Aprender a usarlas correctamente es tan importante como entender la teoría.

`lower.tail` — La Opción Más Útil de las Funciones `p`

Todas las funciones `p` (acumuladas) tienen el argumento `lower.tail`:

`lower.tail = TRUE` (por defecto):
- `pnorm(k)` $= P(X \leq k)$
- `pbinom(k, n, p)` $= P(X \leq k)$
- `ppois(k, lambda)` $= P(X \leq k)$

Calcula el área **desde** $-\infty$ **hasta** k

`lower.tail = FALSE`:
- `pnorm(k, lower.tail=FALSE)` $= P(X > k)$
- `pbinom(k, n, p, lower.tail=FALSE)` $= P(X > k)$
- `ppois(k, lambda, lower.tail=FALSE)` $= P(X > k)$

Calcula el área **desde** k **hasta** $+\infty$

Equivalencia fundamental:

```
n<-10; p<-0.5; k<-3
# Estas dos expresiones son EXACTAMENTE IGUALES:
pbinom(k, n, p, lower.tail=FALSE)  # P(X > 3)
```

```
[1] 0.828125
```

```
1 - pbinom(k, n, p)                # 1 - P(X   3)
```

```
[1] 0.828125
```

`lower.tail` — Equivalencias y Precauciones

Variables continuas (Normal, t, ², F):

```
# P(X > 1.96) es IDÉNTICO a:
pnorm(1.96, lower.tail=FALSE)
```

```
[1] 0.0249979
```

```
1 - pnorm(1.96)
```

```
[1] 0.0249979
```

Variables discretas (Binomial, Poisson):

```
# ¡CUIDADO! P(X > 3)   P(X   3)
pbinom(3, 10, 0.5, lower.tail=FALSE)  # P(X > 3) = P(X   4)
```

```
[1] 0.828125
```

```
1 - pbinom(4-1, 10, 0.5)              # P(X   4) = 1 - P(X   3)
```

```
[1] 0.828125
```

Quiero calcular…	Normal (continua)	Binomial/Poisson (discreta)

Quiero calcular…	Normal (continua)	Binomial/Poisson (discreta)
$P(X \leq k)$	`pnorm(k)`	`pbinom(k, n, p)` / `ppois(k, )`
$P(X < k)$	`pnorm(k)` $(= P(X \leq k))$	`pbinom(k-1, n, p)`
$P(X > k)$	`pnorm(k, lower.tail=FALSE)`	`pbinom(k, n, p, lower.tail=FALSE)`
$P(X \geq k)$	`pnorm(k, lower.tail=FALSE)` $(= P(X > k))$	`1 - pbinom(k-1, n, p)`

> **Warning**
>
> **Truco para estudiantes:** En variables **discretas** (Binomial, Poisson), $P(X < k) \neq P(X \leq k)$. La diferencia es $P(X = k)$. Usad `lower.tail=FALSE` para colas derechas y recordad restar 1 al límite para desigualdades estrictas.

La Distribución Normal y sus Aproximaciones

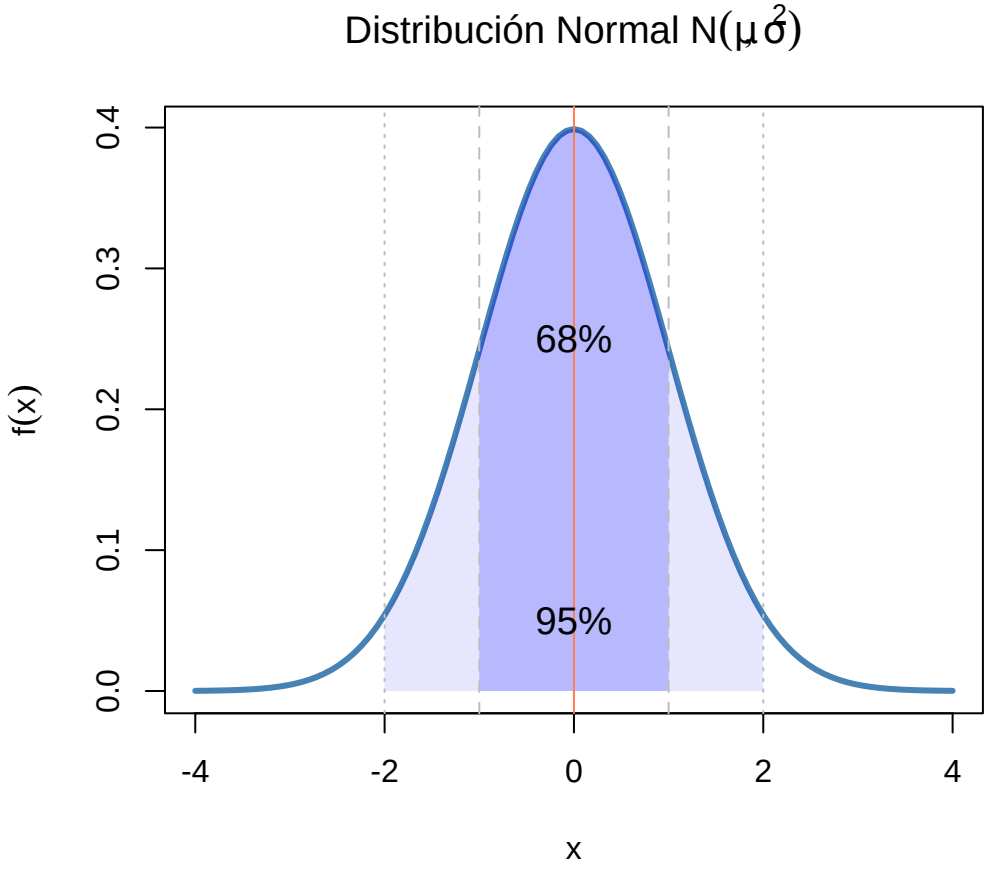
Puente con T03 — Estimación: La distribución Normal es la base del Teorema Central del Límite, que veremos en el Tema 3. Todo lo que aprendas aquí sobre `pnorm()`, `qnorm()` y Z-scores se usará para construir intervalos de confianza y contrastes de hipótesis.

Distribución Normal — Historia y contexto

Carl Friedrich Gauss (1777–1855) introdujo esta distribución estudiando errores de medición astronómica. Originalmente llamada **"campana de Gauss"**, hoy es la distribución más importante en estadística.

¿Por qué es tan ubicua? Por el **Teorema Central del Límite**: la suma de muchas variables independientes tiende a una Normal, sin importar su distribución original. Por eso aparece en biología, medicina, economía, física…

```r
curve(dnorm(x, 0, 1), -4, 4, lwd=3, col="steelblue",
      main=expression(paste("Distribución Normal ", N(mu, sigma^2))),
      xlab="x", ylab=expression(f(x)))
#   ±   (68%)
x1<-seq(-1,1,0.01); polygon(c(x1,rev(x1)),c(dnorm(x1),rep(0,length(x1))),col=rgb(0,0,1,0.2),
#   ± 2  (95%)
x2<-seq(-2,2,0.01); polygon(c(x2,rev(x2)),c(dnorm(x2),rep(0,length(x2))),col=rgb(0,0,1,0.1),
abline(v=c(-2,-1,0,1,2), lty=c(3,2,1,2,3), col=c("grey","grey","coral","grey","grey"))
text(0, 0.25, "68%", cex=1.2); text(0, 0.05, "95%", cex=1.2)
```



La curva normal describe la distribución de errores y de fenómenos naturales donde muchas causas pequeñas se suman. Hoy, en fisioterapia, modela: fuerza muscular, ROM articular, presión arterial, y prácticamente cualquier variable biológica continua.

Distribución Normal — Fórmula y propiedades

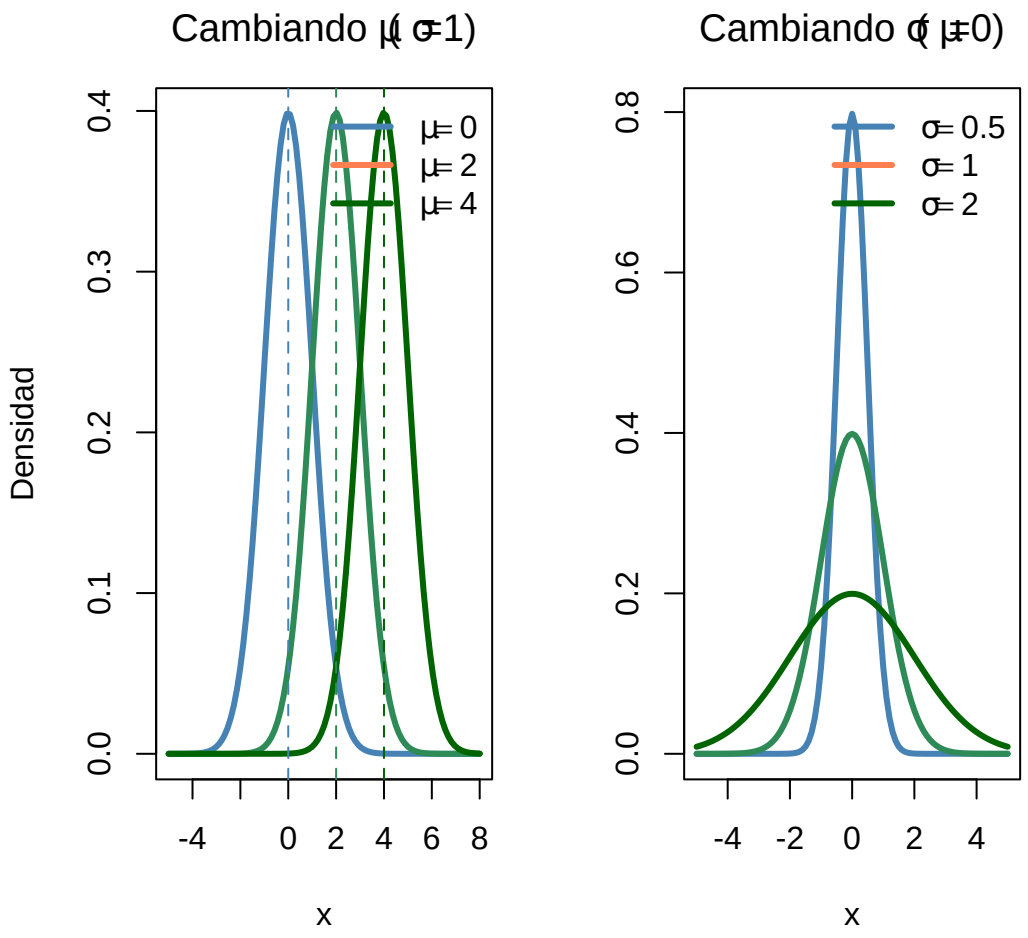
> **Note**
>
> $$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad -\infty < x < \infty$$
>
> - μ = media (centro de la campana), σ = desviación típica (dispersión)
> - $E(X) = \mu$, $\text{Var}(X) = \sigma^2$
> - **Simetrica:** media = mediana = moda
> - $\mu \pm \sigma$ contiene 68%, $\mu \pm 2\sigma$ contiene 95%, $\mu \pm 3\sigma$ contiene 99.7%

Ejemplo clínico: Fuerza de prensión manual: $X \sim N(30, 8^2)$ kg

Visualización de la distribución Normal

Efecto de cambiar μ y σ en la forma de la campana:

```
par(mfrow=c(1,2), mar=c(4,4,3,1))
# Cambiar
curve(dnorm(x, 0, 1), -5, 8, lwd=3, col="steelblue", ylab="Densidad",
      main=expression(paste("Cambiando ", mu, " (", sigma, "=1)")), xlab="x")
curve(dnorm(x, 2, 1), -5, 8, lwd=3, col="seagreen", add=TRUE)
curve(dnorm(x, 4, 1), -5, 8, lwd=3, col="darkgreen", add=TRUE)
abline(v=c(0,2,4), lty=2, col=c("steelblue","seagreen","darkgreen"))
legend("topright", c(expression(mu==0),expression(mu==2),expression(mu==4)),
       col=c("steelblue","coral","darkgreen"), lwd=3, bty="n")
# Cambiar
curve(dnorm(x, 0, 0.5), -5, 5, lwd=3, col="steelblue", ylab="",
      main=expression(paste("Cambiando ", sigma, " (", mu, "=0)")), xlab="x")
curve(dnorm(x, 0, 1), -5, 5, lwd=3, col="seagreen", add=TRUE)
curve(dnorm(x, 0, 2), -5, 5, lwd=3, col="darkgreen", add=TRUE)
legend("topright", c(expression(sigma==0.5),expression(sigma==1),expression(sigma==2)),
       col=c("steelblue","coral","darkgreen"), lwd=3, bty="n")
```




```r
par(mfrow=c(1,1))
```

μ desplaza, σ ensancha. La Normal es simétrica: media = mediana = moda.

Estandarización — El concepto más importante

La visualización comparativa de escalas originales vs. estandarizadas se muestra en la siguiente diapositiva.

> **!** Important
>
> **Definición general:** La estandarización transforma cualquier variable para que tenga media 0 y varianza 1:

$$Z = \frac{X - E(X)}{\sqrt{\text{Var}(X)}} = \frac{X - \mu_X}{\sigma_X}$$

Si $X \sim N(\mu, \sigma^2)$, entonces $Z \sim N(0,1)$. La distribución $N(0,1)$ se llama **Normal estándar**.

Propiedades fundamentales de Z: - $E(Z) = 0$ y $\text{Var}(Z) = 1$ (siempre, para cualquier distribución) - **Adimensional:** Z no tiene unidades → permite **comparar** variables completamente diferentes - $Z = 2$ siempre significa "2 desviaciones estándar por encima de la media", sea cual sea la variable original

¿Por Qué es Fundamental la Estandarización?

1. **Permite usar una única tabla de probabilidades:** Sin estandarización, necesitaríamos infinitas tablas (una para cada combinación de μ y σ). Con Z, solo necesitamos la tabla de la $N(0,1)$.
2. **Hace comparables mediciones distintas:** ¿Qué es más extremo: una presión arterial de 150 mmHg o un IMC de 32 kg/m²? Los Z-scores responden: $z_{PA} = (150-120)/15 = 2.0$ vs $z_{IMC} = (32-25)/4 = 1.75$ → la PA es más extrema.
3. **Base de toda la inferencia:** Los intervalos de confianza y tests de hipótesis usan valores estandarizados ($z_{\alpha/2} = 1.96$, $t_{\alpha/2}$).

Z-scores en la práctica clínica

Tensión Arterial Sistólica: $X \sim N(120, 15^2)$ mmHg

Paciente	TA (mmHg)	$Z = \frac{X-120}{15}$	Interpretación clínica
A	120	0.0	En la media poblacional
B	135	1.0	1 DE por encima
C	105	−1.0	1 DE por debajo
D	150	**2.0**	2 DE por encima → **HTA**
E	90	−2.0	2 DE por debajo → Hipotensión

```
cat("Paciente D: z =", round((150-120)/15,1),
    "→ P(Z > 2) =", round(pnorm(2, lower.tail=FALSE),4),
    "\nPaciente E: z =", round((90-120)/15,1),
    "→ P(Z < -2) =", round(pnorm(-2),4))
```

```
Paciente D: z = 2 → P(Z > 2) = 0.0228
Paciente E: z = -2 → P(Z < -2) = 0.0228
```

Estandarización — Más ejemplos clínicos

LDL-Colesterol: $X \sim N(130, \sigma^2 = 40)$ mg/dL $\rightarrow \sigma = \sqrt{40} \approx 6.32$

Cálculo	Fórmula	Resultado
Paciente con LDL = 140	$z = \frac{140-130}{6.32}$	$z \approx 1.58$
Percentil 90	$x = 130 + z_{0.90} \times 6.32$	$x \approx 130 + 1.28 \times 6.32 = 138.1$
$P(LDL > 140)$	$P(Z > 1.58)$	≈ 0.057 (5.7%)

Glucemia en ayunas: $X \sim N(100, 10^2)$ mg/dL

Paciente	Glucemia	Z-score	Interpretación
Normal	90	$z = -1.0$	1 DE bajo la media
Límite	100	$z = 0.0$	En la media
Prediabetes	120	$z = 2.0$	2 DE arriba
Diabetes	140	$z = 4.0$	Muy extremo ($P < 0.001$)

```r
glucemias <- c(90, 100, 120, 140)
z_gluc <- (glucemias - 100) / 10
cat("Z-scores glucemia:", round(z_gluc, 2),
    "\nP(Z > 4) =", round(pnorm(4, lower.tail=FALSE), 6))
```

```
Z-scores glucemia: -1 0 2 4
P(Z > 4) = 3.2e-05
```

Estandarización y cálculo de probabilidades

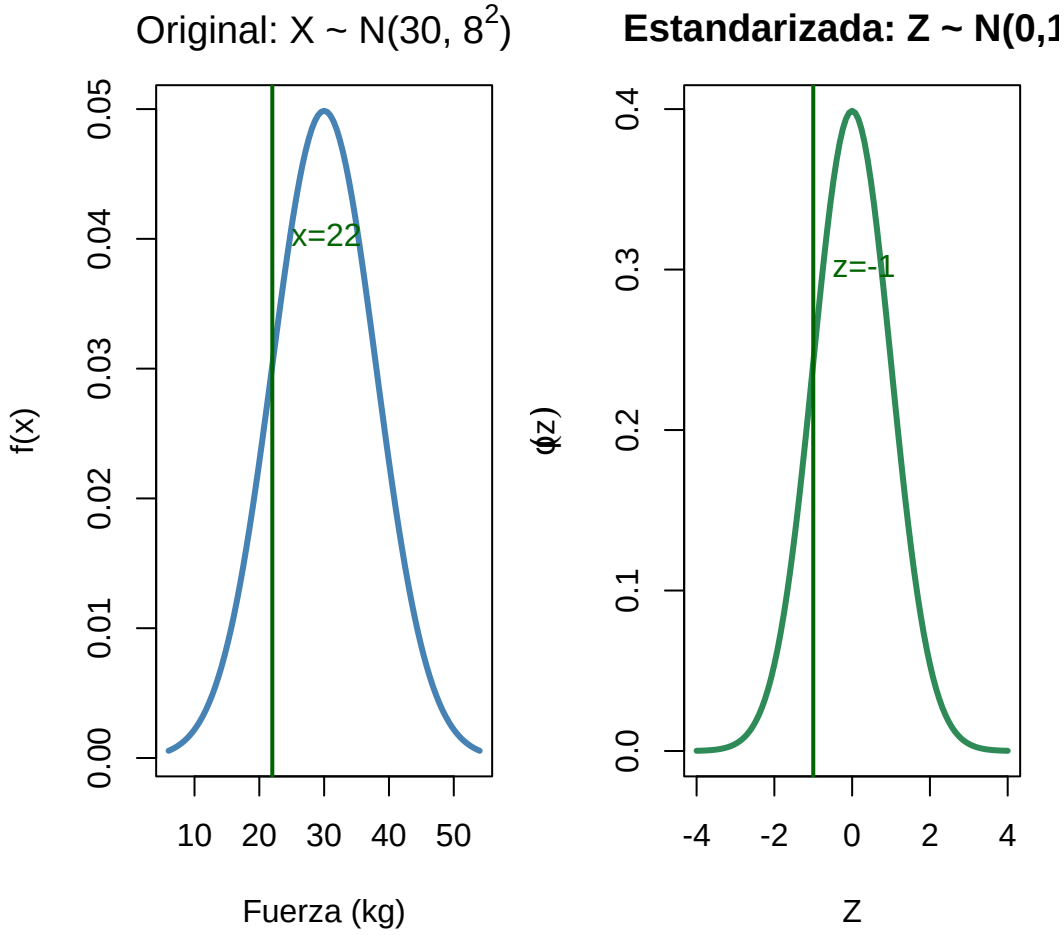
La clave práctica: Para calcular cualquier probabilidad Normal, convertimos a Z y usamos $N(0, 1)$:

$$P(X \leq x) = P\left(Z \leq \frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

```r
mu <- 30; sigma <- 8; x_obs <- 22
z_obs <- (x_obs - mu) / sigma

par(mfrow=c(1,2), mar=c(4,4,3,1))
# Escala original X ~ N(30, 8²)
curve(dnorm(x, mu, sigma), mu-24, mu+24, lwd=3, col="steelblue",
      main=expression(paste("Original: X ~ N(30, ", 8^2, ")")),
      xlab="Fuerza (kg)", ylab="f(x)")
abline(v=x_obs, col="darkgreen", lwd=2); text(x_obs, 0.04, "x=22", col="darkgreen", pos=4)

# Escala estandarizada Z ~ N(0,1)
curve(dnorm(x), -4, 4, lwd=3, col="seagreen",
      main="Estandarizada: Z ~ N(0,1)",
      xlab="Z", ylab=expression(phi(z)))
abline(v=z_obs, col="darkgreen", lwd=2); text(z_obs, 0.3, paste0("z=",z_obs), col="darkgreen
```




```
par(mfrow=c(1,1))

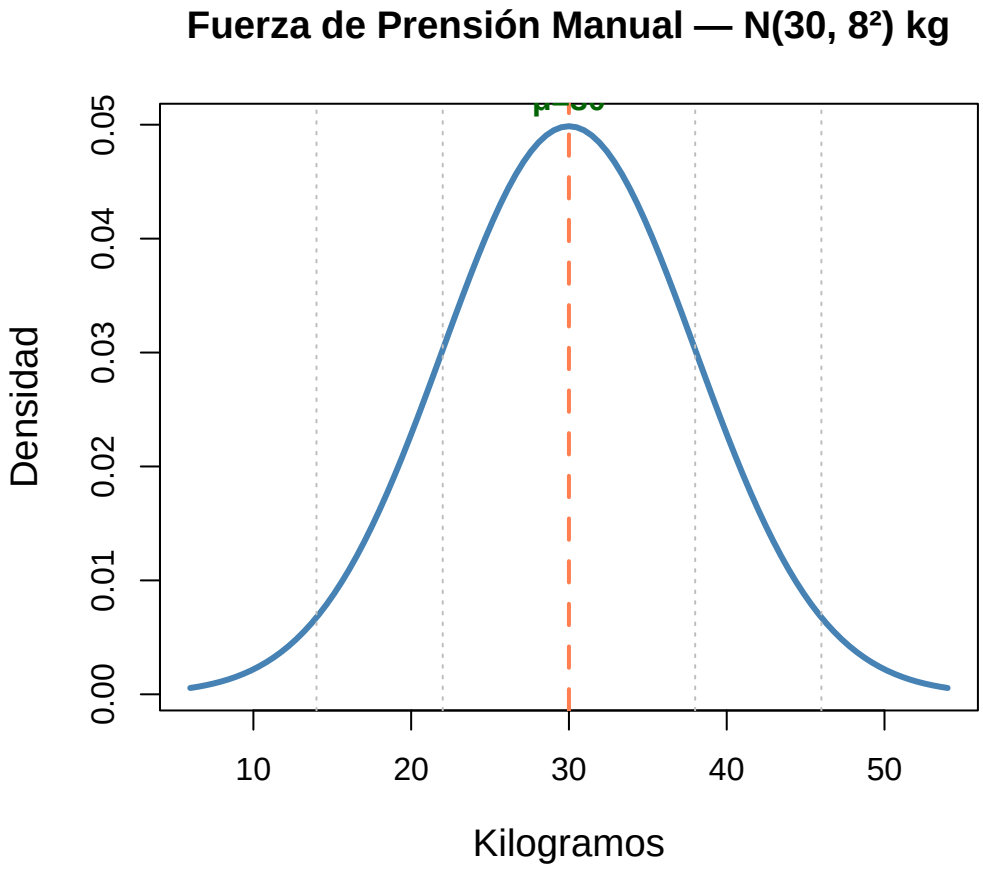
cat("X =", x_obs, "kg → Z =", round(z_obs,2),
    " P(X <", x_obs,") = P(Z <", round(z_obs,2),") =",
    round(pnorm(x_obs, mu, sigma), 4))
```

```
X = 22 kg → Z = -1  P(X < 22 ) = P(Z < -1 ) = 0.1587
```

El área a la izquierda de $x = 22$ en la escala original es EXACTAMENTE igual al área a la izquierda de $z = -1$ en la escala estandarizada.

Normal — Fuerza de prensión manual

```
mu <- 30; sigma <- 8
curve(dnorm(x, mu, sigma), mu-24, mu+24, col="steelblue", lwd=3,
      main="Fuerza de Prensión Manual - N(30, 8²) kg",
      xlab="Kilogramos", ylab="Densidad", cex.lab=1.2)
abline(v=c(mu-2*sigma, mu-sigma, mu, mu+sigma, mu+2*sigma),
       lty=c(3,3,2,3,3), lwd=c(1,1,2,1,1), col=c("grey","grey","coral","grey","grey"))
text(mu, 0.052, " =30", col="darkgreen", font=2)
```



$$P(X < 22) = P\left(Z < \frac{22-30}{8}\right) = P(Z < -1) = 0.159$$

$$P(22 < X < 38) = P(-1 < Z < 1) = 0.683$$

```r
cat("P(X<22) =", round(pnorm(22, mu, sigma),3),
    "\nP(22<X<38) =", round(pnorm(38,mu,sigma)-pnorm(22,mu,sigma),3))
```

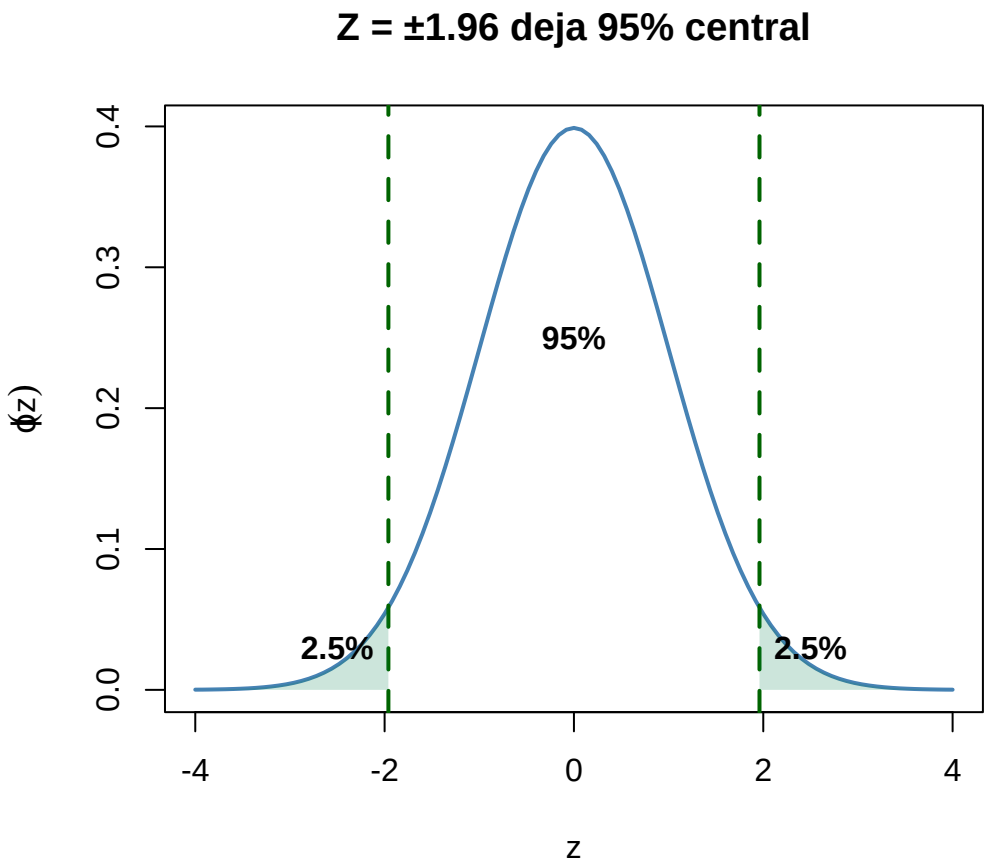
```
P(X<22) = 0.159
P(22<X<38) = 0.683
```

Normal — Percentiles clave

Los más usados en inferencia estadística:

Percentil	Z	Uso
90%	1.282	IC 80%
95%	1.645	Test unilateral
97.5%	**1.960**	**IC 95% bilateral**
99%	2.326	IC 98%
99.5%	2.576	IC 99%

```r
curve(dnorm(x), -4, 4, col="steelblue", lwd=2,
      main="Z = ±1.96 deja 95% central",
      xlab="z", ylab=expression(varphi(z)))
abline(v=c(-1.96, 1.96), col="darkgreen", lty=2, lwd=2)
xr <- seq(1.96, 4, 0.01); yr <- dnorm(xr)
polygon(c(xr, rev(xr)), c(yr, rep(0,length(yr))), col=rgb(0,0.5,0.3,0.2), border=NA)
xl <- seq(-4, -1.96, 0.01); yl <- dnorm(xl)
polygon(c(xl, rev(xl)), c(yl, rep(0,length(yl))), col=rgb(0,0.5,0.3,0.2), border=NA)
text(c(-2.5, 0, 2.5), c(0.03, 0.25, 0.03), c("2.5%","95%","2.5%"), font=2)
```




```
cat("Z para IC 95%:", round(qnorm(0.975), 3),
    "\nZ para IC 99%:", round(qnorm(0.995), 3))
```

```
Z para IC 95%: 1.96
Z para IC 99%: 2.576
```

Un paciente tiene $Z = -1.5$ en fuerza de prensión y $Z = +2.1$ en IMC. ¿Cuál de las dos mediciones es más preocupante? ¿Por qué?

Modelos para Datos Discretos en Fisioterapia

Conexión: Muchos fenómenos en fisioterapia son conteos: número de pacientes que responden a un tratamiento, número de sesiones necesarias para alcanzar un objetivo funcional. Las distribuciones Binomial y Poisson modelan estos eventos discretos.

Distribución Binomial — Contexto histórico

Jacob Bernoulli (1654–1705) en su obra póstuma *Ars Conjectandi* (1713) estudió experimentos con dos resultados posibles (éxito/fracaso). Su sobrino **Daniel Bernoulli** aplicó estos modelos a la medicina.

¿Por qué "Binomial"? La fórmula usa el **coeficiente binomial** $\binom{n}{k} = \frac{n!}{k!(n-k)!}$, que cuenta el número de formas de elegir k éxitos entre n ensayos.

En Fisioterapia: La Binomial modela todo lo que consiste en contar **éxitos** en un número fijo de pacientes: ¿cuántos de 10 pacientes mejoran con una terapia? ¿cuántos de 20 tratamientos tienen éxito?

> **Tip**
>
> **Para recordar:** Binomial = **nº fijo de ensayos** (n) + **probabilidad constante** (p) + **independencia** entre ensayos. Si tratamos 10 pacientes con la misma terapia y cada uno mejora o no independientemente → Binomial.

Distribución Binomial

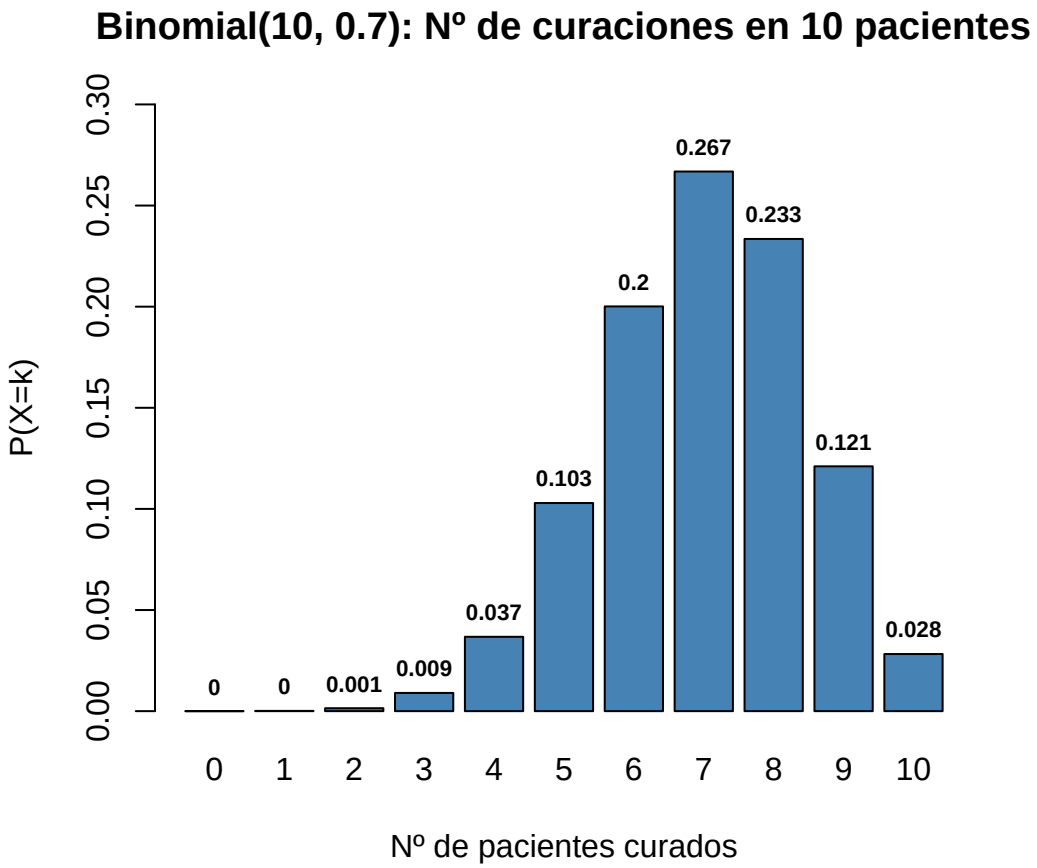
> **Note**
>
> $$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \ldots, n$$
>
> donde $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ es el coeficiente binomial.

- **Significado:** Número de éxitos en n ensayos independientes con probabilidad p
- $E(X) = n \cdot p$, $\text{Var}(X) = n \cdot p \cdot (1-p)$
- Forma simétrica si $p = 0.5$, asimétrica si $p \neq 0.5$

Ejemplo clínico: Fármaco cura al 70% de pacientes ($p = 0.7$), $n = 10$ tratados.

Binomial — Ejemplo clínico con R

```
n <- 10; p <- 0.7; k <- 0:n
bp <- barplot(dbinom(k, n, p), names.arg=k, col="steelblue",
        main="Binomial(10, 0.7): Nº de curaciones en 10 pacientes",
        xlab="Nº de pacientes curados", ylab="P(X=k)", ylim=c(0,0.3))
text(bp, dbinom(k,n,p)+0.012, round(dbinom(k,n,p),3), cex=0.7, font=2)
```



Cálculo a mano — $P(X = 7)$:

$\binom{10}{7} = \frac{10 \cdot 9 \cdot 8}{3 \cdot 2 \cdot 1} = 120$

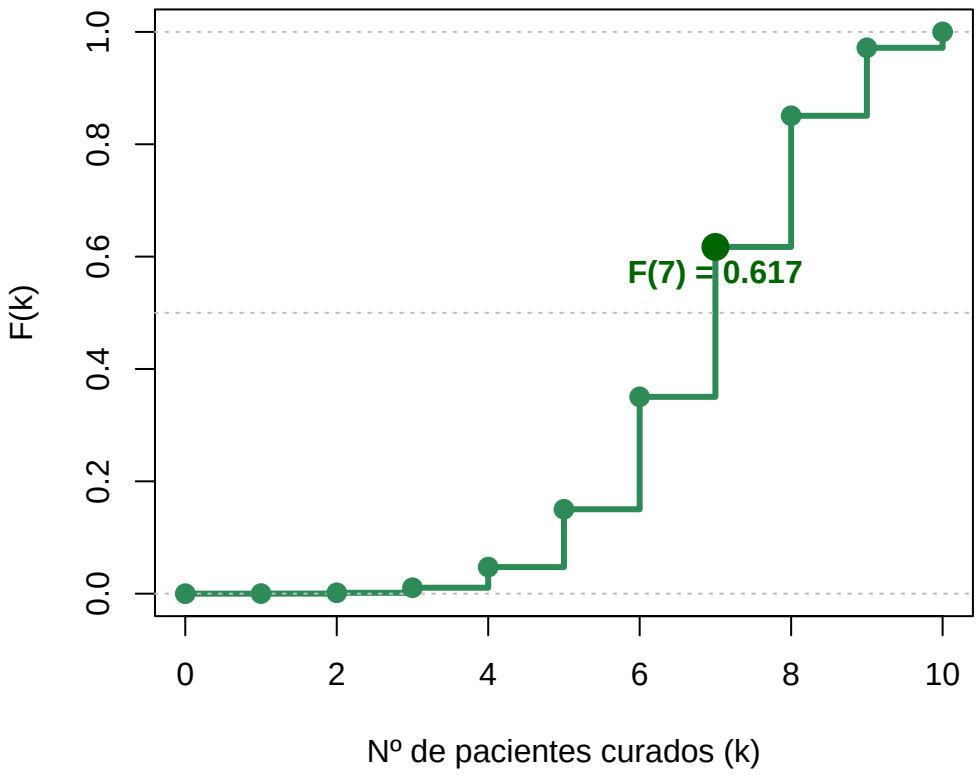
$P(X = 7) = 120 \cdot (0.7)^7 \cdot (0.3)^3 = 120 \cdot 0.0824 \cdot 0.027 = 0.267$

```r
cat("Manual:", round(120*0.7^7*0.3^3,3),
    "\ndbinom:", round(dbinom(7,10,0.7),3))
```

```
Manual: 0.267
dbinom: 0.267
```

f.d.a. de la Binomial — Cálculo de Probabilidades Acumuladas

```r
n <- 10; p <- 0.7; k <- 0:n
Fx <- pbinom(k, n, p)
plot(k, Fx, type="s", lwd=3, col="seagreen",
     main=expression(paste("f.d.a. Binomial(10, 0.7): F(k) = P(X   k)")),
     xlab="Nº de pacientes curados (k)", ylab="F(k)", ylim=c(0,1))
abline(h=c(0,0.5,1), lty=3, col="grey"); points(k, Fx, pch=19, col="seagreen", cex=1.3)
# Marcar F(7)
points(7, Fx[8], pch=19, col="darkgreen", cex=1.8)
text(7, Fx[8]-0.05, paste0("F(7) = ", round(Fx[8],3)), col="darkgreen", font=2)
```



$$F(7) = P(X \leq 7) = \sum_{k=0}^{7} \binom{10}{k} 0.7^k \cdot 0.3^{10-k}$$

Binomial — Regla de oro (Variables discretas)

> **Warning**
>
> En VA discretas, los límites de los intervalos **importan**:
>
> - $P(X \leq k)$ = `pbinom(k, n, p)`
> - $P(X < k)$ = `pbinom(k-1, n, p)` ← ¡no es lo mismo!
> - $P(X \geq k)$ = `1 - pbinom(k-1, n, p)`
> - $P(X > k)$ = `1 - pbinom(k, n, p)`

```r
n <- 10; p <- 0.7
cat("P(X  7) =", round(pbinom(7,n,p), 4),
    "\nP(X < 7)  = P(X  6) =", round(pbinom(6,n,p), 4), "  ← ¡diferente!",
    "\nP(X  7)  =", round(1-pbinom(6,n,p), 4),
    "\nP(X > 7)  =", round(1-pbinom(7,n,p), 4))
```

```
P(X  7) = 0.6172
P(X < 7)  = P(X  6) = 0.3504   ← ¡diferente!
P(X  7)  = 0.6496
P(X > 7)  = 0.3828
```

Distribución de Poisson — Contexto histórico

Siméon Denis Poisson (1781–1840) publicó esta distribución en 1837 en su obra *Recherches sur la probabilité des jugements*. Originalmente modelaba el número de condenas erróneas en juicios.

¿Cuándo surge? La Poisson es el límite de la Binomial cuando $n \to \infty$ y $p \to 0$ manteniendo $\lambda = n \cdot p$ constante. Esto la hace ideal para **eventos raros** en grandes poblaciones.

En Fisioterapia: La Poisson modela eventos que ocurren con tasa constante: nº de pacientes que llegan a urgencias por esguince en un turno, nº de caídas por mes en una residencia, nº de reacciones adversas por año en una clínica.

> **Tip**
>
> **Para recordar:** Poisson = **tasa constante** (λ) + eventos **independientes** en el tiempo. Si registramos cuántos pacientes llegan con lumbalgia aguda cada semana → Poisson.

Distribución de Poisson

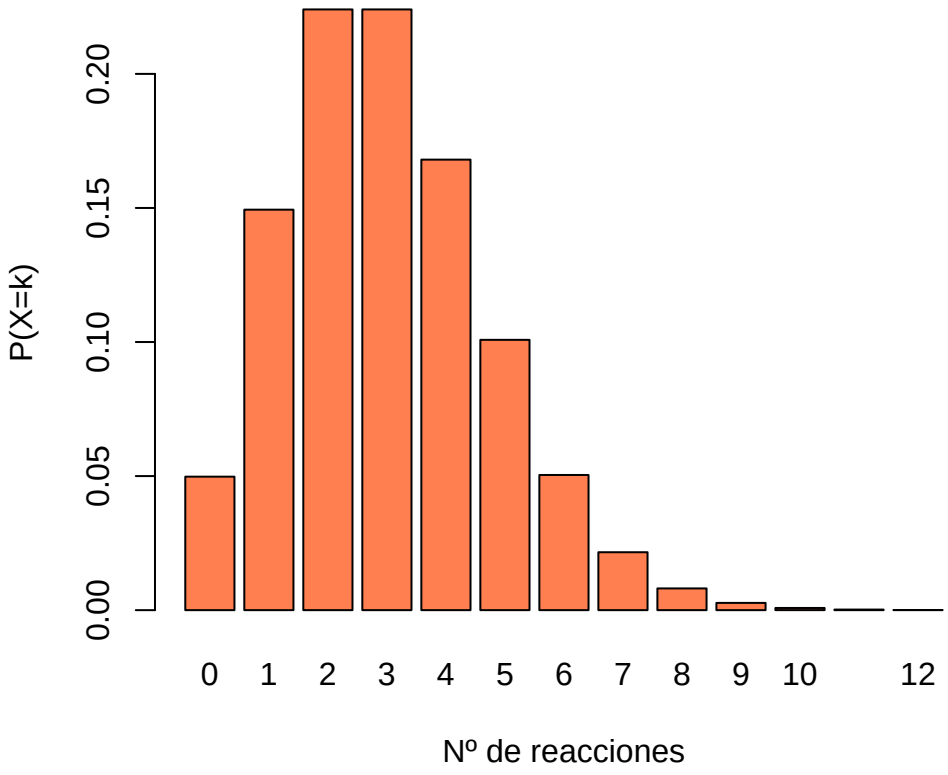
> **Note**
>
> $$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, ...$$

- **Significado:** Número de eventos raros en un intervalo fijo (tiempo/espacio)
- $E(X) = \lambda$, $\text{Var}(X) = \lambda$ (¡media = varianza!)
- Propiedad aditiva: $X \sim Po(\lambda_1), Y \sim Po(\lambda_2)$ indep. $\rightarrow X + Y \sim Po(\lambda_1 + \lambda_2)$

Ejemplo clínico: Reacciones adversas en clínica de fisioterapia: $\lambda = 3$/día

Poisson — Ejemplo clínico con R

```
lambda <- 3; k <- 0:12
bp <- barplot(dpois(k, lambda), names.arg=k, col="coral",
        main="Poisson(3): Reacciones adversas por día",
        xlab="Nº de reacciones", ylab="P(X=k)")
```



Cálculo a mano — $P(X = 5)$**:**

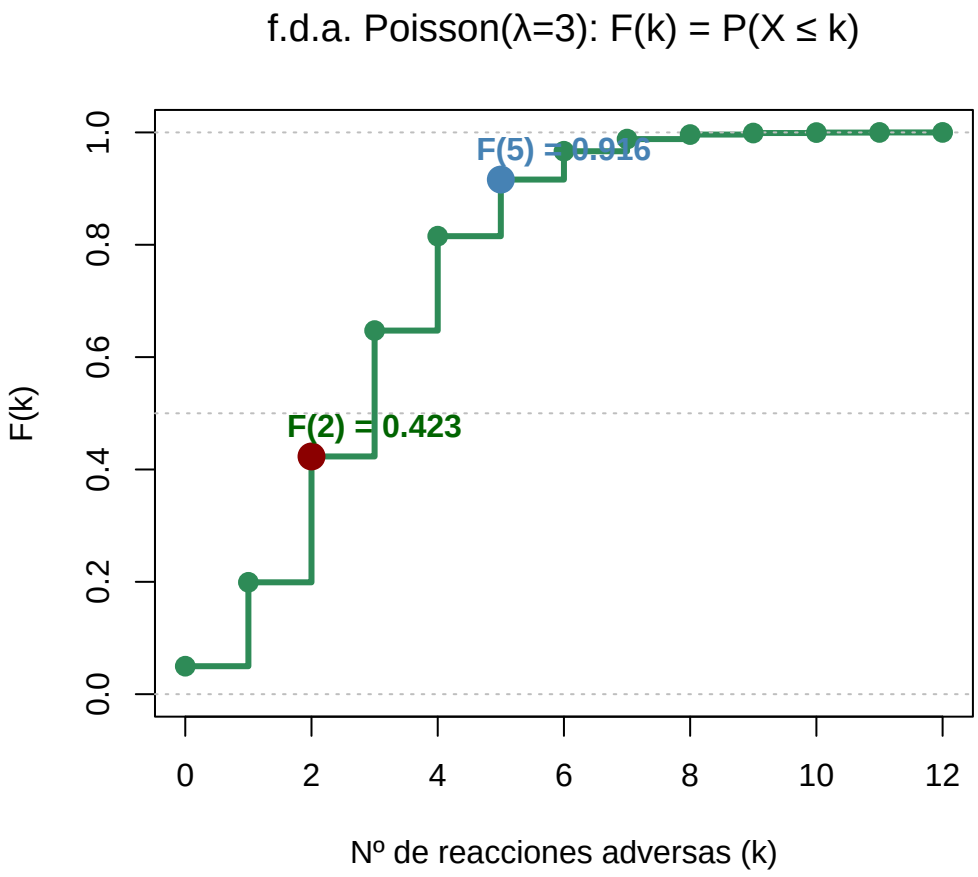
$P(X = 5) = \frac{3^5 e^{-3}}{5!} = \frac{243 \cdot 0.0498}{120} \approx 0.101$

```
cat("Manual:", round(3^5*exp(-3)/factorial(5),3),
    "\ndpois:", round(dpois(5, lambda),3),
    "\nP(X 2) =", round(ppois(2, lambda),3))
```

```
Manual: 0.101
dpois: 0.101
P(X 2) = 0.423
```

f.d.a. de la Poisson — Cálculo de Probabilidades Acumuladas

```
lambda <- 3; k <- 0:12
Fx <- ppois(k, lambda)
plot(k, Fx, type="s", lwd=3, col="seagreen",
     main=expression(paste("f.d.a. Poisson( =3): F(k) = P(X   k)")),
     xlab="Nº de reacciones adversas (k)", ylab="F(k)", ylim=c(0,1))
abline(h=c(0,0.5,1), lty=3, col="grey"); points(k, Fx, pch=19, col="seagreen", cex=1.3)
# Marcar F(2) y F(5)
points(c(2,5), Fx[c(3,6)], pch=19, col=c("darkred","steelblue"), cex=1.8)
text(3, Fx[3]+0.05, paste0("F(2) = ", round(Fx[3],3)), col="darkgreen", font=2)
text(6, Fx[6]+0.05, paste0("F(5) = ", round(Fx[6],3)), col="steelblue", font=2)
```



$$P(X \leq 2) = \sum_{k=0}^{2} \frac{3^k e^{-3}}{k!} \quad P(2 < X \leq 5) = F(5) - F(2)$$

```
cat("F(2) =", round(ppois(2,3),3), "| F(5) =", round(ppois(5,3),3),
    "| P(2<X 5) =", round(ppois(5,3)-ppois(2,3),3))
```

```
F(2) = 0.423 | F(5) = 0.916 | P(2<X 5) = 0.493
```

Distribución t-student — Origen y propiedades

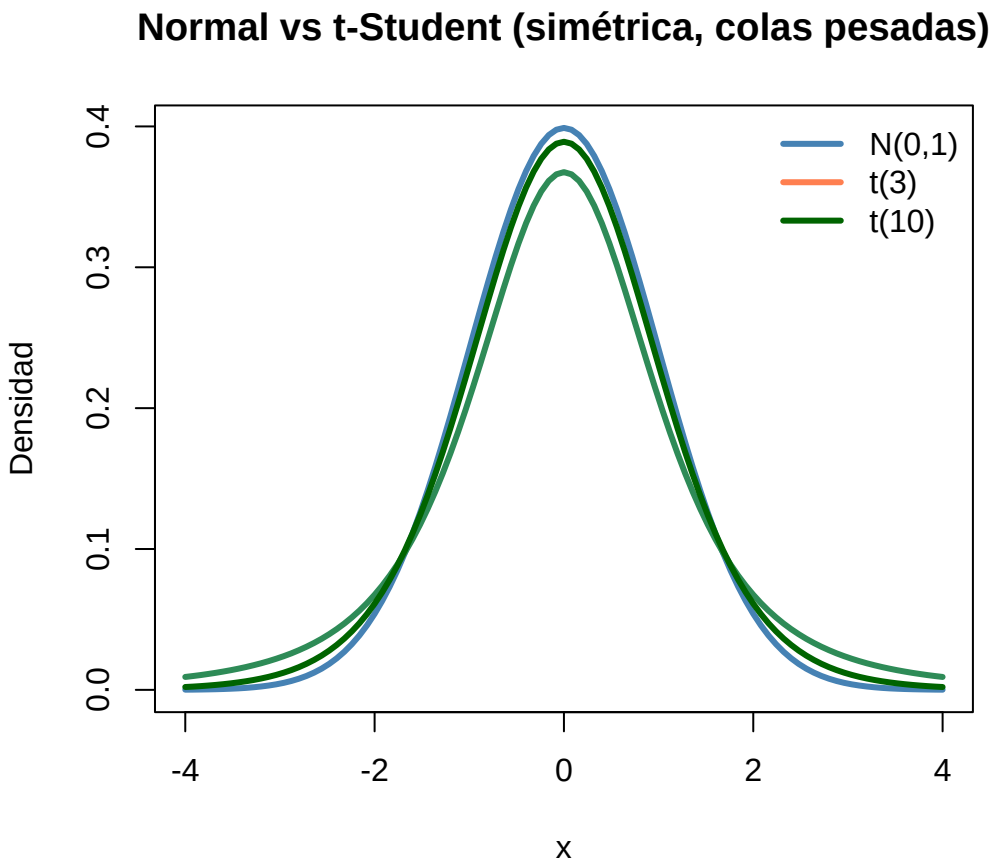
La distribución t-Student la usaremos en el Tema 4 para comparar medias de dos grupos de tratamiento en fisioterapia.

William S. Gosset (1908), químico de Guinness, publicó bajo el seudónimo **"Student"**. Descubrió que al estimar σ con s, el cociente $\frac{\bar{x}-\mu}{s/\sqrt{n}}$ NO sigue una Normal, sino una distribución con **colas más pesadas**.

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

Propiedades: - **Simétrica** alrededor de 0 (como la Normal) - Colas **más pesadas** que la Normal → valores extremos más probables - Cuando $n \to \infty$, $t_{n-1} \to N(0,1)$ - Un solo parámetro: grados de libertad ($gl = n - 1$)

```
curve(dnorm(x), -4, 4, lwd=3, col="steelblue", ylab="Densidad",
      main="Normal vs t-Student (simétrica, colas pesadas)")
curve(dt(x, 3), -4, 4, lwd=3, col="seagreen", add=TRUE)
curve(dt(x, 10), -4, 4, lwd=3, col="darkgreen", add=TRUE)
legend("topright", c("N(0,1)","t(3)","t(10)"), col=c("steelblue","coral","darkgreen"), lwd=3
```



Uso principal: IC para la media con σ desconocida, tests t para una y dos muestras.

Distribución χ^2 (Chi-Cuadrado) — Pearson

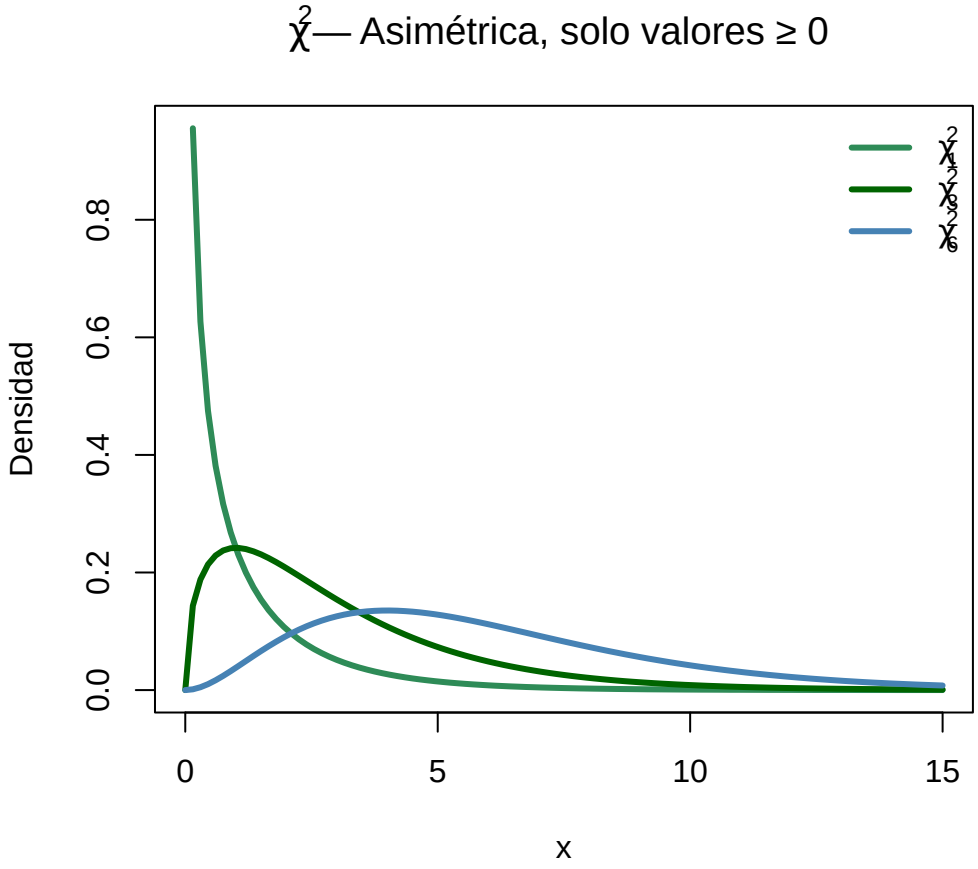
La distribución ^{2} la usaremos en el Tema 5 para analizar tablas de contingencia y estudiar la asociación entre tratamientos de fisioterapia y resultados clínicos.

Karl Pearson (1900). Surge como suma de k normales estándar independientes al cuadrado:

$$\chi^2_k = Z_1^2 + Z_2^2 + \cdots + Z_k^2 \sim \chi^2_k$$

Propiedades: - **NO es simétrica** (asimétrica positiva, cola a la derecha) - Solo toma valores ≥ 0 - $E(\chi^2_k) = k$, $\text{Var}(\chi^2_k) = 2k$ - Cuando $k \to \infty$, tiende a Normal

```r
curve(dchisq(x, 1), 0, 15, lwd=3, col="seagreen", ylab="Densidad",
      main=expression(paste(chi^2, " - Asimétrica, solo valores  0")))
curve(dchisq(x, 3), 0, 15, lwd=3, col="darkgreen", add=TRUE)
curve(dchisq(x, 6), 0, 15, lwd=3, col="steelblue", add=TRUE)
legend("topright", c(expression(chi[1]^2),expression(chi[3]^2),expression(chi[6]^2)),
       col=c("seagreen","darkgreen","steelblue"), lwd=3, bty="n")
```



Uso principal: Test χ^2 para tablas de contingencia, test de bondad de ajuste.

Distribución F de Snedecor

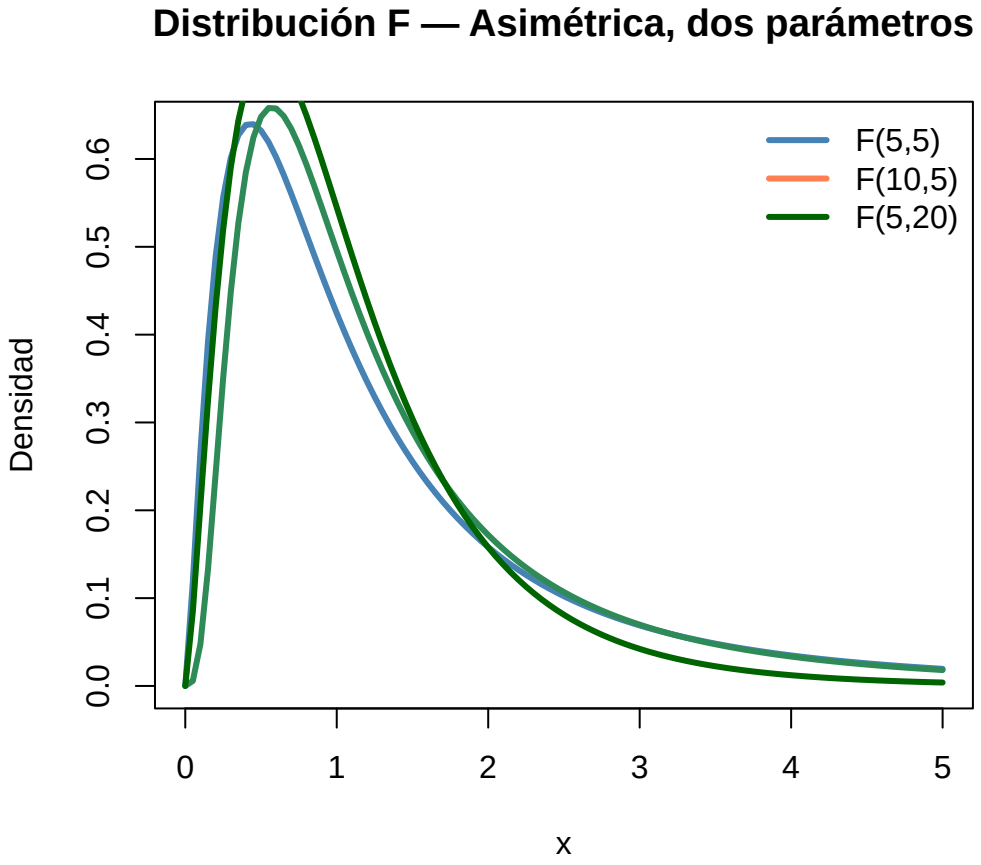
La distribución F la usaremos en el Tema 6 al evaluar modelos de regresión y comparar la variabilidad explicada por distintas variables clínicas.

George W. Snedecor (1934), nombrada en honor a **R.A. Fisher**. Surge como cociente de dos χ^2 independientes divididas por sus grados de libertad:

$$F_{k_1,k_2} = \frac{\chi^2_{k_1}/k_1}{\chi^2_{k_2}/k_2}$$

Propiedades: - **NO es simétrica** (asimétrica positiva, como χ^2) - Solo toma valores ≥ 0 - Dos parámetros: gl_1 (numerador) y gl_2 (denominador)

```
curve(df(x, 5, 5), 0, 5, lwd=3, col="steelblue", ylab="Densidad",
      main="Distribución F - Asimétrica, dos parámetros")
curve(df(x, 10, 5), 0, 5, lwd=3, col="seagreen", add=TRUE)
curve(df(x, 5, 20), 0, 5, lwd=3, col="darkgreen", add=TRUE)
legend("topright", c("F(5,5)","F(10,5)","F(5,20)"), col=c("steelblue","coral","darkgreen"), l
```



Uso principal: Test F para igualdad de varianzas, ANOVA, regresión (test F global).

Cálculo de p-valores — ¡cuidado con la asimetría!

Distribución	¿Simétrica?	P-valor bilateral	Función R
Normal	Sí	`2 * pnorm(-abs(z))`	`pnorm()`
t-Student	Sí	`2 * pt(-abs(t), df)`	`pt()`
χ^2	**No**	**No tiene sentido bilateral** (test de una cola)	`pchisq()`
F	**No**	Usar cola adecuada según F_{obs}	`pf()`

Para χ^2 y F (asimétricas), el test es inherentemente unilateral porque solo nos preocupan valores grandes del estadístico (discrepancias grandes de H_0).

```
# P-valor para  ²  (siempre cola derecha)
chi_obs <- 13.87; gl <- 6
p_chi <- pchisq(chi_obs, gl, lower.tail=FALSE)
cat(" ² =", chi_obs, "gl =", gl, "→ P =", round(p_chi, 4))
```

```
 ² = 13.87 gl = 6 → P = 0.0311
```

```
# P-valor para F (cola derecha si F > 1)
F_obs <- 3.5; gl1 <- 5; gl2 <- 20
p_F <- pf(F_obs, gl1, gl2, lower.tail=FALSE)
cat("\nF =", F_obs, "gl =", gl1, ",", gl2, "→ P =", round(p_F, 4))
```

```

F = 3.5 gl = 5 , 20 → P = 0.0196
```

> **Warning**
>
> **Para estudiantes:** t es simétrica → P-valor bilateral se calcula como $2 \times P(T > |t|)$. χ^2 y F **no** son simétricas → el P-valor se calcula solo en la cola correspondiente. **Nunca** multipliques por 2 para χ^2 o F.

Guía rápida: ¿qué distribución uso en fisioterapia?

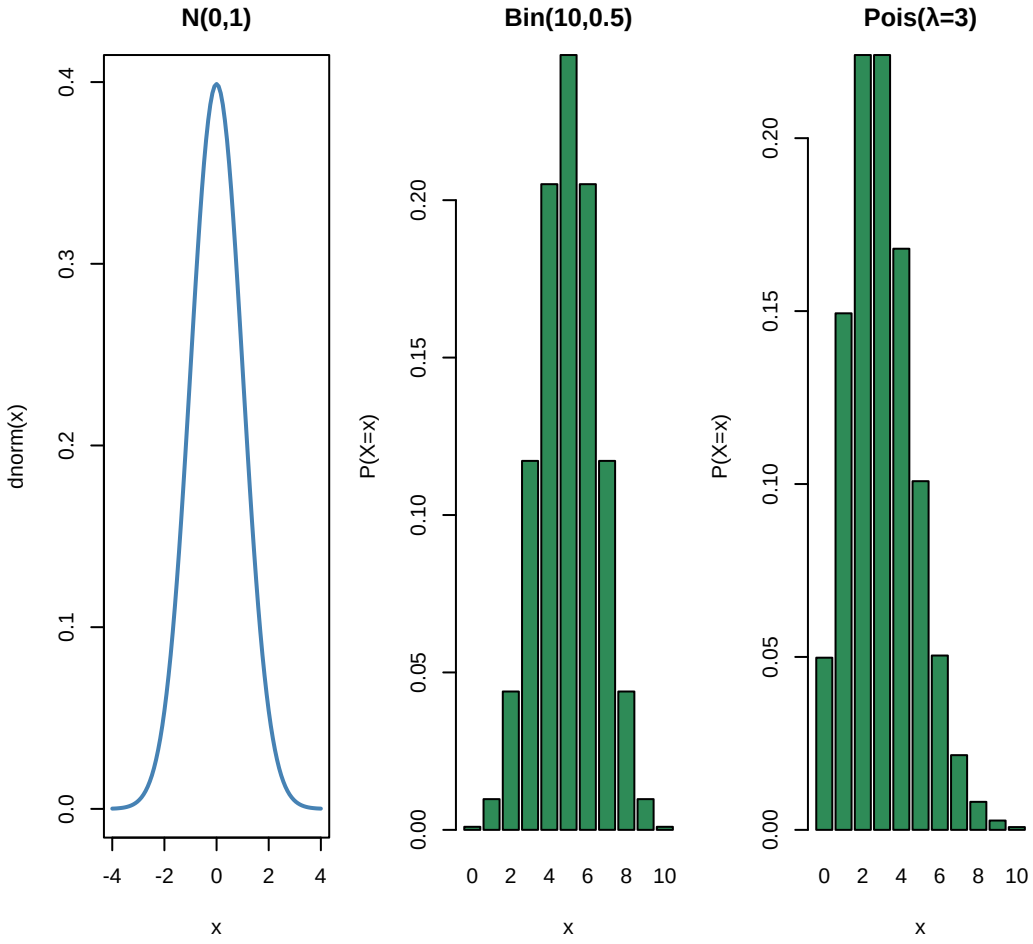
Situación clínica	Distribución	Parámetros	Función R
ROM, fuerza, PA (variables continuas)	**Normal**	μ, σ	`dnorm()`, `pnorm()`
Éxitos en n pacientes (curación, mejoría)	**Binomial**	n, p	`dbinom()`, `pbinom()`
Eventos raros por unidad de tiempo	**Poisson**	λ	`dpois()`, `ppois()`
Inferencia sobre medias	**t-Student**	gl	`dt()`, `pt()`
Comparación de varianzas	**F de Snedecor**	gl_1, gl_2	`df()`, `pf()`
Tablas de contingencia	χ^2	gl	`dchisq()`, `pchisq()`

> **Tip**
>
> **Regla nemotécnica:** `d` = densidad/probabilidad puntual, `p` = probabilidad acumulada (CDF), `q` = cuantil (percentil), `r` = aleatorio.

Comparativa de las tres distribuciones

	Normal	Binomial	Poisson
Tipo	Continua	Discreta	Discreta
Parámetros	μ, σ	n, p	λ
Soporte	$\mathbb{R}$	$\{0, \dots, n\}$	$\{0, 1, 2, \dots\}$
$E(X)$	μ	np	λ
Var(X)	σ^2	$np(1-p)$	λ
Ejemplo clínico	ROM, fuerza	Éxitos terapéuticos	Eventos adversos

```r
par(mfrow=c(1,3), mar=c(4,4,3,1))
curve(dnorm(x), -4,4, col="steelblue", lwd=2, main="N(0,1)", xlab="x")
barplot(dbinom(0:10,10,0.5), names=0:10, col="seagreen",
        main="Bin(10,0.5)", xlab="x", ylab="P(X=x)")
barplot(dpois(0:10,3), names=0:10, col="seagreen",
        main="Pois( =3)", xlab="x", ylab="P(X=x)")
```




```r
par(mfrow=c(1,1))
```

Aproximaciones y Teorema Central del Límite

Conexión T02→T03: Las aproximaciones entre distribuciones son la base del Teorema Central del Límite, que en el Tema 3 nos permitirá construir intervalos de confianza para cualquier parámetro.

¿Por Qué Aproximamos? — Motivación

Calcular probabilidades exactas con la Binomial requiere evaluar factores combinatorios $\binom{n}{k}$ que se vuelven **imposibles de calcular a mano** cuando n es grande. Las aproximaciones nos permiten usar la **Normal** (mucho más manejable) en su lugar.

Idea clave: Bajo ciertas condiciones, las distribuciones discretas "se parecen" a la Normal cuando el tamaño muestral es grande. Esto es consecuencia del **Teorema Central del Límite**.

Aproximación	Condición	Fórmula
Binomial $\to$ Normal	$np \geq 5$ y $n(1-p) \geq 5$	$B(n,p) \approx N(np,\ np(1-p))$
Poisson $\to$ Normal	$\lambda \geq 10$	$Po(\lambda) \approx N(\lambda,\ \lambda)$

Binomial $\to$ Normal — Condiciones y visualización

¿Cuándo funciona? Cuando $np \geq 5$ y $n(1-p) \geq 5$, el histograma binomial adopta forma de campana.

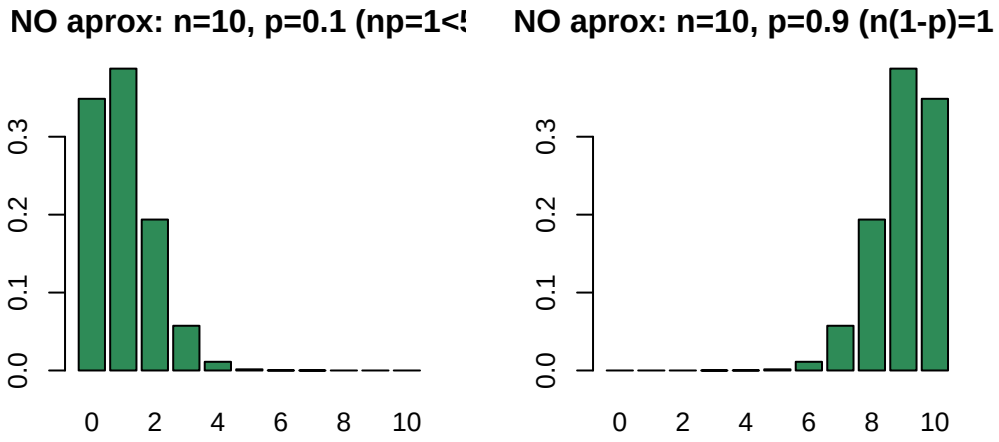
```
par(mfrow=c(2,2), mar=c(4,4,3,1))

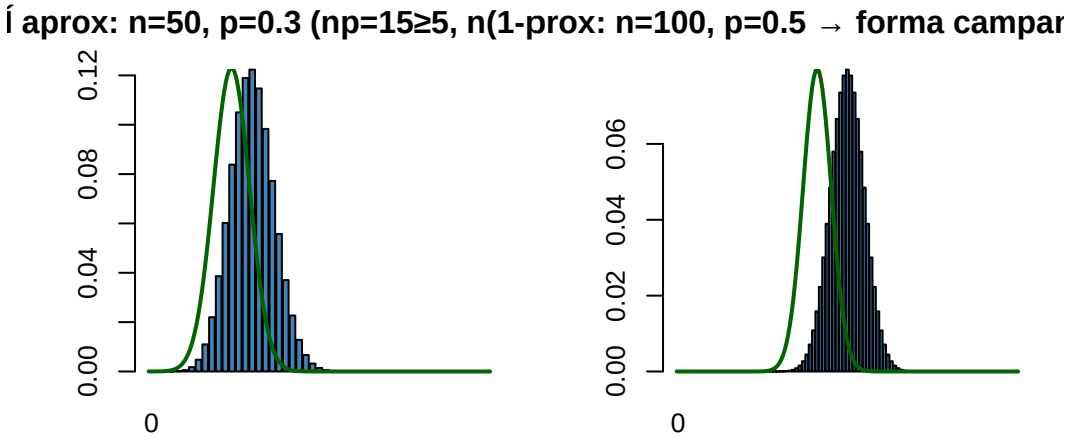
# Caso 1: NO se cumple (n=10, p=0.1 → np=1 < 5)
n<-10; p<-0.1; x<-0:n
barplot(dbinom(x,n,p), names=x, col="seagreen", main=paste0("NO aprox: n=",n,", p=",p," (np="

# Caso 2: NO se cumple (n=10, p=0.9 → n(1-p)=1 < 5)
p<-0.9
barplot(dbinom(x,n,p), names=x, col="seagreen", main=paste0("NO aprox: n=",n,", p=",p," (n(1-

# Caso 3: SÍ se cumple (n=50, p=0.3 → np=15, n(1-p)=35 5)
n<-50; p<-0.3; x<-0:n
bp <- barplot(dbinom(x,n,p), names=ifelse(x%%5==0,x,""), col="steelblue",
        main=paste0("SÍ aprox: n=",n,", p=",p," (np=",n*p," 5, n(1-p)=",n*(1-p)," 5)"))
curve(dnorm(x,n*p,sqrt(n*p*(1-p)))*1, add=T, col="darkgreen", lwd=2, n=200)

# Caso 4: SÍ se cumple (n=100, p=0.5 → ambos  5)
n<-100; p<-0.5; x<-0:n
bp <- barplot(dbinom(x,n,p), names=ifelse(x%%25==0,x,""), col="steelblue",
        main=paste0("SÍ aprox: n=",n,", p=",p," → forma campana perfecta"))
curve(dnorm(x,n*p,sqrt(n*p*(1-p)))*1, add=T, col="darkgreen", lwd=2, n=200)
```






```r
par(mfrow=c(1,1))
```

Binomial → Normal — Corrección de continuidad

La Binomial es **discreta** (barras) y la Normal es **continua** (curva). Para aproximar $P(X \leq k)$, sumamos/restamos 0.5:

Probabilidad	Sin corrección	Con corrección (± 0.5)
$P(X \leq k)$	$\Phi\left(\frac{k-np}{\sqrt{np(1-p)}}\right)$	$\Phi\left(\frac{k+0.5-np}{\sqrt{np(1-p)}}\right)$
$P(X \geq k)$	$1-\Phi\left(\frac{k-np}{\sqrt{np(1-p)}}\right)$	$1-\Phi\left(\frac{k-0.5-np}{\sqrt{np(1-p)}}\right)$

Ejemplo clínico: Fármaco 40% efectivo, $n = 20$ pacientes. $P(X \leq 10)$:

```
n<-20; p<-0.4; k<-10
exacto <- pbinom(k, n, p)
sin_corr <- pnorm(k, n*p, sqrt(n*p*(1-p)))
con_corr <- pnorm(k+0.5, n*p, sqrt(n*p*(1-p)))
cat("Exacto (Binomial):     ", round(exacto, 4),
    "\nNormal sin corrección: ", round(sin_corr, 4),
    "\nNormal con corrección:  ", round(con_corr, 4))
```

```
Exacto (Binomial):      0.8725
Normal sin corrección:  0.8193
Normal con corrección:   0.8731
```

> Tip
>
> **La corrección de continuidad (+0.5) reduce el error de aproximación drásticamente.** En el ejemplo, el error pasa de ~5pp a <0.1pp.

Poisson → Normal — Condiciones

¿Cuándo funciona? Cuando $\lambda \geq 10$, el histograma de Poisson adopta forma simétrica.

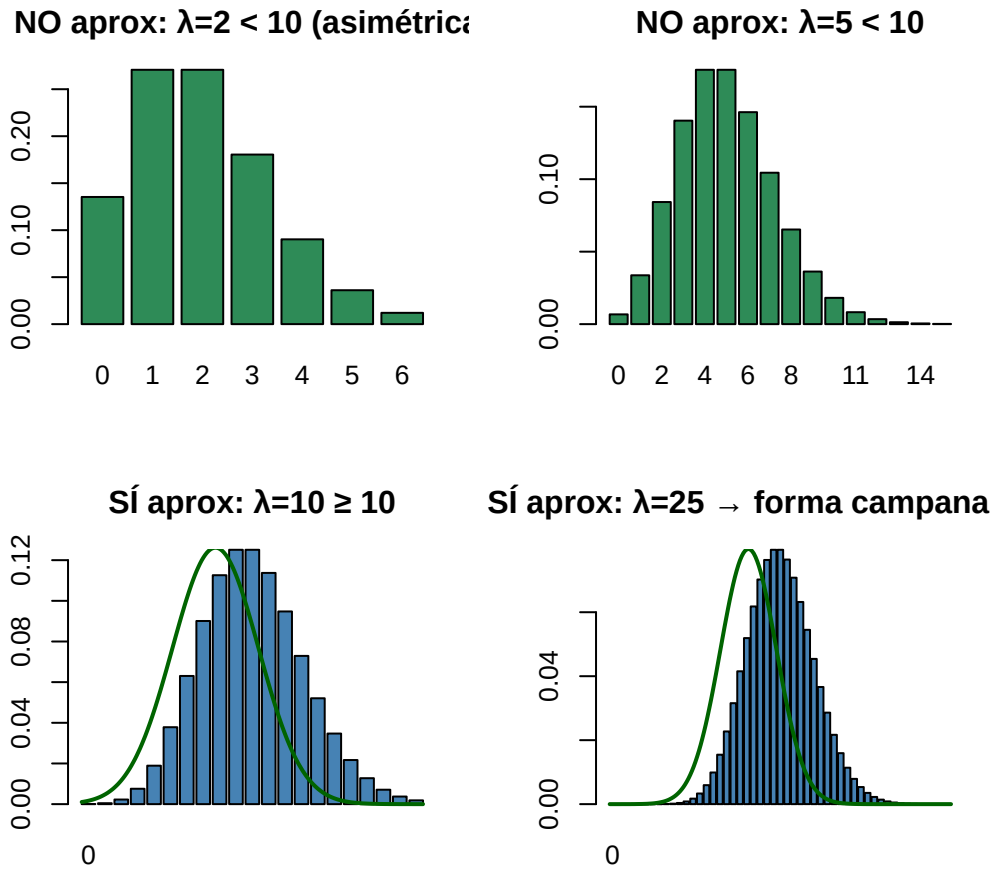
```
par(mfrow=c(2,2), mar=c(4,4,3,1))

# Caso 1:  =2 → NO se cumple (muy asimétrica)
lambda<-2; x<-0:(lambda*3)
barplot(dpois(x,lambda), names=x, col="seagreen",
        main=paste0("NO aprox:  =",lambda," < 10 (asimétrica)"))

# Caso 2:  =5 → NO se cumple (todavía asimétrica)
lambda<-5; x<-0:(lambda*3)
barplot(dpois(x,lambda), names=x, col="seagreen",
        main=paste0("NO aprox:  =",lambda," < 10"))

# Caso 3:  =10 → SÍ se cumple (empieza a ser simétrica)
lambda<-10; x<-0:(lambda*2)
bp <- barplot(dpois(x,lambda), names=ifelse(x%%5==0,x,""), col="steelblue",
        main=paste0("SÍ aprox:  =",lambda,"   10"))
curve(dnorm(x,lambda,sqrt(lambda))*1, add=T, col="darkgreen", lwd=2, n=200)
```

```r
# Caso 4:  =25 → SÍ se cumple (claramente acampanada)
lambda<-25; x<-0:(lambda*2)
bp <- barplot(dpois(x,lambda), names=ifelse(x%%10==0,x,""), col="steelblue",
        main=paste0("SÍ aprox:  =",lambda," → forma campana clara"))
curve(dnorm(x,lambda,sqrt(lambda))*1, add=T, col="darkgreen", lwd=2, n=200)
```




```r
par(mfrow=c(1,1))
```

```r
lambda<-10; k<-7
exacto <- ppois(k, lambda)
con_corr <- pnorm(k+0.5, lambda, sqrt(lambda))
cat("Exacto (Poisson):       ", round(exacto, 4),
    "\nNormal con corrección:  ", round(con_corr, 4))
```

```
Exacto (Poisson):        0.2202
Normal con corrección:   0.2146
```

¿Por Qué Usamos Aproximaciones?

1. **Cálculo manual:** Con $n = 100$, calcular $\binom{100}{50}$ a mano es imposible. La Normal lo resuelve con una fórmula simple.
2. **Inferencia:** Los IC y tests de hipótesis para proporciones usan la aproximación Normal (por eso usamos z_α, no t).
3. **Teoría:** El TCL garantiza que **cualquier** suma de variables independientes tiende a la Normal cuando n es grande — es la base de toda la inferencia estadística.
4. **Software moderno:** Aunque R calcula valores exactos, entender las aproximaciones ayuda a comprender **por qué** funcionan los métodos estadísticos.

> **!** Important
>
> **Condiciones para aplicar la aproximación Normal a la Binomial:** $np \geq 5$ **Y** $n(1-p) \geq 5$. Si no se cumplen, usar el método exacto (Binomial). **Para Poisson:** $\lambda \geq 10$. Si no, usar el método exacto (Poisson).

Ejercicio Clínico — Aplicación de Probabilidad y Distribuciones

Un estudio sobre recuperación funcional tras accidente cerebrovascular reporta que el 30% de los pacientes recupera la marcha independiente en 6 meses.

1. Si tratas a 10 pacientes, ¿cuál es la probabilidad de que exactamente 4 recuperen la marcha? Usa `dbinom(4, 10, 0.3)`.
2. ¿Y la probabilidad de que al menos 6 recuperen la marcha? Usa `pbinom(5, 10, 0.3, lower.tail=FALSE)`.
3. Las puntuaciones de Barthel a los 6 meses siguen una Normal(75, 15). Un paciente obtiene 95. Calcula su Z-score: `(95-75)/15`. ¿Es un valor atípico?
4. ¿Qué percentil ocupa? `pnorm(95, 75, 15)`. Interpreta el resultado.

Resumen — Tema 2

- **Probabilidad** como herramienta para cuantificar incertidumbre clínica (Kolmogorov, Bayes)
- **Probabilidad condicionada** → Teorema de Bayes → VPP y VPN: herramientas clave para interpretar pruebas diagnósticas
- **Variables aleatorias discretas:** Binomial (nº de éxitos terapéuticos), Poisson (eventos adversos)
- **Variables aleatorias continuas:** Normal (la distribución central en clínica), t-Student, ^{2}, F
- **Función de densidad y distribución:** $f(x)$ describe la forma, $F(x) = P(X \leq x)$ calcula probabilidades
- **Aproximaciones y TCL:** la Normal como límite universal → base de la inferencia en T3
- **Funciones R `d`, `p`, `q`, `r`** para trabajar con cualquier distribución

---

Referencias complementarias del libro:

Referencias

- (Femia & Luque-Fernández, 2026) Femia, P. & Luque-Fernández, M. A. (2026). *BioEstatR: Biostatistics Routines in R*. R package v1.0.0. Universidad de Granada. https://migariane.github.io/BioEstatR
- (Kolmogorov, 1933) Kolmogorov, A. N. (1933). *Grundbegriffe der Wahrscheinlichkeitsrechnung*. Springer.
- (Luque-Fernández, 2026) Luque-Fernández, M. A. (2026). *Matemáticas para la Estadística Médica con R*. Cap. 3: Fundamentos de Probabilidad. Universidad de Granada. https://migariane.github.io/MatematicaEstadisticaMedicinaR
- (Luque-Fernández, 2026) Luque-Fernández, M. A. (2026). *Matemáticas para la Estadística Médica con R*. Cap. 4: Variables Aleatorias y Distribuciones. Universidad de Granada.

Ejercicio Clínico — Tema II (Parte II)

Contexto: Fuerza de prensión $\sim N(30, 8^2)$ kg. Paciente con 22 kg. Terapia con 70% éxito por paciente.

1. Calcula Z-score de 22 kg e interpreta

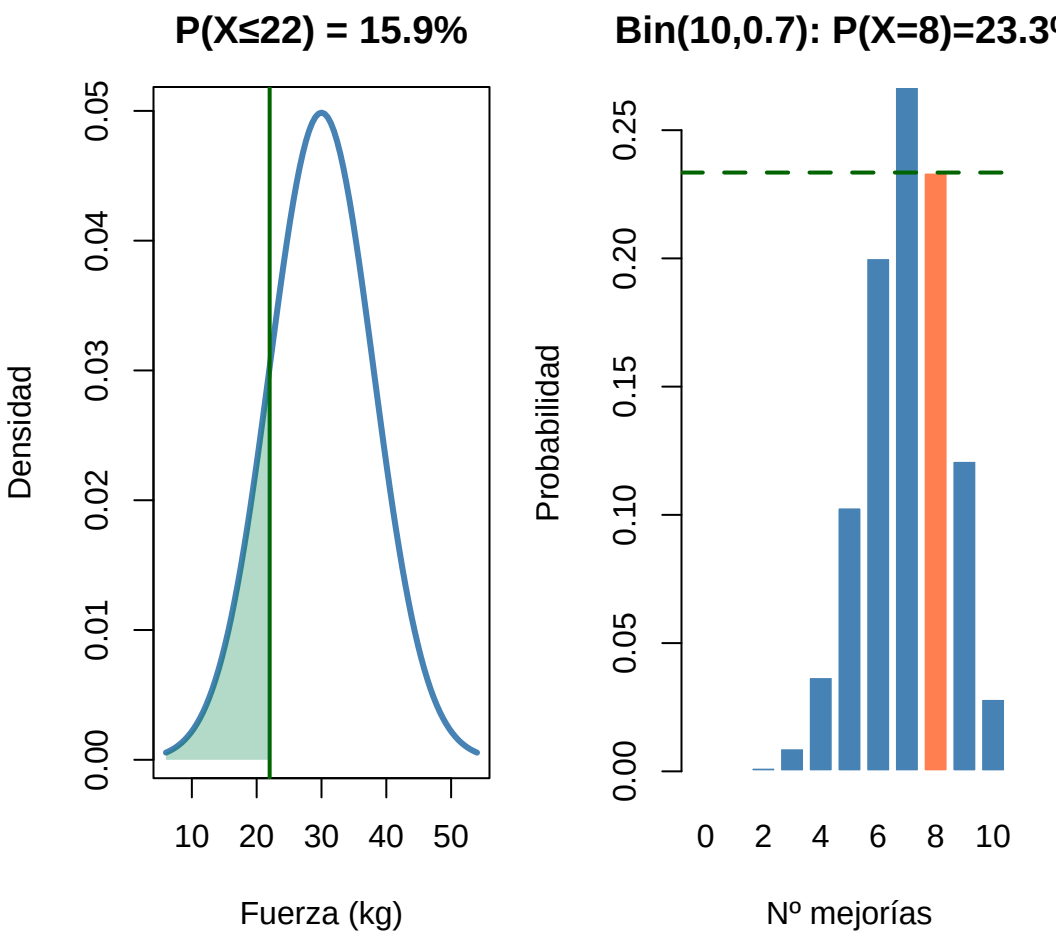
2. ¿% población con fuerza ≤ 22 kg?
3. Tratando 10 pacientes, ¿P(exactamente 8 mejorías)?

Tip

Solución

1. $Z = (22 - 30)/8 = -1.0 \rightarrow 1$ DE bajo la media
2. $P(X \leq 22) = 15.9\%$ de la población
3. $P(X = 8) = \binom{10}{8}(0.7)^8(0.3)^2 = 23.3\%$

```
mu <- 30; sigma <- 8
par(mfrow=c(1,2), mar=c(4,4,3,1))
# Panel 1: Distribución normal
curve(dnorm(x, mu, sigma), mu-24, mu+24, lwd=3, col="steelblue",
      main=paste0("P(X 22) = ", round(pnorm(22,mu,sigma)*100,1),"%"),
      xlab="Fuerza (kg)", ylab="Densidad")
abline(v=22, col="darkgreen", lwd=2)
xr <- seq(mu-24, 22, 0.1)
polygon(c(xr, rev(xr)), c(dnorm(xr,mu,sigma), rep(0,length(xr))),
        col=rgb(0,0.5,0.3,0.3), border=NA)
# Panel 2: Binomial
p_binom <- dbinom(8, 10, 0.7)
probs <- dbinom(0:10, 10, 0.7)
highlight <- ifelse(0:10==8, "coral", "steelblue")
barplot(probs, names=0:10, col=highlight, border="white",
        main=paste0("Bin(10,0.7): P(X=8)=", round(p_binom*100,1),"%"),
        xlab="Nº mejorías", ylab="Probabilidad")
abline(h=p_binom, col="darkgreen", lty=2, lwd=2)
```




```
par(mfrow=c(1,1))

cat("Z =", round((22-30)/8,1), "\nP(X 22) =", round(pnorm(22,30,8)*100,1), "%",
    "\nP(X=8) =", round(dbinom(8,10,0.7)*100,1), "%")
```

```
Z = -1
P(X 22) = 15.9 %
P(X=8) = 23.3 %
```

Código del Tema II (Parte II) — Resumen Organizado

Distribución Normal y estandarización

```
# Propiedades N( ,  ²)
mu <- 30; sigma <- 8
pnorm(22, mu, sigma)                        # P(X < 22) = 15.9%
pnorm(38, mu, sigma) - pnorm(22, mu, sigma)  # P(22 < X < 38) = 68.3%

# Z-scores
z <- (22 - 30) / 8                          # Z = -1.0
pnorm(-1)                                    # P(Z < -1) = 15.9%

# Percentiles clave
qnorm(0.975)                                 # Z = 1.96 (IC 95%)
qnorm(0.995)                                 # Z = 2.576 (IC 99%)

# lower.tail = FALSE para cola derecha
pnorm(1.96, lower.tail = FALSE)              # P(Z > 1.96) = 2.5%
```

Distribuciones discretas

```
# Binomial(n, p) - nº de éxitos en n ensayos
n <- 10; p <- 0.7
dbinom(8, n, p)                              # P(X = 8) exacto
pbinom(7, n, p)                              # P(X   7)
pbinom(7, n, p, lower.tail = FALSE)          # P(X > 7) = P(X   8)

# Poisson( ) - nº de eventos en intervalo
lambda <- 4
dpois(3, lambda)                             # P(X = 3)
ppois(2, lambda)                             # P(X   2)

#  ²  y F - colas asimétricas
pchisq(13.87, 6, lower.tail = FALSE)         # P( ²  > 13.87)
pf(3.5, 5, 20, lower.tail = FALSE)           # P(F ,   > 3.5)
```

Aproximaciones

```r
# Binomial → Normal: np > 5 y n(1-p) > 5
n <- 50; p <- 0.3
p_exacto <- pbinom(10, n, p)
p_normal <- pnorm(10.5, n*p, sqrt(n*p*(1-p)))  # Con corrección +0.5

# Poisson → Normal:  > 10
lambda <- 25
p_pois <- ppois(20, lambda)
p_norm <- pnorm(20.5, lambda, sqrt(lambda))    # Con corrección +0.5
```


Femia, P., & Luque-Fernández, M. A. (2026). *BioEstatR: Biostatistics routines in r*. https://migariane.github.io/BioEstatR

Kolmogorov, A. N. (1933). *Grundbegriffe der wahrscheinlichkeitsrechnung*. Springer.

Luque-Fernández, M. A. (2026). *Matemáticas para la estadística médica con r*. Universidad de Granada. https://migariane.github.io/MatematicaEstadisticaMedicinaR