

# Probabilidad y Variables Aleatorias con R

## Tema II (Parte II) — La Distribución Normal, Modelos Discretos y Aproximaciones

Miguel Angel Luque-Fernández

2026-01-01

### Herramientas Computacionales para Distribuciones

**Conexión:** R dispone de funciones específicas para cada distribución de probabilidad. Aprender a usarlas correctamente es tan importante como entender la teoría.

#### `lower.tail` — La Opción Más Útil de las Funciones `p`

Todas las funciones `p` (acumuladas) tienen el argumento `lower.tail`:

`lower.tail = TRUE` (por defecto):

- `pnorm(k) = P(X ≤ k)`
- `pbinom(k, n, p) = P(X ≤ k)`
- `ppois(k, lambda) = P(X ≤ k)`

Calcula el área desde  $-\infty$  hasta  $k$

`lower.tail = FALSE`:

- `pnorm(k, lower.tail=FALSE) = P(X > k)`
- `pbinom(k, n, p, lower.tail=FALSE) = P(X > k)`
- `ppois(k, lambda, lower.tail=FALSE) = P(X > k)`

Calcula el área desde  $k$  hasta  $+\infty$

**Equivalencia fundamental:**

```
n<-10; p<-0.5; k<-3
# Estas dos expresiones son EXACTAMENTE IGUALES:
pbinom(k, n, p, lower.tail=FALSE) # P(X > 3)
```

```
[1] 0.828125
```

```
1 - pbinom(k, n, p) # 1 - P(X ≤ 3)
```

```
[1] 0.828125
```

## lower.tail — Equivalencias y Precauciones

Variables continuas (Normal, t,  $\chi^2$ , F):

```
# P(X > 1.96) es IDÉNTICO a:
pnorm(1.96, lower.tail=FALSE)
```

```
[1] 0.0249979
```

```
1 - pnorm(1.96)
```

```
[1] 0.0249979
```

Variables discretas (Binomial, Poisson):

```
# ¡CUIDADO! P(X > 3) = P(X ≥ 4)
pbinom(3, 10, 0.5, lower.tail=FALSE) # P(X > 3) = P(X ≥ 4)
```

```
[1] 0.828125
```

```
1 - pbinom(4-1, 10, 0.5) # P(X ≥ 4) = 1 - P(X ≤ 3)
```

```
[1] 0.828125
```

| Quiero calcular... | Normal (continua)           | Binomial/Poisson (discreta)       |
|--------------------|-----------------------------|-----------------------------------|
| $P(X \leq k)$      | pnorm(k)                    | pbinom(k, n, p) / ppois(k, )      |
| $P(X < k)$         | pnorm(k) (= $P(X \leq k)$ ) | pbinom(k-1, n, p)                 |
| $P(X > k)$         | pnorm(k, lower.tail=FALSE)  | pbinom(k, n, p, lower.tail=FALSE) |

| Quiero calcular... | Normal (continua)                                       | Binomial/Poisson (discreta)    |
|--------------------|---------------------------------------------------------|--------------------------------|
| $P(X \geq k)$      | <code>pnorm(k, lower.tail=FALSE)</code> (= $P(X > k)$ ) | $1 - \text{pbinom}(k-1, n, p)$ |

### ⚠ Warning

**Truco para estudiantes:** En variables **discretas** (Binomial, Poisson),  $P(X < k) \neq P(X \leq k)$ . La diferencia es  $P(X = k)$ . Usad `lower.tail=FALSE` para colas derechas y recordad restar 1 al límite para desigualdades estrictas.

## La Distribución Normal y sus Aproximaciones

**Puente con T03 — Estimación:** La distribución Normal es la base del Teorema Central del Límite, que veremos en el Tema 3. Todo lo que aprendas aquí sobre `pnorm()`, `qnorm()` y Z-scores se usará para construir intervalos de confianza y contrastes de hipótesis.


### Distribución Normal — Historia y contexto

**Carl Friedrich Gauss (1777–1855)** introdujo esta distribución estudiando errores de medición astronómica. Originalmente llamada “**campana de Gauss**”, hoy es la distribución más importante en estadística.

**¿Por qué es tan ubicua?** Por el **Teorema Central del Límite**: la suma de muchas variables independientes tiende a una Normal, sin importar su distribución original. Por eso aparece en biología, medicina, economía, física...

```
curve(dnorm(x, 0, 1), -4, 4, lwd=3, col="steelblue",
      main=expression(paste("Distribución Normal ", N(mu, sigma^2))),
      xlab="x", ylab=expression(f(x)))
#   ±   (68%)
x1<-seq(-1,1,0.01); polygon(c(x1,rev(x1)),c(dnorm(x1),rep(0,length(x1))),col=rgb(0,0,1,0.2),lty=2)
#   ± 2  (95%)
x2<-seq(-2,2,0.01); polygon(c(x2,rev(x2)),c(dnorm(x2),rep(0,length(x2))),col=rgb(0,0,1,0.1),lty=2)
abline(v=c(-2,-1,0,1,2), lty=c(3,2,1,2,3), col=c("grey","grey","coral","grey","grey"))
text(0, 0.25, "68%", cex=1.2); text(0, 0.05, "95%", cex=1.2)
```

## Distribución Normal $N(\mu, \sigma^2)$



La curva normal describe la distribución de errores y de fenómenos naturales donde muchas causas pequeñas se suman. Hoy, en fisioterapia, modela: fuerza muscular, ROM articular, presión arterial, y prácticamente cualquier variable biológica continua.

### Distribución Normal — Fórmula y propiedades

#### Note

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}, \quad -\infty < x < \infty$$

- $\mu$  = media (centro de la campana),  $\sigma$  = desviación típica (dispersión)
- $E(X) = \mu$ ,  $\text{Var}(X) = \sigma^2$
- **Simétrica:** media = mediana = moda


- $\mu \pm \sigma$  contiene 68%,  $\mu \pm 2\sigma$  contiene 95%,  $\mu \pm 3\sigma$  contiene 99.7%

**Ejemplo clínico:** Fuerza de prensión manual:  $X \sim N(30, 8^2)$  kg

## Visualización de la distribución Normal

Efecto de cambiar  $\mu$  y  $\sigma$  en la forma de la campana:

```
par(mfrow=c(1,2), mar=c(4,4,3,1))
# Cambiar
curve(dnorm(x, 0, 1), -5, 8, lwd=3, col="steelblue", ylab="Densidad",
      main=expression(paste("Cambiando ", mu, " (", sigma, "=1)")), xlab="x")
curve(dnorm(x, 2, 1), -5, 8, lwd=3, col="seagreen", add=TRUE)
curve(dnorm(x, 4, 1), -5, 8, lwd=3, col="darkgreen", add=TRUE)
abline(v=c(0,2,4), lty=2, col=c("steelblue","seagreen","darkgreen"))
legend("topright", c(expression(mu==0),expression(mu==2),expression(mu==4)),
      col=c("steelblue","coral","darkgreen"), lwd=3, bty="n")
# Cambiar
curve(dnorm(x, 0, 0.5), -5, 5, lwd=3, col="steelblue", ylab="",
      main=expression(paste("Cambiando ", sigma, " (", mu, "=0)")), xlab="x")
curve(dnorm(x, 0, 1), -5, 5, lwd=3, col="seagreen", add=TRUE)
curve(dnorm(x, 0, 2), -5, 5, lwd=3, col="darkgreen", add=TRUE)
legend("topright", c(expression(sigma==0.5),expression(sigma==1),expression(sigma==2)),
      col=c("steelblue","coral","darkgreen"), lwd=3, bty="n")
```



```
par(mfrow=c(1,1))
```

$\mu$  desplaza,  $\sigma$  ensancha. La Normal es simétrica: media = mediana = moda.

## Estandarización — El concepto más importante

La visualización comparativa de escalas originales vs. estandarizadas se muestra en la siguiente diapositiva.

! Important

**Definición general:** La estandarización transforma cualquier variable para que tenga media 0 y varianza 1:

$$Z = \frac{X - E(X)}{\sqrt{\text{Var}(X)}} = \frac{X - \mu_X}{\sigma_X}$$

Si  $X \sim N(\mu, \sigma^2)$ , entonces  $Z \sim N(0, 1)$ . La distribución  $N(0, 1)$  se llama **Normal estándar**.

**Propiedades fundamentales de Z:** -  $E(Z) = 0$  y  $\text{Var}(Z) = 1$  (siempre, para cualquier distribución) - **Adimensional:** Z no tiene unidades  $\rightarrow$  permite **comparar** variables completamente diferentes -  $Z = 2$  siempre significa “2 desviaciones estándar por encima de la media”, sea cual sea la variable original

### ¿Por Qué es Fundamental la Estandarización?

1. **Permite usar una única tabla de probabilidades:** Sin estandarización, necesitaríamos infinitas tablas (una para cada combinación de  $\mu$  y  $\sigma$ ). Con Z, solo necesitamos la tabla de la  $N(0, 1)$ .
2. **Hace comparables mediciones distintas:** ¿Qué es más extremo: una presión arterial de 150 mmHg o un IMC de 32 kg/m<sup>2</sup>? Los Z-scores responden:  $z_{PA} = (150 - 120)/15 = 2.0$  vs  $z_{IMC} = (32 - 25)/4 = 1.75 \rightarrow$  la PA es más extrema.
3. **Base de toda la inferencia:** Los intervalos de confianza y tests de hipótesis usan valores estandarizados ( $z_{\alpha/2} = 1.96$ ,  $t_{\alpha/2}$ ).

### Z-scores en la práctica clínica

**Tensión Arterial Sistólica:**  $X \sim N(120, 15^2)$  mmHg

| Paciente | TA (mmHg) | $Z = \frac{X-120}{15}$ | Interpretación clínica                       |
|----------|-----------|------------------------|----------------------------------------------|
| A        | 120       | 0.0                    | En la media poblacional                      |
| B        | 135       | 1.0                    | 1 DE por encima                              |
| C        | 105       | -1.0                   | 1 DE por debajo                              |
| D        | 150       | <b>2.0</b>             | 2 DE por encima $\rightarrow$ <b>HTA</b>     |
| E        | 90        | -2.0                   | 2 DE por debajo $\rightarrow$<br>Hipotensión |

```
cat("Paciente D: z =", round((150-120)/15,1),
    "\n→ P(Z > 2) =", round(pnorm(2, lower.tail=FALSE),4),
    "\nPaciente E: z =", round((90-120)/15,1),
    "\n→ P(Z < -2) =", round(pnorm(-2),4))
```

Paciente D:  $z = 2 \rightarrow P(Z > 2) = 0.0228$   
 Paciente E:  $z = -2 \rightarrow P(Z < -2) = 0.0228$

## Estandarización — Más ejemplos clínicos

**LDL-Colesterol:**  $X \sim N(130, \sigma^2 = 40)$  mg/dL  $\rightarrow \sigma = \sqrt{40} \approx 6.32$

| Cálculo                | Fórmula                          | Resultado                                  |
|------------------------|----------------------------------|--------------------------------------------|
| Paciente con LDL = 140 | $z = \frac{140-130}{6.32}$       | $z \approx 1.58$                           |
| Percentil 90           | $x = 130 + z_{0.90} \times 6.32$ | $x \approx 130 + 1.28 \times 6.32 = 138.1$ |
| $P(LDL > 140)$         | $P(Z > 1.58)$                    | $\approx 0.057$ (5.7%)                     |

**Glucemia en ayunas:**  $X \sim N(100, 10^2)$  mg/dL

| Paciente    | Glucemia | Z-score    | Interpretación              |
|-------------|----------|------------|-----------------------------|
| Normal      | 90       | $z = -1.0$ | 1 DE bajo la media          |
| Límite      | 100      | $z = 0.0$  | En la media                 |
| Prediabetes | 120      | $z = 2.0$  | 2 DE arriba                 |
| Diabetes    | 140      | $z = 4.0$  | Muy extremo ( $P < 0.001$ ) |

```
glucemias <- c(90, 100, 120, 140)
z_gluc <- (glucemias - 100) / 10
cat("Z-scores glucemia:", round(z_gluc, 2),
    "\nP(Z > 4) =", round(pnorm(4, lower.tail=FALSE), 6))
```

Z-scores glucemia: -1 0 2 4  
 $P(Z > 4) = 3.2e-05$

## Estandarización y cálculo de probabilidades

**La clave práctica:** Para calcular cualquier probabilidad Normal, convertimos a Z y usamos  $N(0, 1)$ :

$$P(X \leq x) = P\left(Z \leq \frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$




```

mu <- 30; sigma <- 8; x_obs <- 22
z_obs <- (x_obs - mu) / sigma

par(mfrow=c(1,2), mar=c(4,4,3,1))
# Escala original  $X \sim N(30, 8^2)$ 
curve(dnorm(x, mu, sigma), mu-24, mu+24, lwd=3, col="steelblue",
      main=expression(paste("Original:  $X \sim N(30, ", 8^2, ")$ ")),
      xlab="Fuerza (kg)", ylab="f(x)")
abline(v=x_obs, col="darkgreen", lwd=2); text(x_obs, 0.04, "x=22", col="darkgreen", pos=4)

# Escala estandarizada  $Z \sim N(0,1)$ 
curve(dnorm(x), -4, 4, lwd=3, col="seagreen",
      main="Estandarizada:  $Z \sim N(0,1)$ ",
      xlab="Z", ylab=expression(phi(z)))
abline(v=z_obs, col="darkgreen", lwd=2); text(z_obs, 0.3, paste0("z=", z_obs), col="darkgreen")

```



```
par(mfrow=c(1,1))


cat("X =", x_obs, "kg → Z =", round(z_obs,2),
    " P(X <", x_obs,") = P(Z <", round(z_obs,2),") =",
    round(pnorm(x_obs, mu, sigma), 4))
```

$X = 22 \text{ kg} \rightarrow Z = -1 \quad P(X < 22) = P(Z < -1) = 0.1587$

El área a la izquierda de  $x = 22$  en la escala original es **EXACTAMENTE** igual al área a la izquierda de  $z = -1$  en la escala estandarizada.

## Normal — Fuerza de presión manual

```
mu <- 30; sigma <- 8
curve(dnorm(x, mu, sigma), mu-24, mu+24, col="steelblue", lwd=3,
      main="Fuerza de Presión Manual - N(30, 8²) kg",
      xlab="Kilogramos", ylab="Densidad", cex.lab=1.2)
abline(v=c(mu-2*sigma, mu-sigma, mu, mu+sigma, mu+2*sigma),
       lty=c(3,3,2,3,3), lwd=c(1,1,2,1,1), col=c("grey","grey","coral","grey","grey"))
text(mu, 0.052, " =30", col="darkgreen", font=2)
```



$$P(X < 22) = P\left(Z < \frac{22 - 30}{8}\right) = P(Z < -1) = 0.159$$

$$P(22 < X < 38) = P(-1 < Z < 1) = 0.683$$

```
cat("P(X<22) =", round(pnorm(22, mu, sigma),3),
    "\nP(22<X<38) =", round(pnorm(38,mu,sigma)-pnorm(22,mu,sigma),3))
```

$P(X < 22) = 0.159$

$P(22 < X < 38) = 0.683$


## Normal — Percentiles clave

Los más usados en inferencia estadística:

| Percentil    | Z            | Uso                     |
|--------------|--------------|-------------------------|
| 90%          | 1.282        | IC 80%                  |
| 95%          | 1.645        | Test unilateral         |
| <b>97.5%</b> | <b>1.960</b> | <b>IC 95% bilateral</b> |
| 99%          | 2.326        | IC 98%                  |
| 99.5%        | 2.576        | IC 99%                  |

```
curve(dnorm(x), -4, 4, col="steelblue", lwd=2,
      main="Z = ±1.96 deja 95% central",
      xlab="z", ylab=expression(varphi(z)))
abline(v=c(-1.96, 1.96), col="darkgreen", lty=2, lwd=2)
xr <- seq(1.96, 4, 0.01); yr <- dnorm(xr)
polygon(c(xr, rev(xr)), c(yr, rep(0,length(yr))), col=rgb(0,0.5,0.3,0.2), border=NA)
xl <- seq(-4, -1.96, 0.01); yl <- dnorm(xl)
polygon(c(xl, rev(xl)), c(yl, rep(0,length(yl))), col=rgb(0,0.5,0.3,0.2), border=NA)
text(c(-2.5, 0, 2.5), c(0.03, 0.25, 0.03), c("2.5%", "95%", "2.5%"), font=2)
```

**$Z = \pm 1.96$  deja 95% central**



```
cat("Z para IC 95%", round(qnorm(0.975), 3),  
    "\nZ para IC 99%", round(qnorm(0.995), 3))
```

Z para IC 95%: 1.96

Z para IC 99%: 2.576

*Un paciente tiene  $Z = -1.5$  en fuerza de prensión y  $Z = +2.1$  en IMC. ¿Cuál de las dos mediciones es más preocupante? ¿Por qué?*

---

## Modelos para Datos Discretos en Fisioterapia

**Conexión:** Muchos fenómenos en fisioterapia son conteos: número de pacientes que responden a un tratamiento, número de sesiones necesarias para alcanzar un objetivo funcional. Las distribuciones Binomial y Poisson modelan estos eventos discretos.

### Distribución Binomial — Contexto histórico

**Jacob Bernoulli** (1654–1705) en su obra póstuma *Ars Conjectandi* (1713) estudió experimentos con dos resultados posibles (éxito/fracaso). Su sobrino **Daniel Bernoulli** aplicó estos modelos a la medicina.

**¿Por qué “Binomial”?** La fórmula usa el **coeficiente binomial**  $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ , que cuenta el número de formas de elegir  $k$  éxitos entre  $n$  ensayos.

**En Fisioterapia:** La Binomial modela todo lo que consiste en contar **éxitos** en un número fijo de pacientes: ¿cuántos de 10 pacientes mejoran con una terapia? ¿cuántos de 20 tratamientos tienen éxito?

#### 💡 Tip

**Para recordar:** Binomial = **nº fijo de ensayos** ( $n$ ) + **probabilidad constante** ( $p$ ) + **independencia** entre ensayos. Si tratamos 10 pacientes con la misma terapia y cada uno mejora o no independientemente → Binomial.

### Distribución Binomial

#### i Note

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$$


donde  $\binom{n}{k} = \frac{n!}{k!(n-k)!}$  es el coeficiente binomial.

- **Significado:** Número de éxitos en  $n$  ensayos independientes con probabilidad  $p$
- $E(X) = n \cdot p$ ,  $\text{Var}(X) = n \cdot p \cdot (1-p)$
- Forma simétrica si  $p = 0.5$ , asimétrica si  $p \neq 0.5$

**Ejemplo clínico:** Fármaco cura al 70% de pacientes ( $p = 0.7$ ),  $n = 10$  tratados.

## Binomial — Ejemplo clínico con R

```
n <- 10; p <- 0.7; k <- 0:n
bp <- barplot(dbinom(k, n, p), names.arg=k, col="steelblue",
              main="Binomial(10, 0.7): N° de curaciones en 10 pacientes",
              xlab="N° de pacientes curados", ylab="P(X=k)", ylim=c(0,0.3))
text(bp, dbinom(k,n,p)+0.012, round(dbinom(k,n,p),3), cex=0.7, font=2)
```



**Cálculo a mano —  $P(X = 7)$ :**

$$\binom{10}{7} = \frac{10 \cdot 9 \cdot 8}{3 \cdot 2 \cdot 1} = 120$$

$$P(X = 7) = 120 \cdot (0.7)^7 \cdot (0.3)^3 = 120 \cdot 0.0824 \cdot 0.027 = 0.267$$

```
cat("Manual:", round(120*0.7^7*0.3^3,3),
    "\ndbinom:", round(dbinom(7,10,0.7),3))
```


Manual: 0.267  
 dbinom: 0.267

### f.d.a. de la Binomial — Cálculo de Probabilidades Acumuladas

```
n <- 10; p <- 0.7; k <- 0:n
Fx <- pbinom(k, n, p)
plot(k, Fx, type="s", lwd=3, col="seagreen",
     main=expression(paste("f.d.a. Binomial(10, 0.7): F(k) = P(X ≤ k)")),
     xlab="Nº de pacientes curados (k)", ylab="F(k)", ylim=c(0,1))
abline(h=c(0,0.5,1), lty=3, col="grey"); points(k, Fx, pch=19, col="seagreen", cex=1.3)
# Marcar F(7)
points(7, Fx[8], pch=19, col="darkgreen", cex=1.8)
text(7, Fx[8]-0.05, paste0("F(7) = ", round(Fx[8],3)), col="darkgreen", font=2)
```



f.d.a. Binomial(10, 0.7):  $F(k) = P(X \leq k)$



$$F(7) = P(X \leq 7) = \sum_{k=0}^7 \binom{10}{k} 0.7^k \cdot 0.3^{10-k}$$

**Binomial — Regla de oro (Variables discretas)**

### ⚠ Warning

En VA discretas, los límites de los intervalos **importan**:

- $P(X \leq k) = \text{pbinom}(k, n, p)$
- $P(X < k) = \text{pbinom}(k-1, n, p) \leftarrow$  ¡no es lo mismo!
- $P(X \geq k) = 1 - \text{pbinom}(k-1, n, p)$
- $P(X > k) = 1 - \text{pbinom}(k, n, p)$

```
n <- 10; p <- 0.7
cat("P(X = 7) =", round(pbinom(7,n,p), 4),
    "\nP(X < 7) = P(X = 6) =", round(pbinom(6,n,p), 4), " ← ¡diferente!",
    "\nP(X = 7) =", round(1-pbinom(6,n,p), 4),
    "\nP(X > 7) =", round(1-pbinom(7,n,p), 4))
```

```
P(X = 7) = 0.6172
P(X < 7) = P(X = 6) = 0.3504 ← ¡diferente!
P(X = 7) = 0.6496
P(X > 7) = 0.3828
```

## Distribución de Poisson — Contexto histórico

**Siméon Denis Poisson** (1781–1840) publicó esta distribución en 1837 en su obra *Recherches sur la probabilité des jugements*. Originalmente modelaba el número de condenas erróneas en juicios.

¿Cuándo surge? La Poisson es el límite de la Binomial cuando  $n \rightarrow \infty$  y  $p \rightarrow 0$  manteniendo  $\lambda = n \cdot p$  constante. Esto la hace ideal para **eventos raros** en grandes poblaciones.

**En Fisioterapia:** La Poisson modela eventos que ocurren con tasa constante: nº de pacientes que llegan a urgencias por esguince en un turno, nº de caídas por mes en una residencia, nº de reacciones adversas por año en una clínica.

### 💡 Tip

**Para recordar:** Poisson = **tasa constante** ( $\lambda$ ) + eventos **independientes** en el tiempo.  
Si registramos cuántos pacientes llegan con lumbalgia aguda cada semana  $\rightarrow$  Poisson.

## Distribución de Poisson

**i** Note

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$


- **Significado:** Número de eventos raros en un intervalo fijo (tiempo/espacio)
- $E(X) = \lambda$ ,  $\text{Var}(X) = \lambda$  (¡media = varianza!)
- Propiedad aditiva:  $X \sim Po(\lambda_1), Y \sim Po(\lambda_2)$  indep.  $\rightarrow X + Y \sim Po(\lambda_1 + \lambda_2)$

**Ejemplo clínico:** Reacciones adversas en clínica de fisioterapia:  $\lambda = 3/\text{día}$

### Poisson — Ejemplo clínico con R

```
lambda <- 3; k <- 0:12
bp <- barplot(dpois(k, lambda), names.arg=k, col="coral",
              main="Poisson(3): Reacciones adversas por día",
              xlab="Nº de reacciones", ylab="P(X=k)")
```

### Poisson(3): Reacciones adversas por día



Cálculo a mano —  $P(X = 5)$ :

$$P(X = 5) = \frac{3^5 e^{-3}}{5!} = \frac{243 \cdot 0.0498}{120} \approx 0.101$$

```
cat("Manual:", round(3^5*exp(-3)/factorial(5),3),  
    "\ndpois:", round(dpois(5, lambda),3),  
    "\nP(X 2) =", round(ppois(2, lambda),3))
```


Manual: 0.101

dpois: 0.101

P(X 2) = 0.423

## f.d.a. de la Poisson — Cálculo de Probabilidades Acumuladas

```
lambda <- 3; k <- 0:12
Fx <- ppois(k, lambda)
plot(k, Fx, type="s", lwd=3, col="seagreen",
     main=expression(paste("f.d.a. Poisson(=3): F(k) = P(X ≤ k)")),
     xlab="Nº de reacciones adversas (k)", ylab="F(k)", ylim=c(0,1))
abline(h=c(0,0.5,1), lty=3, col="grey"); points(k, Fx, pch=19, col="seagreen", cex=1.3)
# Marcar F(2) y F(5)
points(c(2,5), Fx[c(3,6)], pch=19, col=c("darkred","steelblue"), cex=1.8)
text(3, Fx[3]+0.05, paste0("F(2) = ", round(Fx[3],3)), col="darkgreen", font=2)
text(6, Fx[6]+0.05, paste0("F(5) = ", round(Fx[6],3)), col="steelblue", font=2)
```



$$P(X \leq 2) = \sum_{k=0}^2 \frac{3^k e^{-3}}{k!} \quad P(2 < X \leq 5) = F(5) - F(2)$$

```
cat("F(2) =", round(ppois(2,3),3), " | F(5) =", round(ppois(5,3),3),
    " | P(2<X 5) =", round(ppois(5,3)-ppois(2,3),3))
```

F(2) = 0.423 | F(5) = 0.916 | P(2<X 5) = 0.493

## Distribución t-student — Origen y propiedades

La distribución *t-Student* la usaremos en el Tema 4 para comparar medias de dos grupos de tratamiento en fisioterapia.


**William S. Gosset** (1908), químico de Guinness, publicó bajo el seudónimo “**Student**”. Descubrió que al estimar  $\sigma$  con  $s$ , el cociente  $\frac{\bar{x}-\mu}{s/\sqrt{n}}$  NO sigue una Normal, sino una distribución con **colas más pesadas**.

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

**Propiedades:** - **Simétrica** alrededor de 0 (como la Normal) - Colas **más pesadas** que la Normal  $\rightarrow$  valores extremos más probables - Cuando  $n \rightarrow \infty$ ,  $t_{n-1} \rightarrow N(0,1)$  - Un solo parámetro: grados de libertad ( $gl = n - 1$ )

```
curve(dnorm(x), -4, 4, lwd=3, col="steelblue", ylab="Densidad",
      main="Normal vs t-Student (simétrica, colas pesadas)")
curve(dt(x, 3), -4, 4, lwd=3, col="seagreen", add=TRUE)
curve(dt(x, 10), -4, 4, lwd=3, col="darkgreen", add=TRUE)
legend("topright", c("N(0,1)", "t(3)", "t(10)"), col=c("steelblue", "coral", "darkgreen"), lwd=3)
```

## Normal vs t-Student (simétrica, colas pesadas)



**Uso principal:** IC para la media con  $\sigma$  desconocida, tests t para una y dos muestras.

## Distribución $\chi^2$ (Chi-Cuadrado) — Pearson

*La distribución  $\chi^2$  la usaremos en el Tema 5 para analizar tablas de contingencia y estudiar la asociación entre tratamientos de fisioterapia y resultados clínicos.*

**Karl Pearson** (1900). Surge como suma de  $k$  normales estándar independientes al cuadrado:

$$\chi_k^2 = Z_1^2 + Z_2^2 + \dots + Z_k^2 \sim \chi_k^2$$


**Propiedades:** - **NO es simétrica** (asimétrica positiva, cola a la derecha) - Solo toma valores  $\geq 0$  -  $E(\chi_k^2) = k$ ,  $\text{Var}(\chi_k^2) = 2k$  - Cuando  $k \rightarrow \infty$ , tiende a Normal

```

curve(dchisq(x, 1), 0, 15, lwd=3, col="seagreen", ylab="Densidad",
      main=expression(paste(chi^2, " - Asimétrica, solo valores ≥ 0")))
curve(dchisq(x, 3), 0, 15, lwd=3, col="darkgreen", add=TRUE)
curve(dchisq(x, 6), 0, 15, lwd=3, col="steelblue", add=TRUE)
legend("topright", c(expression(chi[1]^2), expression(chi[3]^2), expression(chi[6]^2)),
      col=c("seagreen", "darkgreen", "steelblue"), lwd=3, bty="n")

```

$\chi^2$  — Asimétrica, solo valores  $\geq 0$



**Uso principal:** Test  $\chi^2$  para tablas de contingencia, test de bondad de ajuste.

### Distribución F de Snedecor

*La distribución F la usaremos en el Tema 6 al evaluar modelos de regresión y comparar la variabilidad explicada por distintas variables clínicas.*




**George W. Snedecor** (1934), nombrada en honor a **R.A. Fisher**. Surge como cociente de dos  $\chi^2$  independientes divididas por sus grados de libertad:

$$F_{k_1, k_2} = \frac{\chi_{k_1}^2 / k_1}{\chi_{k_2}^2 / k_2}$$

**Propiedades:** - **NO es simétrica** (asimétrica positiva, como  $\chi^2$ ) - Solo toma valores  $\geq 0$  - Dos parámetros:  $gl_1$  (numerador) y  $gl_2$  (denominador)

```
curve(df(x, 5, 5), 0, 5, lwd=3, col="steelblue", ylab="Densidad",
      main="Distribución F - Asimétrica, dos parámetros")
curve(df(x, 10, 5), 0, 5, lwd=3, col="seagreen", add=TRUE)
curve(df(x, 5, 20), 0, 5, lwd=3, col="darkgreen", add=TRUE)
legend("topright", c("F(5,5)", "F(10,5)", "F(5,20)"), col=c("steelblue", "coral", "darkgreen"),
```

### Distribución F — Asimétrica, dos parámetros



**Uso principal:** Test F para igualdad de varianzas, ANOVA, regresión (test F global).

### Cálculo de p-valores — ¡cuidado con la asimetría!

| Distribución     | ¿Simétrica? | P-valor bilateral                                | Función R             |
|------------------|-------------|--------------------------------------------------|-----------------------|
| <b>Normal</b>    | Sí          | $2 * \text{pnorm}(-\text{abs}(z))$               | <code>pnorm()</code>  |
| <b>t-Student</b> | Sí          | $2 * \text{pt}(-\text{abs}(t), \text{df})$       | <code>pt()</code>     |
| $\chi^2$         | No          | No tiene sentido bilateral<br>(test de una cola) | <code>pchisq()</code> |
| <b>F</b>         | No          | Usar cola adecuada según $F_{\text{obs}}$        | <code>pf()</code>     |

Para  $\chi^2$  y F (asimétricas), el test es inherentemente unilateral porque solo nos preocupan valores grandes del estadístico (discrepancias grandes de  $H_0$ ).

```
# P-valor para  $\chi^2$  (siempre cola derecha)
chi_obs <- 13.87; gl <- 6
p_chi <- pchisq(chi_obs, gl, lower.tail=FALSE)
cat("  $\chi^2$  =", chi_obs, "gl =", gl, "→ P =", round(p_chi, 4))
```

$\chi^2 = 13.87$  gl = 6 → P = 0.0311

```
# P-valor para F (cola derecha si F > 1)
F_obs <- 3.5; gl1 <- 5; gl2 <- 20
p_F <- pf(F_obs, gl1, gl2, lower.tail=FALSE)
cat("\nF =", F_obs, "gl =", gl1, ", ", gl2, "→ P =", round(p_F, 4))
```

F = 3.5 gl = 5 , 20 → P = 0.0196

#### Warning

**Para estudiantes:** t es simétrica → P-valor bilateral se calcula como  $2 \times P(T > |t|)$ .  $\chi^2$  y F **no** son simétricas → el P-valor se calcula solo en la cola correspondiente. **Nunca** multipliques por 2 para  $\chi^2$  o F.

## Guía rápida: ¿qué distribución uso en fisioterapia?

| Situación clínica                         | Distribución         | Parámetros    | Función R                                        |
|-------------------------------------------|----------------------|---------------|--------------------------------------------------|
| ROM, fuerza, PA (variables continuas)     | <b>Normal</b>        | $\mu, \sigma$ | <code>dnorm()</code> ,<br><code>pnorm()</code>   |
| Éxitos en n pacientes (curación, mejoría) | <b>Binomial</b>      | $n, p$        | <code>dbinom()</code> ,<br><code>pbinom()</code> |
| Eventos raros por unidad de tiempo        | <b>Poisson</b>       | $\lambda$     | <code>dpois()</code> ,<br><code>ppois()</code>   |
| Inferencia sobre medias                   | <b>t-Student</b>     | $gl$          | <code>dt()</code> , <code>pt()</code>            |
| Comparación de varianzas                  | <b>F de Snedecor</b> | $gl_1, gl_2$  | <code>df()</code> , <code>pf()</code>            |
| Tablas de contingencia                    | $\chi^2$             | $gl$          | <code>dchisq()</code> ,<br><code>pchisq()</code> |


### Tip

**Regla nemotécnica:** **d** = densidad/probabilidad puntual, **p** = probabilidad acumulada (CDF), **q** = cuantil (percentil), **r** = aleatorio.

## Comparativa de las tres distribuciones

|                        | Normal        | Binomial            | Poisson              |
|------------------------|---------------|---------------------|----------------------|
| <b>Tipo</b>            | Continua      | Discreta            | Discreta             |
| <b>Parámetros</b>      | $\mu, \sigma$ | $n, p$              | $\lambda$            |
| <b>Soporte</b>         | $\mathbb{R}$  | $\{0, \dots, n\}$   | $\{0, 1, 2, \dots\}$ |
| $E(X)$                 | $\mu$         | $np$                | $\lambda$            |
| $\text{Var}(X)$        | $\sigma^2$    | $np(1-p)$           | $\lambda$            |
| <b>Ejemplo clínico</b> | ROM, fuerza   | Éxitos terapéuticos | Eventos adversos     |

```
par(mfrow=c(1,3), mar=c(4,4,3,1))
curve(dnorm(x), -4,4, col="steelblue", lwd=2, main="N(0,1)", xlab="x")
barplot(dbinom(0:10,10,0.5), names=0:10, col="seagreen",
        main="Bin(10,0.5)", xlab="x", ylab="P(X=x)")
barplot(dpois(0:10,3), names=0:10, col="seagreen",
        main="Pois(=3)", xlab="x", ylab="P(X=x)")
```



```
par(mfrow=c(1,1))
```

## Aproximaciones y Teorema Central del Límite

**Conexión T02→T03:** Las aproximaciones entre distribuciones son la base del Teorema Central del Límite, que en el Tema 3 nos permitirá construir intervalos de confianza para cualquier parámetro.

## ¿Por Qué Aproximamos? — Motivación

Calcular probabilidades exactas con la Binomial requiere evaluar factores combinatorios  $\binom{n}{k}$  que se vuelven **imposibles de calcular a mano** cuando  $n$  es grande. Las aproximaciones nos permiten usar la **Normal** (mucho más manejable) en su lugar.

**Idea clave:** Bajo ciertas condiciones, las distribuciones discretas “se parecen” a la Normal cuando el tamaño muestral es grande. Esto es consecuencia del **Teorema Central del Límite**.

| Aproximación                  | Condición                     | Fórmula                                   |
|-------------------------------|-------------------------------|-------------------------------------------|
| Binomial $\rightarrow$ Normal | $np \geq 5$ y $n(1-p) \geq 5$ | $B(n, p) \approx N(np, np(1-p))$          |
| Poisson $\rightarrow$ Normal  | $\lambda \geq 10$             | $Po(\lambda) \approx N(\lambda, \lambda)$ |

## Binomial $\rightarrow$ Normal — Condiciones y visualización

**¿Cuándo funciona?** Cuando  $np \geq 5$  y  $n(1-p) \geq 5$ , el histograma binomial adopta forma de campana.

```
par(mfrow=c(2,2), mar=c(4,4,3,1))


# Caso 1: NO se cumple (n=10, p=0.1  $\rightarrow$  np=1 < 5)
n<-10; p<-0.1; x<-0:n
barplot(dbinom(x,n,p), names=x, col="seagreen", main=paste0("NO aprox: n=",n," p=",p," (np="
```

```
# Caso 2: NO se cumple (n=10, p=0.9  $\rightarrow$  n(1-p)=1 < 5)
p<-0.9
barplot(dbinom(x,n,p), names=x, col="seagreen", main=paste0("NO aprox: n=",n," p=",p," (n(1-
```


```
# Caso 3: SÍ se cumple (n=50, p=0.3  $\rightarrow$  np=15, n(1-p)=35 5)
n<-50; p<-0.3; x<-0:n
bp <- barplot(dbinom(x,n,p), names=ifelse(x%%5==0,x,""), col="steelblue",
             main=paste0("SÍ aprox: n=",n," p=",p," (np=",n*p," 5, n(1-p)=",n*(1-p)," 5)"))
curve(dnorm(x,n*p,sqrt(n*p*(1-p)))*1, add=T, col="darkgreen", lwd=2, n=200)
```

```
# Caso 4: SÍ se cumple (n=100, p=0.5  $\rightarrow$  ambos 5)
n<-100; p<-0.5; x<-0:n
bp <- barplot(dbinom(x,n,p), names=ifelse(x%%25==0,x,""), col="steelblue",
             main=paste0("SÍ aprox: n=",n," p=",p,"  $\rightarrow$  forma campana perfecta"))
curve(dnorm(x,n*p,sqrt(n*p*(1-p)))*1, add=T, col="darkgreen", lwd=2, n=200)
```



NO aprox:  $n=10$ ,  $p=0.1$  ( $np=1 < 5$ )



NO aprox:  $n=10$ ,  $p=0.9$  ( $n(1-p)=1 < 5$ )



¡ aprox:  $n=50$ ,  $p=0.3$  ( $np=15 \geq 5$ ,  $n(1-p)=35 \geq 5$ ) → forma campana



```
par(mfrow=c(1,1))
```

## Binomial → Normal — Corrección de continuidad

La Binomial es **discreta** (barras) y la Normal es **continua** (curva). Para aproximar  $P(X \leq k)$ , sumamos/restamos 0.5:

| Probabilidad  | Sin corrección                                     | Con corrección ( $\pm 0.5$ )                           |
|---------------|----------------------------------------------------|--------------------------------------------------------|
| $P(X \leq k)$ | $\Phi\left(\frac{k-np}{\sqrt{np(1-p)}}\right)$     | $\Phi\left(\frac{k+0.5-np}{\sqrt{np(1-p)}}\right)$     |
| $P(X \geq k)$ | $1 - \Phi\left(\frac{k-np}{\sqrt{np(1-p)}}\right)$ | $1 - \Phi\left(\frac{k-0.5-np}{\sqrt{np(1-p)}}\right)$ |

**Ejemplo clínico:** Fármaco 40% efectivo,  $n = 20$  pacientes.  $P(X \leq 10)$ :

```
n<-20; p<-0.4; k<-10
exacto <- pbinom(k, n, p)
sin_corr <- pnorm(k, n*p, sqrt(n*p*(1-p)))
con_corr <- pnorm(k+0.5, n*p, sqrt(n*p*(1-p)))
cat("Exacto (Binomial):      ", round(exacto, 4),
    "\nNormal sin corrección: ", round(sin_corr, 4),
    "\nNormal con corrección:  ", round(con_corr, 4))
```

```
Exacto (Binomial):      0.8725
Normal sin corrección:  0.8193
Normal con corrección:  0.8731
```

#### Tip

La corrección de continuidad (+0.5) reduce el error de aproximación drásticamente. En el ejemplo, el error pasa de ~5pp a <0.1pp.

## Poisson → Normal — Condiciones

¿Cuándo funciona? Cuando  $\lambda \geq 10$ , el histograma de Poisson adopta forma simétrica.

```
par(mfrow=c(2,2), mar=c(4,4,3,1))


# Caso 1: =2 → NO se cumple (muy asimétrica)
lambda<-2; x<-0:(lambda*3)
barplot(dpois(x,lambda), names=x, col="seagreen",
        main=paste0("NO aprox: =",lambda," < 10 (asimétrica)"))

# Caso 2: =5 → NO se cumple (todavía asimétrica)
lambda<-5; x<-0:(lambda*3)
barplot(dpois(x,lambda), names=x, col="seagreen",
        main=paste0("NO aprox: =",lambda," < 10"))


# Caso 3: =10 → SÍ se cumple (empieza a ser simétrica)
lambda<-10; x<-0:(lambda*2)
bp <- barplot(dpois(x,lambda), names=ifelse(x%%5==0,x,""), col="steelblue",
              main=paste0("SÍ aprox: =",lambda," 10"))
curve(dnorm(x,lambda,sqrt(lambda))*1, add=T, col="darkgreen", lwd=2, n=200)
```

```
# Caso 4:  $\lambda=25 \rightarrow$  Sí se cumple (claramente acampanada)
lambda<-25; x<-0:(lambda*2)
bp <- barplot(dpois(x,lambda), names=ifelse(x%10==0,x,""), col="steelblue",
  main=paste0("Sí aprox: =",lambda,"  $\rightarrow$  forma campana clara"))
curve(dnorm(x,lambda,sqrt(lambda))*1, add=T, col="darkgreen", lwd=2, n=200)
```


**NO aprox:  $\lambda=2 < 10$  (asimétrica)**




**NO aprox:  $\lambda=5 < 10$**



**Sí aprox:  $\lambda=10 \geq 10$**



**Sí aprox:  $\lambda=25 \rightarrow$  forma campana**



```
par(mfrow=c(1,1))
```

```
lambda<-10; k<-7
exacto <- ppois(k, lambda)
con_corr <- pnorm(k+0.5, lambda, sqrt(lambda))
cat("Exacto (Poisson):      ", round(exacto, 4),
  "\nNormal con corrección: ", round(con_corr, 4))
```



Exacto (Poisson): 0.2202  
Normal con corrección: 0.2146

### ¿Por Qué Usamos Aproximaciones?

1. **Cálculo manual:** Con  $n = 100$ , calcular  $\binom{100}{50}$  a mano es imposible. La Normal lo resuelve con una fórmula simple.
2. **Inferencia:** Los IC y tests de hipótesis para proporciones usan la aproximación Normal (por eso usamos  $z_\alpha$ , no  $t$ ).
3. **Teoría:** El TCL garantiza que **cualquier** suma de variables independientes tiende a la Normal cuando  $n$  es grande — es la base de toda la inferencia estadística.
4. **Software moderno:** Aunque R calcula valores exactos, entender las aproximaciones ayuda a comprender **por qué** funcionan los métodos estadísticos.

#### ! Important

**Condiciones para aplicar la aproximación Normal a la Binomial:**  $np \geq 5$  Y  $n(1-p) \geq 5$ . Si no se cumplen, usar el método exacto (Binomial). **Para Poisson:**  $\lambda \geq 10$ . Si no, usar el método exacto (Poisson).

---

### Ejercicio Clínico — Aplicación de Probabilidad y Distribuciones

Un estudio sobre recuperación funcional tras accidente cerebrovascular reporta que el 30% de los pacientes recupera la marcha independiente en 6 meses.

1. Si tratas a 10 pacientes, ¿cuál es la probabilidad de que exactamente 4 recuperen la marcha? Usa `dbinom(4, 10, 0.3)`.
2. ¿Y la probabilidad de que al menos 6 recuperen la marcha? Usa `pbinom(5, 10, 0.3, lower.tail=FALSE)`.
3. Las puntuaciones de Barthel a los 6 meses siguen una Normal(75, 15). Un paciente obtiene 95. Calcula su Z-score:  $(95-75)/15$ . ¿Es un valor atípico?
4. ¿Qué percentil ocupa? `pnorm(95, 75, 15)`. Interpreta el resultado.

## Resumen — Tema 2

- **Probabilidad** como herramienta para cuantificar incertidumbre clínica (Kolmogorov, Bayes)
  - **Probabilidad condicionada** → Teorema de Bayes → VPP y VPN: herramientas clave para interpretar pruebas diagnósticas
  - **Variables aleatorias discretas:** Binomial (nº de éxitos terapéuticos), Poisson (eventos adversos)
  - **Variables aleatorias continuas:** Normal (la distribución central en clínica), t-Student,  $\chi^2$ , F
  - **Función de densidad y distribución:**  $f(x)$  describe la forma,  $F(x) = P(X \leq x)$  calcula probabilidades
  - **Aproximaciones y TCL:** la Normal como límite universal → base de la inferencia en T3
  - **Funciones R** `d`, `p`, `q`, `r` para trabajar con cualquier distribución
- 

## Referencias complementarias del libro:

### Referencias

- (Femia & Luque-Fernández, 2026) Femia, P. & Luque-Fernández, M. A. (2026). *BioEstatR: Biostatistics Routines in R*. R package v1.0.0. Universidad de Granada. <https://migariane.github.io/BioEstatR>
  - (Kolmogorov, 1933) Kolmogorov, A. N. (1933). *Grundbegriffe der Wahrscheinlichkeitsrechnung*. Springer.
  - (Luque-Fernández, 2026) Luque-Fernández, M. A. (2026). *Matemáticas para la Estadística Médica con R*. Cap. 3: Fundamentos de Probabilidad. Universidad de Granada. <https://migariane.github.io/MatematicaEstadisticaMedicinaR>
  - (Luque-Fernández, 2026) Luque-Fernández, M. A. (2026). *Matemáticas para la Estadística Médica con R*. Cap. 4: Variables Aleatorias y Distribuciones. Universidad de Granada.
- 

## Ejercicio Clínico — Tema II (Parte II)

**Contexto:** Fuerza de prensión  $\sim N(30, 8^2)$  kg. Paciente con 22 kg. Terapia con 70% éxito por paciente.

1. Calcula Z-score de 22 kg e interpreta
2. ¿% población con fuerza  $\leq 22$  kg?



3. Tratando 10 pacientes, ¿P(exactamente 8 mejorías)?

### 💡 Tip

### Solución

1.  $Z = (22 - 30)/8 = -1.0 \rightarrow 1$  DE bajo la media
2.  $P(X \leq 22) = 15.9\%$  de la población
3.  $P(X = 8) = \binom{10}{8}(0.7)^8(0.3)^2 = 23.3\%$

```
mu <- 30; sigma <- 8
par(mfrow=c(1,2), mar=c(4,4,3,1))
# Panel 1: Distribución normal
curve(dnorm(x, mu, sigma), mu-24, mu+24, lwd=3, col="steelblue",
      main=paste0("P(X ≤ 22) = ", round(pnorm(22,mu,sigma)*100,1),"%"),
      xlab="Fuerza (kg)", ylab="Densidad")
abline(v=22, col="darkgreen", lwd=2)
xr <- seq(mu-24, 22, 0.1)
polygon(c(xr, rev(xr)), c(dnorm(xr,mu,sigma), rep(0,length(xr))),
      col=rgb(0,0.5,0.3,0.3), border=NA)
# Panel 2: Binomial
p_binom <- dbinom(8, 10, 0.7)
probs <- dbinom(0:10, 10, 0.7)
highlight <- ifelse(0:10==8, "coral", "steelblue")
barplot(probs, names=0:10, col=highlight, border="white",
      main=paste0("Bin(10,0.7): P(X=8)=", round(p_binom*100,1),"%"),
      xlab="Nº mejorías", ylab="Probabilidad")
abline(h=p_binom, col="darkgreen", lty=2, lwd=2)
```



```
par(mfrow=c(1,1))

cat("Z =", round((22-30)/8,1), "\nP(X ≤ 22) =", round(pnorm(22,30,8)*100,1), "%",
    "\nP(X=8) =", round(dbinom(8,10,0.7)*100,1), "%")
```

Z = -1  
P(X ≤ 22) = 15.9 %  
P(X=8) = 23.3 %

## Código del Tema II (Parte II) — Resumen Organizado

### Distribución Normal y estandarización

```
# Propiedades  $N(\mu, \sigma^2)$ 
mu <- 30; sigma <- 8
pnorm(22, mu, sigma)           #  $P(X < 22) = 15.9\%$ 
pnorm(38, mu, sigma) - pnorm(22, mu, sigma) #  $P(22 < X < 38) = 68.3\%$ 

# Z-scores
z <- (22 - 30) / 8              #  $Z = -1.0$ 
pnorm(-1)                      #  $P(Z < -1) = 15.9\%$ 

# Percentiles clave
qnorm(0.975)                   #  $Z = 1.96$  (IC 95%)
qnorm(0.995)                   #  $Z = 2.576$  (IC 99%)

# lower.tail = FALSE para cola derecha
pnorm(1.96, lower.tail = FALSE) #  $P(Z > 1.96) = 2.5\%$ 
```

### Distribuciones discretas

```
# Binomial(n, p) - n° de éxitos en n ensayos
n <- 10; p <- 0.7
dbinom(8, n, p)                #  $P(X = 8)$  exacto
pbinom(7, n, p)                #  $P(X \leq 7)$ 
pbinom(7, n, p, lower.tail = FALSE) #  $P(X > 7) = P(X \geq 8)$ 

# Poisson() - n° de eventos en intervalo
lambda <- 4
dpois(3, lambda)               #  $P(X = 3)$ 
ppois(2, lambda)               #  $P(X \leq 2)$ 

#  $\chi^2$  y F - colas asimétricas
pchisq(13.87, 6, lower.tail = FALSE) #  $P(\chi^2 > 13.87)$ 
pf(3.5, 5, 20, lower.tail = FALSE)  #  $P(F_{5,20} > 3.5)$ 
```

## Aproximaciones

```
# Binomial → Normal: np > 5 y n(1-p) > 5
n <- 50; p <- 0.3
p_exacto <- pbinom(10, n, p)
p_normal <- pnorm(10.5, n*p, sqrt(n*p*(1-p))) # Con corrección +0.5

# Poisson → Normal: λ > 10
lambda <- 25
p_pois <- ppois(20, lambda)
p_norm <- pnorm(20.5, lambda, sqrt(lambda)) # Con corrección +0.5
```

Femia, P., & Luque-Fernández, M. A. (2026). *BioEstatR: Biostatistics routines in r*. <https://migariane.github.io/BioEstatR>

Kolmogorov, A. N. (1933). *Grundbegriffe der wahrscheinlichkeitsrechnung*. Springer.

Luque-Fernández, M. A. (2026). *Matemáticas para la estadística médica con r*. Universidad de Granada. <https://migariane.github.io/MatematicaEstadisticaMedicinaR>